

**POLITECNICO DI MILANO**  
Corso di Laurea Magistrale in Ingegneria Informatica  
Dipartimento di Elettronica, Informazione e Bioingegneria



**TAMPERING DETECTION PER  
CAMERE INTELLIGENTI A BASSO  
CONSUMO ENERGETICO**

Relatore: Prof. Giacomo BORACCHI  
Correlatori: Ing. Claudio MARCHISIO  
Ing. Alessandro SENTINELLI

Tesi di Laurea di:  
**Adriano GAIBOTTI, matricola 780200**

Anno Accademico 2013-2014



*È per te il dubbio e la certezza  
La forza e la dolcezza  
È per te che il mare sa di sale  
È per te la notte di natale  
È per te ogni cosa che c'è  
Ninna na ninna e...*

*Jovanotti*



# Sommario

Nel campo dei sistemi di monitoraggio video, uno dei principali problemi è quello di identificare eventi che possano compromettere la corretta ripresa della scena, come ad esempio lo spostamento della camera o la sfocatura dovuta a dell'acqua che si deposita a ridosso della lente. Il problema di individuare, in maniera automatica, questo tipo di eventi prende il nome di *tampering detection*. Nella letteratura scientifica questo problema è stato affrontato solamente per applicazioni in cui la camera opera con acquisizione continua, dispone di una certa potenza computazionale e viene alimentata a corrente.

Lo scopo della tesi è lo sviluppo di un algoritmo di tampering detection per camere intelligenti (*smart camera*) e a basso consumo, da utilizzarsi in scenari di monitoraggio. In particolare, l'algoritmo è caratterizzato da un basso carico computazionale ed è pensato per scenari, tipo il monitoraggio ambientale, dove il sistema, per ridurre il consumo energetico, acquisisce e analizza poche immagini al minuto o all'ora. In questi casi scene ad *alta dinamicità*, come una strada in cui passano macchine e pedoni, non permettono di identificare eventi di tampering tramite un confronto tra frame consecutivi. Inoltre, operando a bassi framerate, si verificano sostanziali variazioni di luminosità tra immagini consecutive.

L'algoritmo proposto si basa su indicatori, estratti dalle singole immagini, calcolati a bassa complessità computazionale; tali indicatori vengono monitorati nel tempo attraverso tecniche *sequenziali* e *one-shot* per identificare l'istante in cui avviene l'evento di tampering. Data l'alta variabilità degli indicatori utilizzati, abbiamo introdotto una fase di *segmentazione* della scena, in modo da limitare l'analisi ad alcune regioni specifiche: questo permette di migliorare le prestazioni dell'algoritmo e diminuire il numero di falsi allarmi. La tesi è stata svolta durante un lavoro di stage presso il gruppo *Advanced System Technology* di *STMicroelectronics*, dove la ricerca è volta allo sviluppo di algoritmi intelligenti di elaborazione immagini da integrare nei propri dispositivi embedded. Sono stati messi a punto diversi sistemi di acquisizione operanti a diversi framerate, che hanno permesso di generare i dataset per testare l'efficacia della soluzione proposta e, in particolare, dei vantaggi nell'utilizzo della segmentazione a supporto del tampering detection.



# Indice

<b>Sommario</b>	<b>iii</b>
<b>1 Introduzione</b>	<b>3</b>
<b>2 Stato dell'arte</b>	<b>9</b>
2.1 Modello della camera . . . . .	9
2.1.1 La matrice prospettica della camera . . . . .	10
2.1.2 Parametri intrinseci . . . . .	12
2.1.3 Parametri estrinseci . . . . .	14
2.2 Rappresentazione digitale delle immagini . . . . .	15
2.3 Identificazione del cambiamento nella stazionarietà di un processo . . . . .	16
2.3.1 Metodi di Change-Point . . . . .	17
2.3.2 Change-Detection Test . . . . .	19
2.4 Tampering Detection . . . . .	26
2.4.1 Concetti e terminologia . . . . .	28
2.4.2 Tecniche basate su confronto di background . . . . .	29
2.4.3 Tecniche basate su monitoraggio sequenziale . . . . .	33
<b>3 Impostazione del problema di ricerca</b>	<b>37</b>
3.1 Modello delle osservazioni . . . . .	37
3.1.1 Sfocatura . . . . .	37
3.1.2 Spostamento della camera . . . . .	39
3.1.3 Occlusione e guasti della camera . . . . .	41
3.2 Tampering detection . . . . .	41
<b>4 Soluzione proposta</b>	<b>43</b>
4.1 Indicatori utilizzati per identificare gli eventi di tampering . .	43
4.1.1 Misura della sfocatura nell'immagine . . . . .	43
4.1.2 Misura dello spostamento della camera . . . . .	45
4.1.3 Comportamento degli indicatori nel tempo . . . . .	48
4.1.4 Detrending degli indicatori . . . . .	49
4.2 Algoritmo di identificazione di sfocature e di spostamenti della camera . . . . .	56

4.2.1	Identificazione delle sfocature . . . . .	57
4.2.2	Identificazione degli spostamenti della camera . . . . .	59
4.3	Algoritmo di segmentazione . . . . .	60
4.3.1	Calcolo dei descrittori utilizzati per la segmentazione .	62
4.3.2	Partizionamento dei feature vector per l'estrazione delle regioni . . . . .	64
4.3.3	Separazione e rifinitura delle regioni . . . . .	67
<b>5</b>	<b>Prove sperimentali e valutazione</b>	<b>69</b>
5.1	Metodi considerati e obiettivi . . . . .	69
5.2	Acquisizione dei dataset . . . . .	70
5.2.1	Eventi di tampering . . . . .	72
5.2.2	Definizione dei ground truth . . . . .	73
5.3	Figure di merito . . . . .	73
5.3.1	Creazione delle ROC curve per il monitoraggio one-shot	73
5.3.2	Metriche per il monitoraggio sequenziale . . . . .	75
5.4	Esperimento 1: tampering sintetico . . . . .	75
5.4.1	Creazione del tampering . . . . .	75
5.4.2	Risultati . . . . .	77
5.5	Esperimento 2: tampering reale . . . . .	81
<b>6</b>	<b>Conclusioni e direzioni future di ricerca</b>	<b>83</b>
<b>Bibliografia</b>		<b>85</b>

# Elenco delle figure

1.1	Esempio di WMSN . . . . .	4
1.2	Esempi di eventi di tampering intenzionali . . . . .	5
1.3	Esempi di eventi di tampering dovuti a cause naturali . . . . .	6
2.1	Athanasius Kircher, Principio della prospettiva nella camera obscura, 1671 . . . . .	10
2.2	Schematizzazione del sistema ottico della camera . . . . .	11
2.3	Similitudini tra triangoli usate nel calcolo dei parametri intrinseci . . . . .	12
2.4	Coordinate di un frame . . . . .	13
2.5	Trasformazione dal sistema di coordinate dell'ambiente a quello della camera . . . . .	14
2.6	Esempio di estrazione dei canali RGB . . . . .	15
2.7	Esempio di estrazione dei canali YUV . . . . .	16
2.8	Esempio di CPM . . . . .	19
2.9	Procedura del CUSUM adattativo . . . . .	22
2.10	Estrazione dei descrittori nel metodo CI-CUSUM . . . . .	22
2.11	Esempio di come opera la regola dell'intersezione degli intervalli di confidenza (ICI-rule) . . . . .	25
2.12	Schema del modo di operare del CDT di tipo gerarchico . . .	26
2.13	Tecniche di tampering detection . . . . .	27
2.14	Sistema di monitoraggio video . . . . .	28
2.15	Comportamento della trasformata di Fourier nel caso di sfocatura . . . . .	31
2.16	Sequenza di frame acquisiti a 30 fps . . . . .	32
2.17	Sequenza di frame acquisiti ogni 30 secondi . . . . .	33
3.1	Esempi di sfocature . . . . .	38
3.2	Sequenza di otto frame consecutivi acquisiti ogni minuto . . .	39
3.3	Esempio di spostamento della camera . . . . .	40
3.4	Esempi di occlusione . . . . .	41
3.5	Esempi di guasti . . . . .	42
4.1	Esempio di cambi di luminosità tra il giorno e la notte . . . . .	44

4.2	Esempio di presenza di sfocature dovute all'aumento del tempo di esposizione della camera . . . . .	45
4.3	Energia media del gradiente lungo un'acquisizione di 24 ore e suo detrending . . . . .	46
4.4	Energia media della luma lungo un'acquisizione di 24 ore e suo detrending . . . . .	47
4.5	Energia media del gradiente e suo detrending nel caso di una sfocatura . . . . .	50
4.6	Energia media della luma e suo detrending nel caso di una sfocatura . . . . .	51
4.7	Energia media del gradiente e suo detrending nel caso di uno spostamento della camera . . . . .	52
4.8	Energia media della luma e suo detrending nel caso di uno spostamento della camera . . . . .	53
4.9	Esempio di sequenza dell'energia media della luma e del suo detrending con un displacement difficile da identificare . . . . .	55
4.10	Esempio di spostamento della camera . . . . .	56
4.11	Esempio di segmentazione della scena . . . . .	56
4.12	Passaggio dallo spazio dei frame allo spazio dei feature vector	62
4.13	Descrittori per la segmentazione della scena . . . . .	64
4.14	Segmentazione della scena . . . . .	67
5.1	Camera digitale usata per le acquisizioni . . . . .	71
5.2	Sistema di acquisizione basato su Raspberry Pi . . . . .	72
5.3	Esempi di sequenze con eventi di sfocature create sinteticamente	76
5.4	Esempio di sequenza con un evento di spostamento della camera creato sinteticamente . . . . .	77
5.5	ROC curve per gli indicatori di spostamento della camera . .	78
5.6	ROC curve per gli indicatori di sfocatura . . . . .	80
5.7	Prestazioni del monitoraggio sequenziale per l'identificazione di sfocature . . . . .	81
5.8	Sequenze con eventi di tampering reali . . . . .	82





# Capitolo 1

## Introduzione

Nell'ultimo decennio le reti senza fili di sensori multimediali, o *wireless multimedia sensor network* (WMSN) [1], di cui vediamo un esempio nella Figura 1.1, hanno ricevuto parecchie attenzioni da parte della ricerca scientifica. Ciò è avvenuto sia in ambito industriale, per i molteplici scenari in cui questo tipo di reti può essere applicato, che in ambito accademico, dati i numerosi problemi rimasti ancora aperti.

Un esempio di scenario applicativo per le WMSN è la rete di sensori per il monitoraggio video (*multimedia surveillance sensor networks*) (MSSN), dove sono presenti dei nodi in grado di acquisire ed elaborare segnali video e di comunicare con gli altri apparati della rete (gateway, applicazioni client, altri sensori, ...). Questi particolari nodi prendono il nome di *smart camera*, o camere intelligenti [2], e sono dispositivi che integrano al loro interno *camere digitali, capacità di calcolo e interfacce di rete*. In questo modo è possibile eseguire algoritmi di elaborazione di immagini o di visione artificiale direttamente sul dispositivo, e ottenere un'*intelligenza distribuita* su tutta la rete. Il fatto di poter eseguire degli algoritmi direttamente sul dispositivo che acquisisce i dati, inoltre, permette di ridurre il consumo energetico limitando il traffico dei dati sulla rete.

Gli scenari più interessanti di impiego delle MSSN sono quelli in cui non si può avere accesso alla rete elettrica per alimentare i sensori: questo può accadere, ad esempio, nel caso in cui si voglia monitorare, con una copertura capillare, ambienti esterni, o più in generale vaste aree extra urbane in cui non è possibile allacciarsi alla rete elettrica.

La necessità di operare in ambienti privi di energia elettrica richiede nodi alimentati a *batteria* in grado di garantire l'operabilità delle camere per degli anni. Lo sviluppo di camere intelligenti a *basso consumo energetico* è già in atto, e sono già presenti dei prototipi o prodotti commerciali. *ST-Microelectronics* ha sviluppato una smart camera in grado di acquisire e trasmettere immagini e video, e fare semplici elaborazioni sui frame, come ad esempio identificazione di oggetti o classificatori. La corrente assorbita

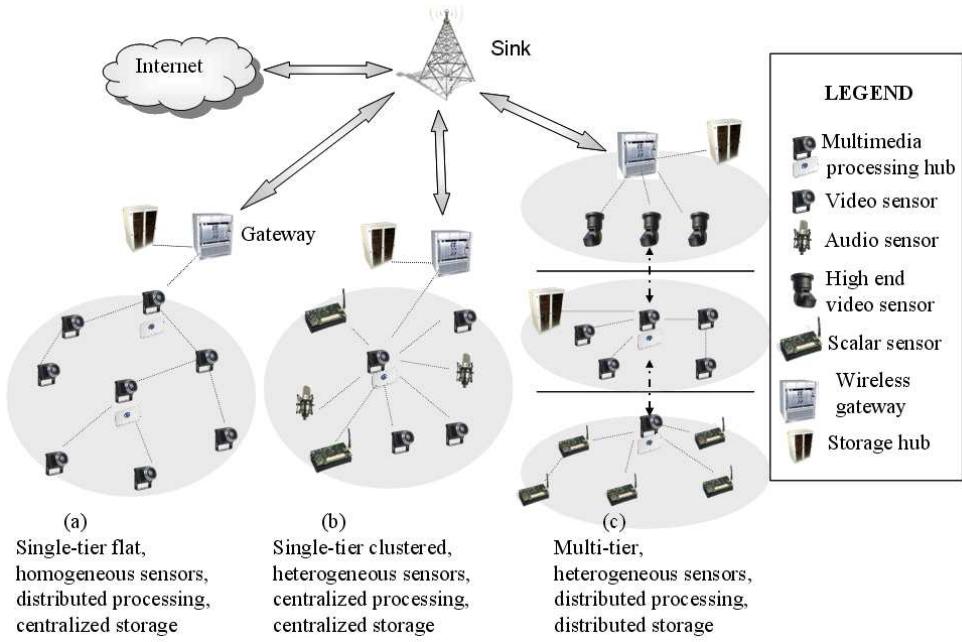


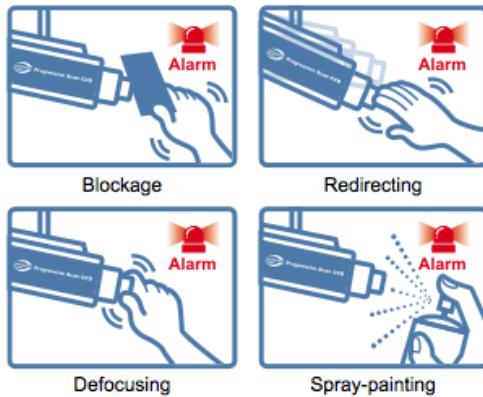
Figura 1.1: Esempio di architettura di una wireless multimedia sensor network (WMSN)

da questo dispositivo è di circa  $30 - 40\mu\text{A}$ , a circa  $1.2 - 1.5\text{V}$ . Questo vuol dire che, utilizzando due batterie di tipo AA per alimentare il dispositivo, la loro carica potrebbe mantenersi per degli anni. Questa ottimizzazione del consumo di energia è dovuta innanzitutto alla possibilità di integrare degli algoritmi direttamente in *hardware*. Un altro fattore che determina il consumo della batteria è il *contesto applicativo* in cui la camera opera. Ad esempio, il *framerate*, ovvero la frequenza con cui la camera acquisisce le immagini, ha degli impatti molto alti sul consumo di potenza del dispositivo. Per alcune applicazioni di monitoraggio video potrebbe non essere necessario avere un'acquisizione *continua*, ovvero tra i 30 e i 2 *frame per secondo* (fps), da parte della camera, ma basterebbe un'acquisizione ed elaborazione a framerate molto più bassi, ad esempio un frame ogni minuto.

In questo lavoro di tesi affrontiamo un particolare problema legato ai sistemi di monitoraggio video, e consideriamo il caso particolare in cui vengano impiegate camere intelligenti a basso consumo energetico.

Uno dei maggiori problemi quando si ha a che fare con sistemi di monitoraggio video consiste nell'identificazione di eventi in grado di compromettere la corretta ripresa della scena da parte del sensore. Eventi di questo tipo sono, ad esempio, lo spostamento della camera, oppure il cambio di messa a fuoco della scena.

Questo tipo di eventi viene classificato generalmente sotto il nome di *tampering*, dall'inglese *manomissione*. Il termine deriva dal fatto che, di solito, questi eventi sono legati ad azioni intenzionali atte a impedire che la ca-



*Figura 1.2: Esempi di eventi di tampering intenzionali. Per evitare che la camera riprenda correttamente la scena è possibile coprire il sensore con un oggetto opaco, oppure spostarla in modo che riprenda una scena diversa. Altre manomissioni possono essere fatte cambiando la messa a fuoco della camera o spruzzando della vernice spray sull'obiettivo.*

camera riprenda correttamente la scena. Può succedere, ad esempio, che un ladro copri l'obiettivo della camera con qualche oggetto, in modo da poter agire indisturbato, oppure che la sposti in modo che riprenda qualcos'altro. Esempi di tampering intenzionale sono illustrati nella Figura 1.2. In questa tesi definiamo con il termine tampering un qualsiasi evento, intenzionale o meno, che possa compromettere la corretta acquisizione della scena inquadrata dalla camera. Ad esempio una sfocatura può essere causata da dell'acqua piovana che si deposita a ridosso della lente, oppure può succedere che una folata di forte vento sposti la camera, cambiando quindi l'inquadratura della scena, oppure che della neve si depositi sulla camera e non permetta di vedere parte della scena. Esempi di eventi di tampering dovuti a cause naturali sono illustrati nella Figura 1.3.

Il problema di individuare, in maniera automatica, eventi di tampering, sia intenzionali che dovuti a cause naturali, prende il nome di *tampering detection*. La letteratura scientifica ha prodotto molte soluzioni a riguardo [3, 4, 5, 6, 7], ma la maggior parte sono legate ad applicazioni in cui le camere operano a framerate *continuo*, solitamente tra i 30 frame per secondo (fps) e i 2 fps. Utilizzando frequenze di acquisizione così alte abbiamo frame consecutivi molto simili fra loro anche in scene molto dinamiche, in cui non avvengono cambiamenti sostanziali all'interno della scena ripresa, a meno di eventi di tampering. Ciò permette di utilizzare tecniche di *background subtraction* o di confronto tra frame consecutivi, e quindi rilevare l'evento di tampering come un cambiamento sostanziale della scena. Queste tecniche, oltre a richiedere capacità di calcolo e di memoria che una camera a basso consumo di potenza difficilmente può garantire, risultano essere non efficaci



(a)

(b)

*Figura 1.3: Esempi di eventi di tampering dovuti a cause naturali: in (a) vediamo come le gocce di pioggia possano portare a delle sfocature nell'immagine, con la conseguente perdita di dettagli, mentre in (b) possiamo vedere un cumulo di neve sulla camera che impedisce di riprendere la totalità della scena.*

nel caso in cui la frequenza con cui i frame vengono acquisiti è bassa. Infatti, in questo caso, le differenze tra due immagini acquisite consecutivamente sono molto elevate, in quanto entrano in gioco nuovi elementi come i *cambiamenti di luminosità* e la *dinamicità* della scena.

Lo scopo della tesi è lo sviluppo di un algoritmo di tampering detection per camere intelligenti (*smart camera*) e a basso consumo, in cui si opera a framerate bassi, minori di 1fps. Lo sviluppo dell'algoritmo è stato fatto nell'ottica di mantenere al minimo il numero di falsi allarmi lanciati dal sistema. Questi ultimi, infatti, comportano un costo dal punto di vista del consumo energetico, in quanto vengono trasmessi sulla rete dei segnali di allarme non necessari.

La soluzione che proponiamo è quella di monitorare degli indicatori a basso costo computazionale, estratti dalle singole immagini, in modo da identificare l'istante in cui avviene l'evento di tampering. Le tecniche di monitoraggio utilizzate sono due:

- **one-shot**, in cui verifichiamo che il valore dell'indicatore, in ogni istante, stia all'interno di un intervallo definito da due *soglie*, calcolate a partire da un insieme di osservazioni di *training*;
- **sequenziale**, in cui verifichiamo la *stazionarietà* dell'indicatore nel tempo, ovvero l'ipotesi che le osservazioni siano *indipendenti e identicamente distribuite* (i.i.d.).

Per garantire alte prestazioni e limitare il numero di falsi allarmi, abbiamo deciso di applicare questo monitoraggio su alcune *regioni adattative* estratte dalla scena. A questo scopo abbiamo sviluppato un *algoritmo di segmentazione* che permetta di estrarre queste regioni. Questo algoritmo viene

eseguito durante la configurazione del sistema, separatamente rispetto alla fase di identificazione degli eventi di tampering. La segmentazione, quindi, non comporta ulteriore costo computazionale all'algoritmo, in cui viene considerata semplicemente come una variabile d'ingresso. Inoltre, la segmentazione può essere eseguita *offline* su un dispositivo esterno come una centrale operativa o un pc collegato alla smart camera durante la fase di configurazione della rete.

Per validare le nostre scelte abbiamo implementato la nostra soluzione in MATLAB e fatto degli esperimenti su alcuni *dataset* di sequenze video con la presenza di eventi di tampering, sia sintetici che reali. Gli esperimenti condotti hanno confermato come l'utilizzo della segmentazione della scena porti a dei miglioramenti nelle prestazioni dell'algoritmo, diminuendo il numero di falsi allarmi.

La tesi è stata svolta durante un lavoro di stage presso la divisione *Advanced System Technology* di *STMicroelectronics*, collaborando in particolare con un gruppo dove la ricerca è volta allo sviluppo di algoritmi intelligenti di elaborazione immagini da integrare nei propri dispositivi embedded.

La tesi è strutturata nel seguente modo.

Nel Capitolo 2 illustriamo le principali tecniche di identificazione di tampering presenti nella letteratura scientifica, introducendo anche alcuni principi di visione artificiale e di elaborazione di immagini necessari alla comprensione del resto della trattazione.

Nel Capitolo 3 diamo una definizione formale degli eventi di tampering e del problema che si pone l'algoritmo di tampering detection.

Nel Capitolo 4 illustriamo la soluzione che abbiamo proposto in questa tesi per il problema dell'identificazione degli eventi di tampering, entrando nel merito sui dettagli realizzativi.

Nel Capitolo 5 mostriamo le prove realizzate per validare la soluzione proposta, descrivendo anche le procedure di acquisizione, la preparazione dei dataset e i risultati ottenuti.

Nel Capitolo 6, infine, presentiamo le considerazioni conclusive e le prospettive future di ricerca.



## Capitolo 2

# Stato dell'arte

In questo capitolo presentiamo i concetti fondamentali della teoria alla base della *visione artificiale* e dell'elaborazione di segnali e lo studio fatto finora sul problema del *tampering detection*.

Nei Paragrafi 2.1 e 2.2 diamo una visione generale del modello della camera e di come vengono rappresentate le immagini digitali, in modo da comprendere meglio gli argomenti trattati nei capitoli successivi.

Nel Paragrafo 2.3 illustriamo le tecniche maggiormente utilizzate per identificare cambiamenti nella stazionarietà di un segnale o una sequenza di dati. Nel Paragrafo 2.4 descriviamo le soluzioni al problema del tampering detection presenti nella letteratura scientifica, definendo inoltre i concetti e la terminologia che verrà utilizzata nel resto della trattazione.

### 2.1 Modello della camera

Affinché un sistema di visione artificiale possa risolvere il problema per cui è stato progettato, è necessario che esso sia in grado di acquisire una porzione della realtà che lo circonda. Questo compito viene svolto da un particolare sensore chiamato *camera*, il cui scopo principale è quello di creare una *proiezione* dell'ambiente *tridimensionale* in un sistema *bidimensionale*. Il principio alla base della camera è un concetto inventato da *Filippo Brunelleschi* nel XV secolo, chiamato *prospettiva a punto unico di fuga (pinhole perspective)* [8]. Il modello matematico utilizzato considera uno spazio tridimensionale, detto *ambiente*, e un piano bidimensionale chiamato *immagine*. I punti su tale piano sono la *proiezione* dell'ambiente tridimensionale. La proiezione è dovuta a un punto, chiamato *centro ottico*, in cui viene convergente la luce emanata dall'ambiente tridimensionale. In questa astrazione, ciascun punto dello spazio tridimensionale viene associato univocamente a un punto nel piano immagine attraverso il raggio di luce che passa dal centro ottico. All'epoca di Brunelleschi, il modello del centro ottico veniva realizzato da una *camera oscura*, come si può osservare nell'illustrazione in Figura

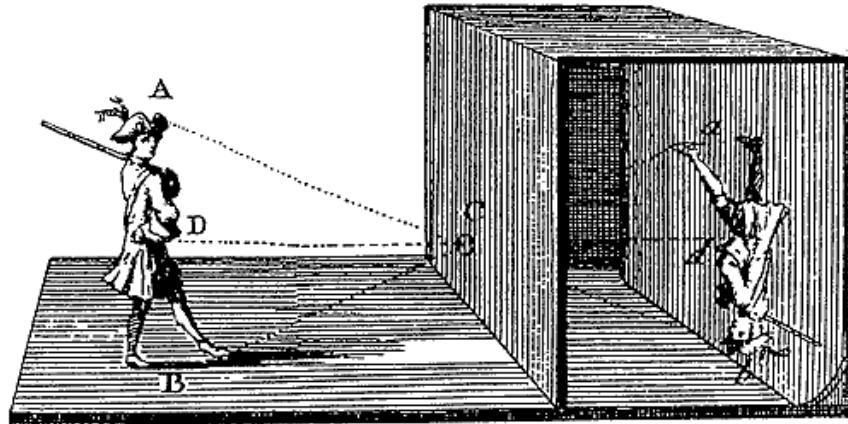


Figura 2.1: Athanasius Kircher, *Principio della prospettiva nella camera obscura*, 1671

2.1, mentre nei moderni sistemi di acquisizione viene realizzato tramite *lenti ottiche*.

### 2.1.1 La matrice prospettica della camera

Nella Figura 2.2 sono illustrati i concetti che sono utilizzati per descrivere il sistema ottico della camera. Indichiamo con la lettera maiuscola  $\mathbf{M} = [X, Y, Z]^T$  un qualsiasi punto nello spazio tridimensionale e con la lettera minuscola  $\mathbf{m} = [u, v]^T$  la sua proiezione sul piano immagine dovuta al centro ottico  $\mathbf{C}$ . La linea che congiunge il centro ottico  $\mathbf{C}$  perpendicolarmente al piano immagine è detta *asse principale*, indicata con  $Z$ , e il suo punto di intersezione con il piano stesso viene definita *punto principale*  $\mathbf{c}$ . La distanza tra il punto principale e il centro ottico viene definita *distanza focale*, e viene indicata con  $f$ .

La rappresentazione dei punti viene fatto attraverso le loro *coordinate omogenee*. In questo modo è possibile rappresentare le trasformazioni tra sistemi di coordinate di ordine differente tramite una singola trasformazione matriciale. Chiamiamo coordinate omogenee di un punto  $\mathbf{m} = [u, v]$  del piano una qualsiasi terna ordinata  $[U, V, W]$  di numeri reali tali che

$$W \neq 0, \frac{U}{W} = u, \frac{V}{W} = v.$$

Analogamente, le coordinate omogenee di un punto  $\mathbf{M} = [x, y, z]$  nello spazio tridimensionale saranno costituite da una quaterna di numeri  $[X, Y, Z, W]$  tali che

$$W \neq 0, \frac{X}{W} = x, \frac{Y}{W} = y, \frac{Z}{W} = z.$$

La coordinata  $W$  viene definita *valore di scala*; nel caso  $W = 1$  le rimanenti coordinate omogenee rappresentano le *coordinate cartesiane* del punto.

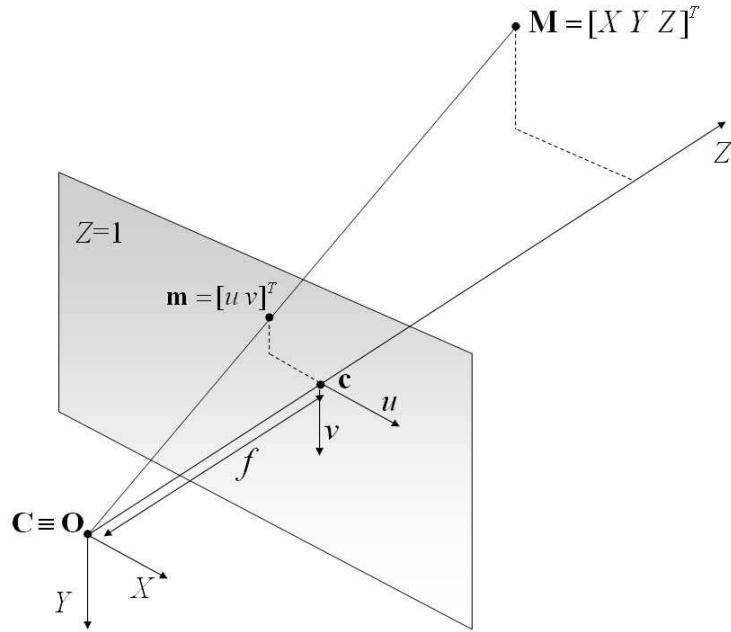


Figura 2.2: Schematizzazione del sistema ottico della camera

Consideriamo un punto  $\mathbf{M}$  nello spazio tridimensionale, rappresentato tramite le coordinate omogenee  $[X, Y, Z, 1]^T$ , e il suo punto immagine  $\mathbf{m}$  rappresentato dalle coordinate omogenee  $[u, v, 1]^T$ . La proiezione della camera può essere espressa come

$$\mathbf{m} = P\mathbf{M}, \quad (2.1)$$

dove  $P$  è una matrice di dimensioni  $3 \times 4$  chiamata *matrice prospettica* [9]. Tale matrice contiene al suo interno informazioni sui parametri della camera a cui è associata, e descrive sia la proiezione sul piano immagine che le trasformazioni di camera rispetto al sistema di riferimento tridimensionale. Formalmente la matrice prospettica viene definita attraverso la concatenazione di due matrici: una che rappresenta i *parametri intrinseci* e un'altra che rappresenta i *parametri estrinseci* [10].

- I *parametri intrinseci* rappresentano le caratteristiche interne della camera come la distanza focale, il centro focale e le caratteristiche di *distorsione* della lente.
- I *parametri estrinseci* rappresentano la posizione della camera rispetto al sistema di riferimento dello spazio tridimensionale.

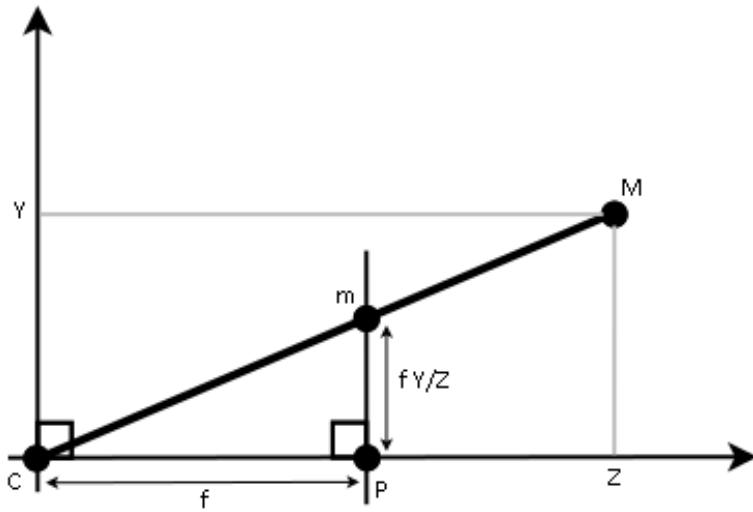


Figura 2.3: Similitudini tra triangoli usate nel calcolo dei parametri intrinseci

### 2.1.2 Parametri intrinseci

La relazione fra le coordinate tridimensionali di un punto  $\mathbf{M} = [X, Y, Z]$  e le coordinate della sua proiezione  $\mathbf{m} = [u, v]$  è:

$$u = f \cdot \frac{X}{Z},$$

$$v = f \cdot \frac{Y}{Z}.$$

Tale relazione deriva dalle proprietà dei triangoli simili, come mostra la Figura 2.3. La *mappatura* viene definita, dunque, dalla seguente relazione:

$$[X, Y, Z]^T \mapsto \left[ f \cdot \frac{X}{Z}, f \cdot \frac{Y}{Z} \right]^T. \quad (2.2)$$

Se il punto nello spazio e la sua proiezione sono rappresentati attraverso le loro coordinate omogenee, la (2.2) può essere riscritta come

$$\begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix} \mapsto \begin{bmatrix} f \cdot X \\ f \cdot Y \\ Z \end{bmatrix} = K \begin{bmatrix} I & | & 0 \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}, \quad (2.3)$$

dove la matrice

$$K = \begin{bmatrix} f & & \\ & f & \\ & & 1 \end{bmatrix} \quad (2.4)$$

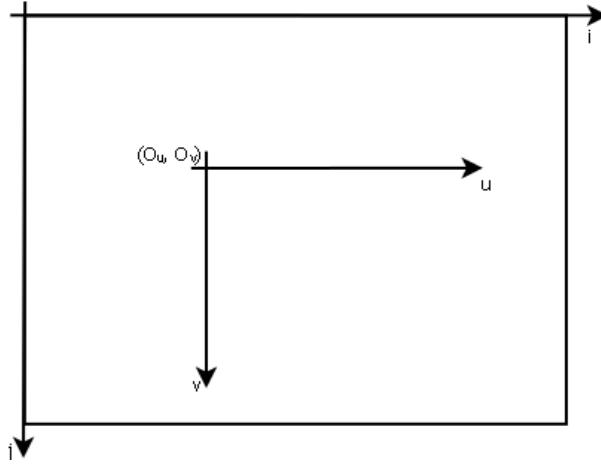


Figura 2.4: Coordinate di un frame

viene detta *matrice di calibrazione* della camera.

Nella (2.2) abbiamo assunto che l'origine delle coordinate del piano immagine si trovi nel punto principale, come è illustrato nella Figura 2.2. Se consideriamo il punto principale di coordinate  $[p_u, p_v]$ , la (2.2) diventa

$$[X, Y, Z]^T \mapsto \left[ f \cdot \frac{X}{Z} + p_u, f \cdot \frac{Y}{Z} + p_v \right]^T, \quad (2.5)$$

mentre la matrice di calibrazione (2.4) diventa

$$K = \begin{bmatrix} f & p_u \\ f & p_v \\ 1 & \end{bmatrix}. \quad (2.6)$$

Nel caso in cui il sensore della camera sia *digitale*, l'immagine deve essere quantizzata come una matrice di  $W$  colonne e  $H$  righe, in cui ciascun elemento prende il nome di *pixel* (dalla contrazione di *picture element*). Ogni pixel possiede, quindi, delle coordinate che definiscono la sua posizione sulla matrice del frame. Se definiamo con  $(i, j)$  le coordinate del generico pixel sulla matrice del frame, dove l'origine è posta nell'angolo in alto a sinistra, e con  $(O_u, O_v)$  le coordinate del punto principale secondo il sistema di riferimento del frame (si veda a riguardo la Figura 2.4), possiamo mettere in relazione le coordinate dell'immagine con le coordinate frame nel seguente modo:

$$u = (i - O_u) \cdot S_u$$

e

$$v = (j - O_v) \cdot S_v,$$

dove  $S_u$  e  $S_v$  sono le dimensioni orizzontali e verticali del singolo pixel. È necessario introdurre, nella matrice di calibrazione, l'informazione del

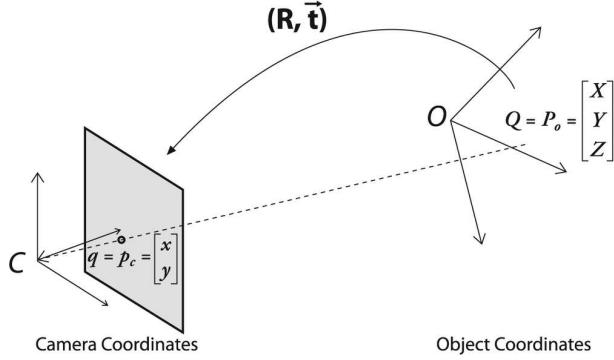


Figura 2.5: Trasformazione dal sistema di coordinate dell'ambiente a quello della camera

numero di pixel per unità di distanza in coordinate immagine  $m_u$  e  $m_v$ , rispettivamente nelle direzioni  $u$  e  $v$ , modificando la matrice di calibrazione definita in (2.6) come

$$K = \begin{bmatrix} \alpha_u & u_0 \\ \alpha_v & v_0 \\ 1 & \end{bmatrix}, \quad (2.7)$$

dove  $\alpha_u = fm_u$  e  $\alpha_v = fm_v$ , mentre il punto principale  $[p_u, p_v]$  viene riscritto come  $[u_0, v_0] = [m_u p_u, m_v p_v]$ .

Nel caso in cui la matrice di calibrazione sia nota, la camera viene detta *completamente calibrata*.

La matrice di calibrazione  $K$  rappresenta, quindi, il cambio di sistema di riferimento nel piano immagine, ridefinendo il centro della camera  $(u_0, v_0)$  in modo che coincida con il punto principale.

### 2.1.3 Parametri estrinseci

La matrice  $K$  descritta da (2.7) è valida per camere poste all'origine del sistema di riferimento. Se consideriamo delle camere poste in un punto arbitrario dell'ambiente, quindi, è necessario che le coordinate dei punti, definite nel sistema di riferimento tridimensionale, siano ridefinite secondo il sistema di coordinate della camera. Questa trasformazione viene definita attraverso una *rototraslazione*, nello spazio, del sistema di riferimento dell'ambiente, in modo che coincida con quello della camera. Se  $\tilde{\mathbf{M}}$  rappresenta le coordinate cartesiane di un punto nel sistema di riferimento dell'ambiente e  $\tilde{\mathbf{M}}_{cam}$  rappresenta lo stesso punto nel sistema di riferimento della camera, si può scrivere

$$\tilde{\mathbf{M}}_{cam} = R(\tilde{\mathbf{M}} - C), \quad (2.8)$$

dove  $C$  rappresenta le coordinate del centro della camera nel sistema di riferimento dell'ambiente,  $R$  è una *matrice di rotazione*  $3 \times 3$  che rappresenta l'orientamento della camera rispetto al sistema di riferimento dell'ambiente e



Figura 2.6: Esempio di estrazione dei canali RGB

$K$  è la matrice di calibrazione della camera. L’equazione (2.8) può essere riscritta in forma matriciale: se definiamo  $\mathbf{M}$  e  $\mathbf{M}_{cam}$  come le rappresentazioni in coordinate omogenee di  $\tilde{\mathbf{M}}$  e  $\tilde{\mathbf{M}}_{cam}$ , abbiamo

$$\mathbf{M}_{cam} = \begin{bmatrix} R & -RC \\ 0 & 1 \end{bmatrix} \mathbf{M},$$

da cui, riprendendo (2.3),

$$\begin{aligned} \mathbf{m} &= K [ I \mid 0 ] \mathbf{M}_{cam} \\ &= K [ I \mid 0 ] \begin{bmatrix} R & -RC \\ 0 & 1 \end{bmatrix} \mathbf{M} \\ &= K [ R \mid -RC ] \mathbf{M}. \end{aligned}$$

Possiamo, quindi, scrivere l’equazione della matrice di proiezione della camera come

$$P = K [ R \mid t ],$$

dove  $t = -RC$  prende il nome di *vettore di traslazione*.

## 2.2 Rappresentazione digitale delle immagini

Nel Paragrafo 2.1.2 abbiamo introdotto il concetto di *immagine digitale* come rappresentazione numerica dell’immagine bidimensionale. Esistono vari modi di rappresentare un’immagine in formato digitale. Le rappresentazioni che a noi interessa considerare sono [10]:

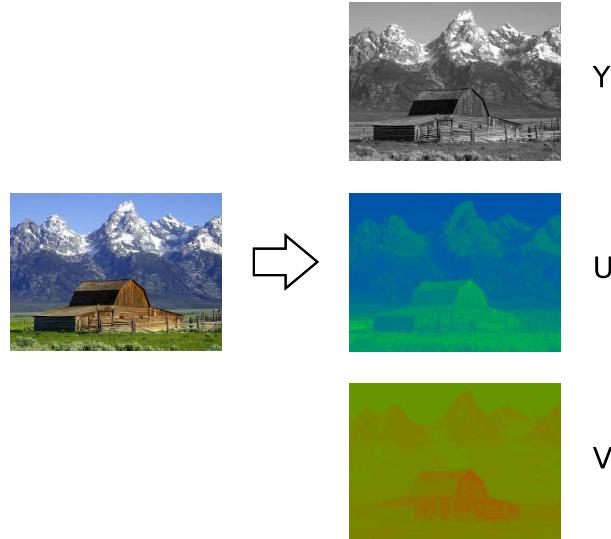


Figura 2.7: Esempio di estrazione dei canali YUV

- *scala di grigi*, in cui l'immagine è rappresentata come una matrice  $\mathbf{I}$  di dimensioni  $H \times W$ , dove l'elemento  $\mathbf{I}(i, j)$  rappresenta il valore di *intensità luminosa* (*luma*) del pixel di coordinate  $(i, j)$ ;
- *RGB*, dove l'immagine è rappresentata come una matrice *tridimensionale*  $\mathbf{I}_{RGB}$  di dimensioni  $H \times W \times 3$ , in cui vengono memorizzati i livelli di intensità luminosa dei tre colori fondamentali *rosso* (R), *verde* (G) e *blu* (B) per ciascun pixel (Figura 2.6);
- *YUV*, in cui lo spazio colore viene definito tramite un componente di luma (Y) e due componenti di *crominanza* (UV), che rappresentano rispettivamente i valori di differenza dal colore blu ( $U = B - Y$ ) e dal colore rosso ( $V = R - Y$ ) (Figura 2.7).

Le immagini digitali possono essere memorizzate in diversi formati. Spesso vengono utilizzati algoritmi di *compressione*, che possono essere

- a perdita di informazione (*lossy*), come nel caso delle immagini *JPEG*;
- senza perdita di informazione (*lossless*), come nel caso dei file d'immagine *PNG* o *GIF*.

### 2.3 Identificazione del cambiamento nella stazionarietà di un processo

Prima di illustrare come è stato affrontato il problema del tampering detection nella letteratura scientifica, affrontiamo il problema, più generale, di

come identificare un cambiamento all'interno di un processo. Una caratteristica, richiesta in molte applicazioni di analisi e elaborazione intelligente di dati, riguarda l'assunzione che il processo generante questi dati non cambi nel tempo [11]. In questo caso si parla di processi *stazionari*, ovvero processi in cui i dati possano essere considerati generati da un'unica distribuzione probabilistica.

In molte situazioni, soprattutto se vengono utilizzati dei sensori per misurare delle grandezze fisiche, si può incorrere in situazioni in cui questa ipotesi di stazionarietà venga meno. Ad esempio, può succedere che il sensore si guasti, oppure che fenomeni esterni non permettano un'acquisizione ottimale. In questi casi è opportuno avere a disposizione degli strumenti in grado di identificare quando la condizione di stazionarietà di un processo viene meno, in modo da poter lanciare un allarme a riguardo. Le tecniche principalmente utilizzate per questo scopo prendono il nome di *Change-Point Methods* (CPM) e *Change-Detection Tests* (CDT), e verranno illustrate nel resto del paragrafo.

### 2.3.1 Metodi di Change-Point

I metodi di Change-Point (CPM) vengono utilizzati per ispezionare una certa sequenza di dati e verificare la sua stazionarietà. Ciò viene fatto verificando che, all'interno della sequenza, esista un istante temporale in cui la distribuzione dei dati cambia (*change point*).

In maniera formale possiamo dire che, data una sequenza di dati

$$\mathcal{X} = \{x(t), t = 1, \dots, n\},$$

essa contiene un change point all'istante  $\tau < n$  se è possibile suddividerla in due sotto-sequenze

$$\begin{aligned}\mathcal{A}_\tau &= \{x(t), t = 1, \dots, \tau\} \\ \mathcal{B}_\tau &= \{x(t), t = \tau + 1, \dots, n\}\end{aligned},$$

le quali sono due realizzazioni *indipendenti e identicamente distribuite* (i.i.d.) di due differenti variabili aleatorie con distribuzione  $\mathcal{F}_0$  e  $\mathcal{F}_1$ . È possibile, quindi, convertire il problema del change point in uno equivalente dove si valuta se  $\mathcal{A}_\tau$  e  $\mathcal{B}_\tau$  sono generati da due distribuzioni diverse.

Il problema, a questo punto, può essere riformulato come un *test d'ipotesi a due campioni* [12], dove l'*ipotesi nulla* ( $H_0$ ) e l'*ipotesi alternativa* ( $H_1$ ) sono le seguenti:

$$\begin{aligned}H_0 : \quad x(t) &\sim \mathcal{F}_0 \quad \forall t \\ H_1 : \quad x(t) &\sim \begin{cases} \mathcal{F}_0 & \text{se } t < \tau \\ \mathcal{F}_1 & \text{se } t \geq \tau \end{cases}.\end{aligned}$$

Per la valutazione delle ipotesi fatte sopra, occorrono delle opportune *statistiche di test a due campioni*

$$\mathcal{T}_\tau = \mathcal{T}(\mathcal{A}_\tau, \mathcal{B}_\tau),$$

in modo da poter comparare  $\mathcal{A}_\tau$  e  $\mathcal{B}_\tau$ . In questo modo è possibile rifiutare l'ipotesi nulla quando il valore della statistica  $\mathcal{T}_\tau$  supera una certa soglia  $h_{n,\alpha}$ , calcolata in funzione di un certo *intervallo di confidenza*  $\alpha$  e del numero di campioni  $n$ .

Se, ad esempio, consideriamo l'ipotesi che  $\mathcal{A}_\tau$  e  $\mathcal{B}_\tau$  siano generate da due distribuzioni *gaussiane*, è possibile valutare la dissimilarità tra le due distribuzioni controllando i due *valori attesi*. Possiamo usare, come statistica di test, la *differenza standardizzata tra le medie di due campioni*, definita come

$$D_\tau = \sqrt{\frac{\tau(n-\tau)}{n}} \frac{\bar{\mathcal{A}}_\tau - \bar{\mathcal{B}}_\tau}{S_\tau},$$

dove  $\bar{\mathcal{A}}_\tau$  e  $\bar{\mathcal{B}}_\tau$  denotano le *medie campionarie* valutate rispettivamente su  $\mathcal{A}_\tau$  e  $\mathcal{B}_\tau$ , mentre  $S_\tau$  è la *varianza campionaria* valutata su tutto l'*insieme dei dati*.

Quando la statistica di test utilizzata, corrispondente a una specifica partizione dell'insieme dei dati, non fornisce l'evidenza necessaria a rifiutare  $H_0$ , l'unica cosa che è possibile stabilire è che nell'istante  $\tau$  scelto non si è avuto un cambiamento nella stazionarietà dell'insieme. *Ciò non implica che l'istante di cambiamento non sia un altro ancora da valutare.* In maniera rigorosa è necessario valutare, quindi, tutte le possibili partizioni dell'insieme dei dati considerati. Le ipotesi nulla e alternativa vengono, perciò, modificate nel seguente modo [13]:

$$\begin{aligned} H_0 : \quad & \forall t, \quad x(t) \sim \mathcal{F}_0 \\ H_1 : \quad & \exists \tau \quad x(t) \sim \begin{cases} \mathcal{F}_0 & \text{se } t < \tau \\ \mathcal{F}_1 & \text{se } t \geq \tau \end{cases}. \end{aligned}$$

Entrando più nel dettaglio, per ciascun punto  $s \in \{2, \dots, n-1\}$ , candidato a essere un change point, valutiamo la statistica di test  $\mathcal{T}_s$ . Viene scelto come change point quello che massimizza la statistica

$$M = \underset{s=2, \dots, n-1}{\operatorname{argmax}} (\mathcal{T}_s),$$

corrispondente al valore  $\mathcal{T}_M$  di  $\mathcal{T}$

$$\mathcal{T}_M = \underset{s=2, \dots, n-1}{\max} (\mathcal{T}_s).$$

Una volta trovato  $\mathcal{T}_M$  il test va finalizzato comparando questa statistica con la soglia  $h_{n,\alpha}$ , in modo da verificare se l'ipotesi nulla sia da scartare o meno. Nella Figura 2.8 possiamo vedere un esempio di CPM basato su una statistica *t di Student* [11]. La sequenza è formata da 500 dati (**a**) ed è stato individuato un cambiamento un cambiamento nella loro distribuzione all'istante  $\tau = 350$ :

$$x(t) \sim \begin{cases} \mathcal{N}(0, 1) & , \text{ se } t < 350 \\ \mathcal{N}(-1, 1) & , \text{ se } t \geq 350 \end{cases}. \quad (2.9)$$

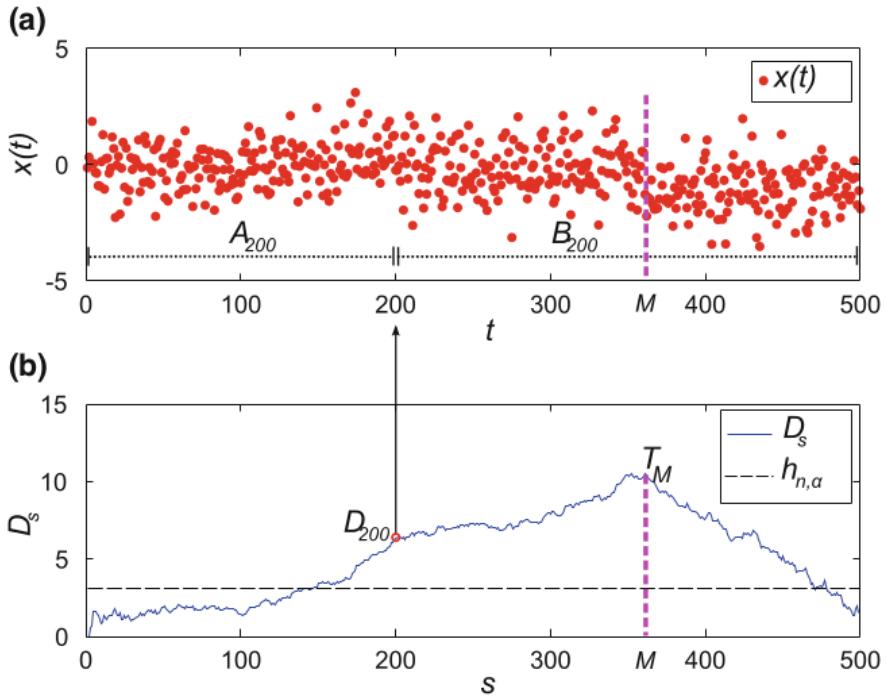


Figura 2.8: Un esempio di CPM basato sulla statistica  $t$  di Student. I dati in (a) sono distribuiti in accordo con (2.9). I valori assunti dalla corrispondente statistica di test  $D_s, s = 2, \dots, 499$  sono riportati in (b). Sono riportati anche il change point stimato  $M$ , e il corrispondente valore nella statistica di test  $T_M$ . A scopo illustrativo la figura mostra anche la partizione di  $\mathcal{X}$  in  $\mathcal{A}_s$  e  $\mathcal{B}_s$  quando  $s = 200$ , insieme al corrispondente valore della statistica  $D_{s=200}$ .

I valori delle varie statistiche in funzione di  $s$  sono visualizzati in (b).

Spesso è preferibile utilizzare dei test statisticci *non parametrici*, soprattutto quando le distribuzioni dei dati sono incognite. Le statistiche maggiormente utilizzate sono quelle basate su *calcolo del rango* [13]. Quando si ha a che fare con cambiamenti nella *località* dei dati una statistica solitamente utilizzata è quella di *Mann-Whitney*, mentre quando si vogliono verificare cambiamenti *di scala* è possibile utilizzare la statistica di *Mood*. La statistica di *Lepage* invece può risultare utile per analizzare entrambi i tipi di cambiamento. Un altro approccio consiste nel comparare le *distribuzioni empiriche* dei due insiemi di dati, usando ad esempio la statistica di *Kolmogorov-Smirnov*.

### 2.3.2 Change-Detection Test

I metodi di change point sono stati principalmente pensati per essere eseguiti *a valle* della completa acquisizione dei dati. Inoltre il suo elevato costo computazionale fa sì che questa tecnica difficilmente possa essere utilizzabile all'interno di un sistema embedded. Le tecniche che vengono descritte

in questo paragrafo, che prendono il nome di *change detection test* (CDT), hanno come scopo principale quello di fare un'elaborazione dei dati *online*, ovvero non appena questi sono disponibili. Tecniche di questo tipo vengono anche chiamate *sequenziali*. La loro relativa semplicità dal punto di vista computazionale permette di utilizzarle all'interno di sistemi embedded ma, rispetto alle tecniche basate su CPM, abbiamo una latenza (ovvero l'intervallo di tempo tra l'istante di identificazione del cambiamento e quello in cui effettivamente questo è avvenuto) e un numero di falsi positivi (viene segnalato un cambiamento nella distribuzione quando in, realtà, questo non è avvenuto) maggiori.

### CDT basati su CUSUM

Le *carte di controllo per le somme cumulate* (CUMulative SUM control chart, abbreviate in *CUSUM*) [11, 12] permettono di identificare un cambiamento all'interno di una sequenza di dati in maniera molto accurata utilizzando alcune informazioni *a priori* sul processo generante i dati. Queste informazioni vengono generalmente acquisite durante un *fase di configurazione* del test, in modo da fissare i parametri di test necessari all'analisi.

Nel seguito presentiamo due metodi di CDT che estendono il metodo CUSUM tradizionale rilassando alcune delle sue assunzioni troppo restrittive. La prima variante permette di identificare in maniera automatica la configurazione dei parametri di test (*CUSUM adattativo*), mentre la seconda, chiamata *computational Intelligence CUSUM* (CI-CUSUM) è in grado di considerare un insieme più ricco di descrittori in modo da aumentare l'efficienza nell'identificare i cambiamenti [14].

#### CUSUM tradizionale e versione adattativa Sia

$$\mathcal{X} = \{x(t), t = 1, \dots, N\}, x(t) \in \mathbb{R}$$

una sequenza di  $N$  dati generata da un processo con densità probabilistica  $f_\theta(x)$ , che assumiamo sconosciuta e parametrizzata secondo un vettore  $\theta \in \mathbb{R}^n$ . Assumiamo, inoltre, che il processo cambi la sua stazionarietà a un istante  $T^0$  sconosciuto. Questo avvenimento può essere modellato come un passaggio dal vettore dei parametri  $\theta_0$  a  $\theta_1$ , associati rispettivamente alle densità  $f_{\theta_0}(x)$  e  $f_{\theta_1}(x)$ . La discrepanza tra le due densità viene valutata comparando il rapporto tra le log-verosimiglianze (*log-likelihood ratio*)

$$s(t) = \ln \frac{f_{\theta_1}(x(t))}{f_{\theta_0}(x(t))} \text{ per ogni } t = 1, \dots, N$$

e la *somma cumulata*

$$S(t) = \sum_{\tau=1}^t s(\tau)$$

CUSUM identifica un cambiamento in  $\mathcal{X}$  all'istante  $\hat{T}$  quando

$$g(t) = S(t) - m(t),$$

ovvero la differenza tra il valore della somma cumulata all'istante  $t$  e il suo valore minimo nel tempo

$$m(t) = \min_{\tau=1,\dots,t} S(\tau),$$

superà una certa soglia  $h$ .

Il metodo CUSUM tradizionale assume che i parametri  $\theta_0$ ,  $\theta_1$  e la soglia  $h$  siano disponibili a priori. La versione adattativa viene incontro a questa assunzione che, generalmente, è difficile da soddisfare.

La variante prima di tutto genera la sequenza cumulata  $Y = \{y(1), y(2), \dots\}$ , dove  $y(s)$  rappresenta il valore della media campionaria stimata su una finestra mobile non sovrapponibile di ampiezza  $n$  presa da  $\mathcal{X}$

$$y(s) = \frac{1}{n} \sum_{t=(s-1)n+1}^{sn} x(t)$$

Scegliendo  $n$  abbastanza grande, per il *teorema del limite centrale* [12], la distribuzione di  $Y$  può essere approssimata con una distribuzione *gaussiana*. In questo modo, quindi, si può utilizzare il metodo CUSUM tradizionale direttamente sulla sequenza  $Y$ . I primi  $K$  dati di  $\mathcal{X}$  vengono usati come *insieme di configurazione* per i parametri necessari a identificare il cambiamento. Il vettore dei parametri  $\theta_0$  è caratterizzato da media e varianza di  $Y$ , stimate attraverso i primi  $K/n$  campioni di  $Y$ . Il vettore dei parametri  $\theta_1$  viene ottenuto attraverso l'identificazione di un intorno di confidenza per  $\theta_0$ , mentre la soglia  $h$  viene calcolata come il valore massimo di  $g(t)$  nella sequenza  $Y$

$$h = \max_{1 \leq t \leq N/n} g(t).$$

L'intera procedura è illustrata nella Figura 2.9.

**CI-CUSUM** Il metodo CI-CUSUM rappresenta un'estensione del CUSUM adattativo molto potente, in quanto ciascun descrittore, estratto dal flusso di dati, può essere utilizzato per avere differenti gradi di sensitività durante l'identificazione di un cambiamento. Facciamo riferimento alla Figura 2.10. I descrittori  $\varphi$  considerati contengono i principali momenti della distribuzione dei dati, come media e varianza, ma anche momenti superiori al secondo come skewness (*skew*) e kurtosis (*kurt*), oltre che altre informazioni derivate dalla densità probabilistica (*pdf*) e dalla funzione di ripartizione dei dati (*cdf*).

A ogni istante queste grandezze vengono confrontate con quelle appartenenti all'intervallo di configurazione (*training set*, indicato in Figura 2.10 come

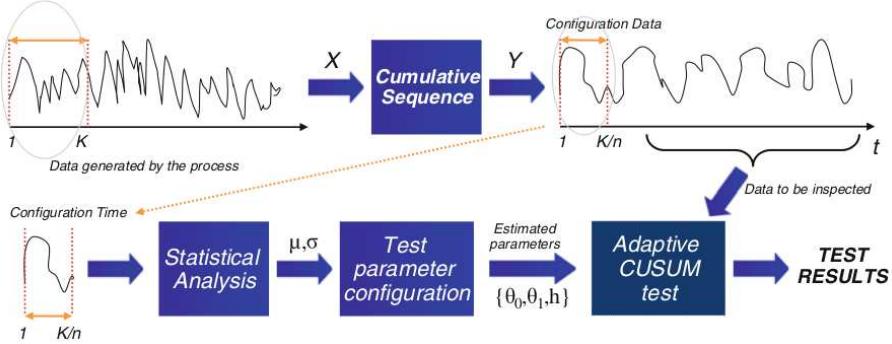


Figura 2.9: Procedura del CUSUM adattativo. Il flusso di dati  $\mathcal{X}$  passa attraverso un processo di fenestratura sequenziale. Non appena sono disponibili  $n$  campioni in una finestra di dati questa viene utilizzata per generare l'indicatore  $y(s)$ , ottenuto tramite la media dei dati della finestra. La distribuzione di  $y(s)$  è approssimativamente gaussiana, grazie al teorema del limite centrale, ammesso che  $n$  sia abbastanza grande. Il CUSUM tradizionale può essere applicato sui parametri  $\theta = [\mu, \sigma^2]$ . I parametri  $\theta_0, \theta_1$  e la soglia  $h$  sono stimati sul insieme di training.

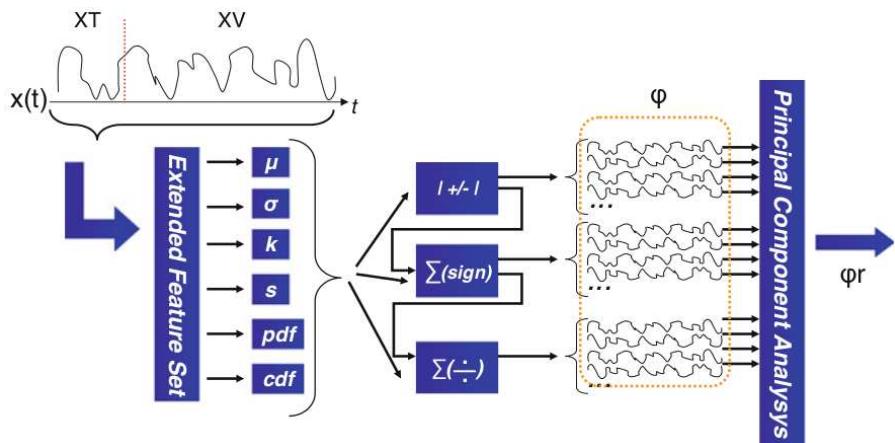


Figura 2.10: Fase di estrazione dei descrittori e la fase di riduzione di CI-CUSUM. Un ampio insieme di descrittori viene estratto dal segnale in ingresso, in modo da comporre l'insieme descrittore  $\varphi$ . I descrittori estratti dall'insieme operazionale  $XV$  sono comparati con quelli valutati nell'insieme di training  $XT$ . Una tecnica di analisi delle componenti principali permette la riduzione di  $\varphi$  al descrittore  $\varphi_r$ .

XT), in modo da valutare la discrepanza tra questi valori. I descrittori utilizzati sono

$$\begin{aligned}\varphi_1(t) &= |\mu_0 - \mu_V|, \varphi_2(t) = |\sigma_0 - \sigma_V|, \\ \varphi_3(t) &= |kurt_0 - kurt_V|, \varphi_4(t) = |skew_0 - skew_V|, \\ \varphi_5(t) &= \int_x |pdf_0(x) - pdf_V(x)| dx, \\ \varphi_6(t) &= \int_x |cdf_0(x) - cdf_V(x)| dx, \\ \varphi_{7 \leq j \leq 12}(t) &= \sum_{v=1}^{t-1} sgn(\varphi_{j-6}(v+1) - \varphi_{j-6}(v)), \\ \varphi_{13 \leq j \leq 24}(t) &= \sum_{v=1}^{t-1} \frac{\varphi_{j-12}(v+1)}{\varphi_{j-12}(v)}\end{aligned}$$

In particolare, i descrittori  $\varphi_5(t)$  e  $\varphi_6(t)$  valutano la discrepanza tra la densità e funzione di ripartizione correnti e quelle rispettive dell'intervallo di configurazione. I descrittori da  $\varphi_7(t)$  a  $\varphi_{12}(t)$  vanno ad analizzare i cambiamenti di segno in elementi consecutivi e quelli da  $\varphi_{13}(t)$  a  $\varphi_{24}(t)$  la somma cumulata del rapporto tra elementi consecutivi. Per ridurre la complessità dello spazio dei descrittori viene applicata un'*analisi delle componenti principali* su  $\varphi$ , in modo da avere la trasformata  $\varphi_r$ . A questo punto, dato che la distribuzione di  $\varphi_r$  non è nota a priori, viene applicato un CUSUM adattativo su di essa.

### CDT basati su Intersezione di Intervalli di Confidenza

La famiglia di tecniche che andiamo ad analizzare adesso è in grado di identificare cambi di stazionarietà, in un flusso di dati, monitorando l'evoluzione nel tempo di un certo numero di descrittori estratti dai dati stessi. L'ipotesi principale che viene fatta è che le osservazioni della sequenza monitorata siano *indipendenti e identicamente distribuiti* (*i.i.d.*) e generati da una distribuzione *gaussiana*.

**ICI-CDT** In *ICI-CDT* (Intersection of Confidence Intervals Change Detection Test) [15], i descrittori sono estratti attraverso una *fenestratura* dei dati disponibili in sotto-sequenze composte da  $n$  istanze. Per ciascuna sotto-sequenza calcoliamo media e varianza campionarie che, per il *teorema del limite centrale* [12], possono essere considerate distribuite in maniera

gaussiana. Entrando nel dettaglio, se consideriamo  $s$  come l' $s$ -esima sottosequenza, i descrittori estratti sono:

$$M(s) = \frac{\sum_{t=(s-1)n+1}^{ns} x(t)}{n}, \text{ e } V(s) = \left( \frac{\sum_{t=(s-1)n+1}^{ns} (x(t) - M(s))^2}{n-1} \right)^{h_0},$$

dove il parametro  $h_0$  è un esponente utilizzato per generare un'approssimazione gaussiana della varianza campionaria.

ICI-CDT utilizza una prima sequenza dei dati in cui si assume l'assenza di cambiamenti nella distribuzione. Tale sequenza prende il nome di *insieme di training* e viene indicata con  $O_{T_0}$ . Da questa sequenza viene stimato il parametro  $h_0$  e si configura il CDT. La configurazione avviene attraverso le due sequenze di descrittori  $\{M(s), s = 1, \dots, S_0\}$  e  $\{V(s), s = 1, \dots, S_0\}$ , con  $S_0 = T_0/n$ .

Calcoliamo quindi le medie  $\hat{\mu}_{S_0}^M$ ,  $\hat{\mu}_{S_0}^V$  e le deviazioni standard  $\hat{\sigma}_{S_0}^M$ ,  $\hat{\sigma}_{S_0}^V$  dei descrittori nell'insieme di training, ovvero:

$$\hat{\mu}_{S_0}^M = \frac{\sum_{s=1}^{S_0} M(s)}{S_0}, \text{ e } \hat{\sigma}_{S_0}^M = \sqrt{\frac{\sum_{s=1}^{S_0} (M(s) - \hat{\mu}_{S_0}^M)^2}{S_0 - 1}},$$

e

$$\hat{\mu}_{S_0}^V = \frac{\sum_{s=1}^{S_0} V(s)}{S_0}, \text{ e } \hat{\sigma}_{S_0}^V = \sqrt{\frac{\sum_{s=1}^{S_0} (V(s) - \hat{\mu}_{S_0}^V)^2}{S_0 - 1}}.$$

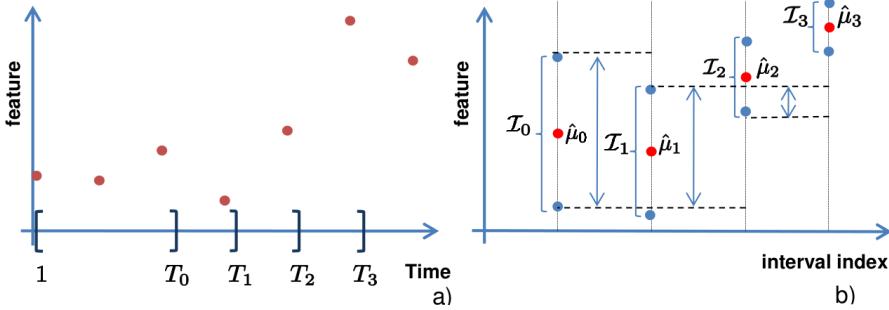
Queste stime definiscono gli *intervalli di confidenza* per i descrittori media e deviazione standard che, sotto la condizione di stazionarietà, sono definiti come:

$$I_{S_0}^M = [\hat{\mu}_{S_0}^M - \Gamma \hat{\sigma}_{S_0}^M, \hat{\mu}_{S_0}^M + \Gamma \hat{\sigma}_{S_0}^M], \\ I_{S_0}^V = [\hat{\mu}_{S_0}^V - \Gamma \hat{\sigma}_{S_0}^V, \hat{\mu}_{S_0}^V + \Gamma \hat{\sigma}_{S_0}^V],$$

dove  $\Gamma > 0$  è un parametro che controlla l'ampiezza dell'intervalle di confidenza e, quindi, la probabilità che un descrittore appartenga all'intervalle sotto l'ipotesi di stazionarietà.

Una volta che la fase di training viene completata, ICI-CDT diventa operativo e può essere utilizzato per identificare cambiamenti nella stazionarietà del flusso di dati. Non appena sono disponibili  $n$  dati, viene creata una nuova sequenza  $s$  e si calcolano i descrittori che andranno a popolare gli intervalli  $I_s^M$  e  $I_s^V$ .

A questo punto è possibile applicare la *regola dell'intersezione degli intervalli di confidenza* (ICI-rule) [16]. Questa regola verifica se una nuova istanza di un descrittore possa essere intesa come una realizzazione della già esistente



*Figura 2.11: Un esempio illustrativo di utilizzo di ICI-rule nella configurazione utilizzata per fare change detection: in (a) sono illustrati i valori del descrittore e l’insieme di intervalli  $\{[1, T_0], [1, T_1], [1, T_2], [1, T_3]\}$ , mentre in (b) vediamo i corrispondenti polinomi di ordine zero stimati, ei loro intervalli di confidenza. ICI-rule seleziona l’intervallo  $[1, T_2]$ , dato che  $I_0 \cap \dots \cap I_2 \neq \emptyset$  e  $I_0 \cap \dots \cap I_3 = \emptyset$ . Le parentesi graffe in (b) rappresentano gli intervalli di confidenza; le frecce invece rappresentano le loro intersezioni.*

distribuzione gaussiana. Se ciò non viene verificato, allora è avvenuto un cambiamento nella distribuzione.

Da un punto di vista operazionale, per ciascuna sequenza  $s$  vengono calcolati gli intervalli di confidenza dei descrittori come è stato fatto per quelli dell’insieme di training. ICI-CDT individua un cambiamento all’interno della sotto-sequenza  $\widehat{s}$  se

$$\bigcap_{s < \widehat{s}} I_s^M \neq \emptyset \text{ e } \bigcap_{s \leq \widehat{s}} I_s^M = \emptyset$$

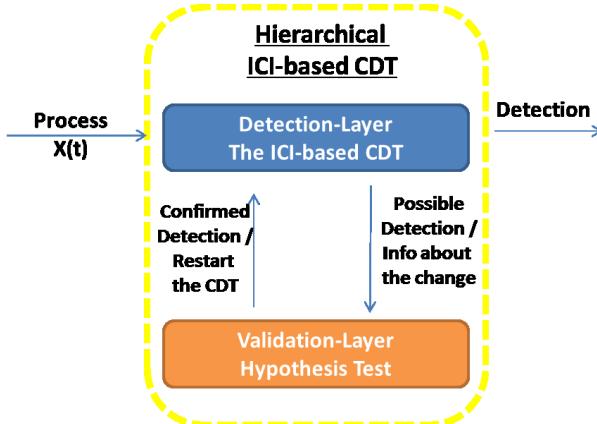
oppure

$$\bigcap_{s < \widehat{s}} I_s^V \neq \emptyset \text{ e } \bigcap_{s \leq \widehat{s}} I_s^V = \emptyset$$

e il tempo di identificazione  $\widehat{T} = n\widehat{s}$  corrisponde all’ultimo termine della sotto-sequenza  $\widehat{s}$ .

La Figura 2.11 illustra un esempio di come opera ICI-rule.

In **a** vengono rappresentati i valori dei descrittori e l’insieme di intervalli  $\{[1, T_0], [1, T_1], [1, T_2], [1, T_3]\}$ , mentre in **b** sono illustrati gli estimatori delle medie e i loro intervalli di confidenza. In questo caso ICI-rule individua un cambiamento nell’intervallo  $[1, T_2]$ , dato che  $I_0 \cap \dots \cap I_2 \neq \emptyset$  e  $I_0 \cap \dots \cap I_3 = \emptyset$ . Il principale problema di questa tecnica consiste nella sua *intrinseca* latenza, dovuta al fatto che opera a finestre. Per risolvere questo limite è possibile applicare delle trasformazioni sui dati in modo da renderli approssimativamente gaussiani. Le trasformazioni più utilizzate sono quelle di *Box-Cox* [17], per dati positivi, e di *Manly*, [18] che può essere utilizzato anche per dati negativi. Usando questo tipo di trasformazioni possiamo evitare di lavorare a finestre e utilizzare un approccio *elemento per elemento* [19].



*Figura 2.12: Schema del modo di operare del CDT di tipo gerarchico*

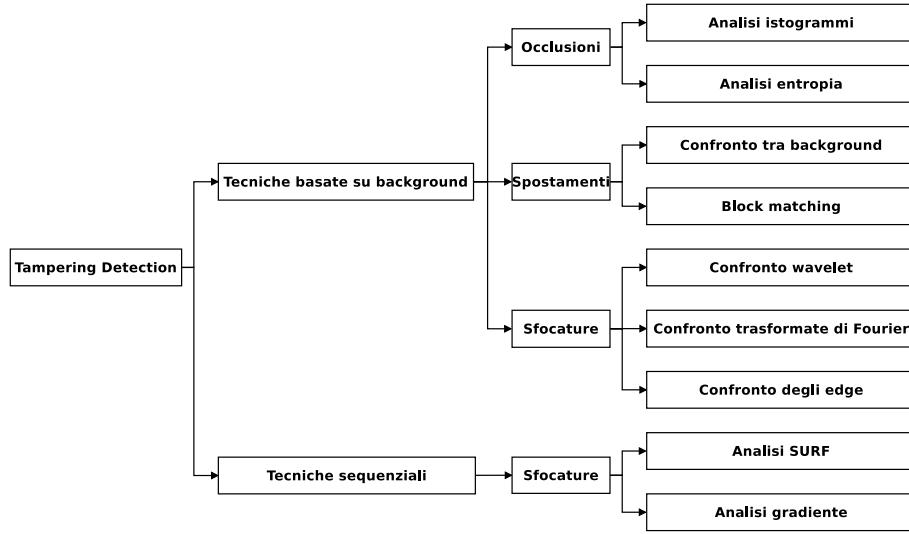
**CDT di tipo gerarchico** Un altro problema di ICI-CDT consiste nel fatto che esso genera un numero molto elevato di falsi positivi. Per fare in modo che questo numero si abbassi, impattando il meno possibile sul tempo di esecuzione, è possibile fare un CDT di tipo *gerarchico* [20], basato su due livelli:

- Il primo livello è composto da ICI-CDT, e opera sequenzialmente su tutti i dati.
- Il secondo livello consiste in un test d'ipotesi statistico in grado di validare o rifiutare l'ipotesi di avvenuto cambiamento. Questo livello viene attivato ogni volta che viene identificato un cambiamento da ICI-CDT.

Uno schema di come opera questo tipo di CDT è visualizzato nella Figura 2.12. Il CDT di tipo gerarchico è progettato in modo da avere un primo livello molto efficiente dal punto di vista del tempo di esecuzione, anche se ciò si traduce in un numero elevato di falsi positivi. Questo limite viene mitigato usando nel secondo livello della gerarchia un test più efficiente dal lato del numero di falsi positivi prodotti. Il fatto che il secondo livello ha un tempo di esecuzione maggiore non è un problema, in quanto esso viene attivato solamente nei casi in cui il primo livello della gerarchia segnala un possibile cambiamento nella distribuzione dei dati.

## 2.4 Tampering Detection

Nei moderni sistemi di videosorveglianza troviamo spesso algoritmi in grado di identificare particolari eventi all'interno della scena ripresa dalla camera. Ad esempio è possibile avere un software in grado di identificare le targhe delle automobili che superano il limite di velocità, oppure la presenza di



*Figura 2.13: Tecniche di tampering detection*

oggetti incustoditi in una stazione [21]. Affinché questi algoritmi funzionino correttamente, è importante che l'*affidabilità* del sistema di acquisizione sia preservata. Questa proprietà viene soddisfatta quando:

- la camera mantiene la stessa inquadratura nell'area di interesse;
- tutti gli elementi della scena sono distinguibili all'interno dell'immagine.

Definiamo tampering un qualsiasi evento che determini un cambio di inquadratura o che non permetta la corretta acquisizione di una parte o della totalità della scena. Possiamo classificare gli eventi di tampering in quattro categorie:

- sfocature,
- spostamenti della camera,
- occlusioni dell'obiettivo,
- guasti della camera.

La letteratura scientifica presenta molte tecniche in grado di affrontare il problema dell'identificazione di questo tipo di eventi. Lo schema in Figura 2.13 mostra le principali tecniche di tampering detection presenti in letteratura. Queste possono essere divise in due categorie:

- tecniche basate su confronto di background,
- tecniche basate su monitoraggio sequenziale.

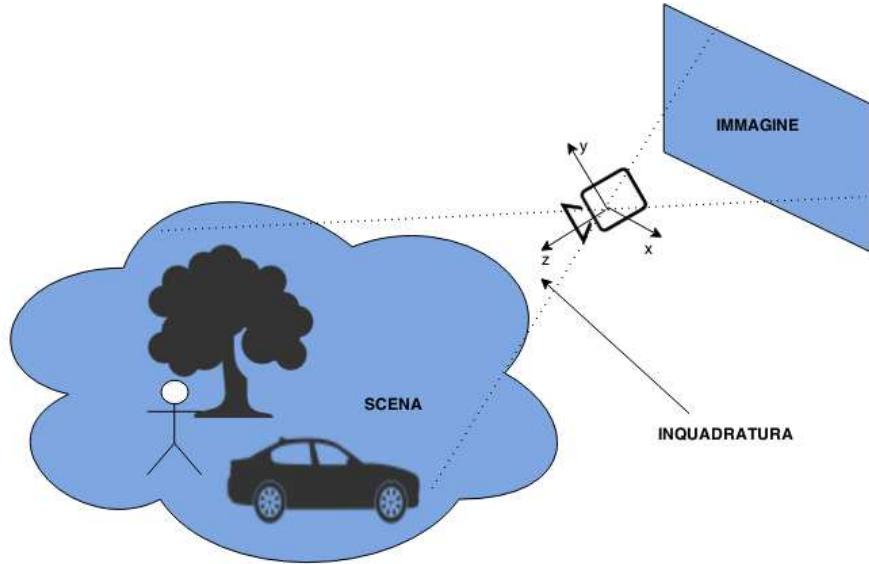


Figura 2.14: Sistema di monitoraggio video

Nel seguito del paragrafo verranno descritti i principali metodi utilizzati in queste due categorie.

#### 2.4.1 Concetti e terminologia

Prima di concentrarci su come è stato affrontato il problema del tampering detection, definiamo i concetti e i termini che verranno utilizzati nel seguito della trattazione.

Lo scenario che consideriamo è quello di una camera che deve riprendere una particolare *scena*. La posizione e l'orientamento della camera determinano l'*inquadratura* della scena. L'acquisizione, da parte della camera, della scena nell'istante di tempo  $t$  viene definita *immagine* o *frame*  $t$ -esimo. La Figura 2.14 illustra questi concetti.

Per semplificare la trattazione, considereremo immagini estratte in *scala di grigi*. Ciascuna immagine, quindi, verrà rappresentata come una matrice di pixel, in cui ciascun elemento rappresenta l'intensità luminosa (*luma*) del pixel corrispondente. L'estensione al caso di immagini *RGB* è immediata: possiamo, infatti, applicare i vari algoritmi in maniera indipendente per ciascun canale di colore, per poi mediare i risultati ottenuti.

Nel seguito della trattazione useremo una specifica terminologia. Indicheremo con  $\mathcal{X}$  l'insieme dei *pixel* costituenti l'immagine acquisita dalla camera,

$$\mathcal{X} \subset \mathbb{N}^2,$$

e con  $x \in \mathcal{X}$  il singolo pixel. Quando vorremo considerare il frame acquisito all'istante di tempo  $t$ , useremo  $z_t$ , con  $t = 1, \dots, \infty$ . In particolare, per indicare il valore della *luminosità* del pixel  $x$  per il frame  $t$ -esimo, useremo il termine  $z_t(x)$ , con

$$z_t(x) \in [0, 255] \quad \forall x \in \mathcal{X}.$$

### 2.4.2 Tecniche basate su confronto di background

Nella maggior parte dei lavori dedicati al problema del tampering detection, il metodo principalmente utilizzato consiste nel confrontare ciascun frame con un modello che viene calcolato a partire dalle osservazioni precedenti. Tale metodo è ampiamente utilizzato in vari ambiti della visione artificiale e prende il nome di *background subtraction*. Una tecnica generale di calcolo del background è presentata in [4]. Il valore del modello di background per il pixel  $x$  è calcolato, in maniera ricorsiva, secondo la seguente formula:

$$B_{t+1}(x) = \begin{cases} aB_t(x) + (1-a)z_t(x) & , \text{ se } |z_t(x) - z_{t-1}(x)| \leq T_t(x) \\ B_t(x) & , \text{ se } |z_t(x) - z_{t-1}(x)| > T_t(x) \end{cases}, \forall x \in \mathcal{X},$$

dove  $0 < a < 1$  è chiamato *parametro di aggiornamento (update parameter)* e  $T_t(x)$  è una soglia che permette di identificare un cambiamento sostanziale di luminosità nel pixel  $(x)$ . Questa soglia viene aggiornata in maniera ricorsiva secondo la seguente formula:

$$\Gamma_{t+1}(x) = \begin{cases} a\Gamma_t(x) + (1-a)(c|z_t(x) - B_t(x)|) & , \text{ se } |z_t(x) - z_{t-1}(x)| \leq \Gamma_t(x) \\ \Gamma_t(x) & , \text{ se } |z_t(x) - z_{t-1}(x)| > \Gamma_t(x) \end{cases}, \forall x \in \mathcal{X},$$

dove  $c > 1$  e  $0 < a < 1$ . Lo stesso modello viene utilizzato in altri lavori, come ad esempio in [5] e [7], mentre una variante molto usata consiste nel calcolare il modello di background a partire dall'*estrazione dei contorni* di ciascun frame ([3], [22]). Un approccio diverso, ma comunque riconducibile allo stesso filone, lo troviamo in [23], dove il background è sostituito da un *buffer* contenente gli ultimi  $n$  frame acquisiti dalla camera, che vengono confrontati con l'ultima osservazione per identificare eventi di tampering.

### Identificazione di occlusioni

L'evento di occlusione avviene quando un oggetto opaco viene posto vicino alla camera, in modo da coprire la scena ripresa. In [4] e [5] questo evento è associato a un cambiamento nella struttura dell'*istogramma* del frame occluso rispetto a quello del background. In particolare, se  $z_t$  è un frame in cui è avvenuta un'occlusione, ci si aspetta che il suo istogramma contenga i valori più alti in un intervallo più ristretto rispetto a quello del background  $B_t$ , in quanto la maggior parte dell'immagine prenderà il colore dell'oggetto

occludente o diventerà più scura.

Indichiamo con  $H_b(\cdot)$  il valore del  $b$ -esimo bin dell'istogramma di un frame, con  $1 \leq b \leq 32$ . Per identificare un evento di occlusione vengono considerate due disequazioni:

$$\begin{aligned} & (H_{\max(H(z_t))-1}(z_t) + H_{\max(H(z_t))}(z_t) + H_{\max(H(z_t))+1}(z_t)) \\ & > \Gamma_1 (H_{\max(H(z_t))-1}(B_t) + H_{\max(H(z_t))}(B_t) + H_{\max(H(z_t))+1}(B_t)), \\ & \sum_{b=1}^{32} H_b(|z_t - B_t|) > \Gamma_2 \sum_{b=1}^k H_b(|z_t - B_t|), \end{aligned}$$

dove  $\Gamma_1 > 1$ ,  $\Gamma_2 > 1$  e  $0 \leq k < 32$  sono soglie che possono essere modificate in base alla sensibilità che si richiede da parte dell'algoritmo.

Un approccio simile è presente in [3], [22] e [6], in cui l'evento di occlusione è associato a un abbassamento dell'*entropia*:

$$E = - \sum_k p_k \ln(p_k),$$

dove  $p_k$  rappresenta la probabilità che il livello di grigio  $k$  sia presente all'interno dell'immagine.

Per riuscire a identificare delle occlusioni *parziali* le tecniche descritte sopra non sono efficaci, in quanto tali eventi non sono in grado di modificare in maniera sostanziale la struttura dell'istogramma dei frame. Una soluzione ([22]) consiste nel dividere ciascuna immagine in un certo numero di *blocchi* della stessa dimensione, in modo da applicare le tecniche descritte sopra per ciascuna partizione.

### Identificazione di spostamenti della camera

Quando viene spostata la camera, in modo cambi l'inquadratura della scena, l'immagine di background  $B_t$  viene lentamente aggiornato in modo da riflettere i cambiamenti avvenuti nei frame. In [5] il metodo proposto per identificare uno spostamento della camera consiste nel confrontare l'immagine di background  $B_t$  con  $B_{t-k}$ , ovvero con un secondo modello *ritardato* di  $k$  frame, dove  $k \in \mathbb{Z}^+$ . L'approccio consiste nel calcolare un *valore di proporzione*  $P$ , ottenuto dal confronto tra i due modelli:

$$P = \begin{cases} P + 1 & , \text{ se } B_t(x) \neq B_{t-k}(x) \\ P & , \text{ se } B_t(x) = B_{t-k}(x) \end{cases}.$$

Lo spostamento della camera viene identificato quando  $P > \Gamma \cdot K$ , dove  $0 < \Gamma < 1$  è un valore di soglia scelto in base alla sensibilità che si vuole dare all'algoritmo e  $K$  è il numero totale di pixel dell'immagine.

Un altro approccio è quello di utilizzare tecniche di *block matching*. L'algoritmo di block matching fornisce due parametri: il primo parametro,  $m$ ,

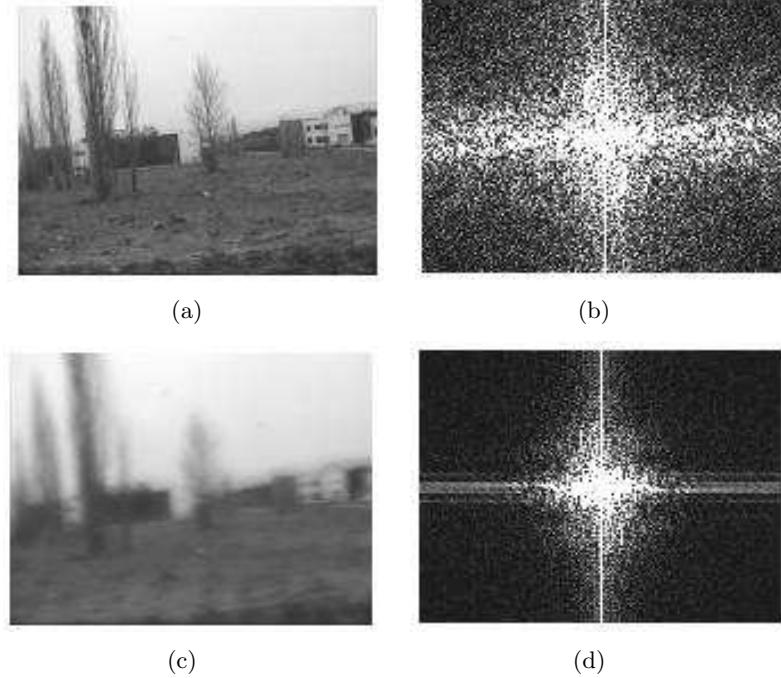


Figura 2.15: Comportamento della trasformata di Fourier nel caso di sfocatura

indica il *vettore della traslazione* tra il background e il frame corrente, mentre il secondo parametro è lo ZNCC relativo a quel vettore. In [3] e [22] l'algoritmo calcola il vettore di spostamento  $m$  del frame corrente rispetto al background, e calcola la *zero-mean normalized cross correlation* (ZNCC) [24]:

$$ZNCC_t(m) = \frac{\sum_{x \in \mathcal{X}} (B_{t-1}(x) - \mu_{B_{t-1}})(z_t(x+m) - \mu_{z_t})}{\sigma_{B_{t-1}} \sigma_{z_t}},$$

dove  $\mu_{z_t}$  e  $\sigma_{z_t}$  rappresentano la media e la deviazione standard della luminosità nell'immagine  $z_t$ . Lo spostamento viene individuato quando il vettore  $m$  ha una lunghezza minima e lo ZNCC corrispondente supera una certa soglia. Un metodo simile viene utilizzato anche in [25], con la differenza che, invece di analizzare la correlazione dei pixel, viene analizzata quella degli istogrammi.

### Identificazione di sfocature

La conseguenza di un evento di sfocatura è la perdita di dettagli nell'immagine. In [4] e [5] questo fenomeno è associato a una diminuzione dell'energia ad alta frequenza. Per analizzare questo cambiamento, [4] confronta ciascun frame con il background nel dominio delle *wavelet* [26], mentre [5] utilizza il dominio della *trasformata di Fourier* [27]. Nella Figura 2.15 vediamo un

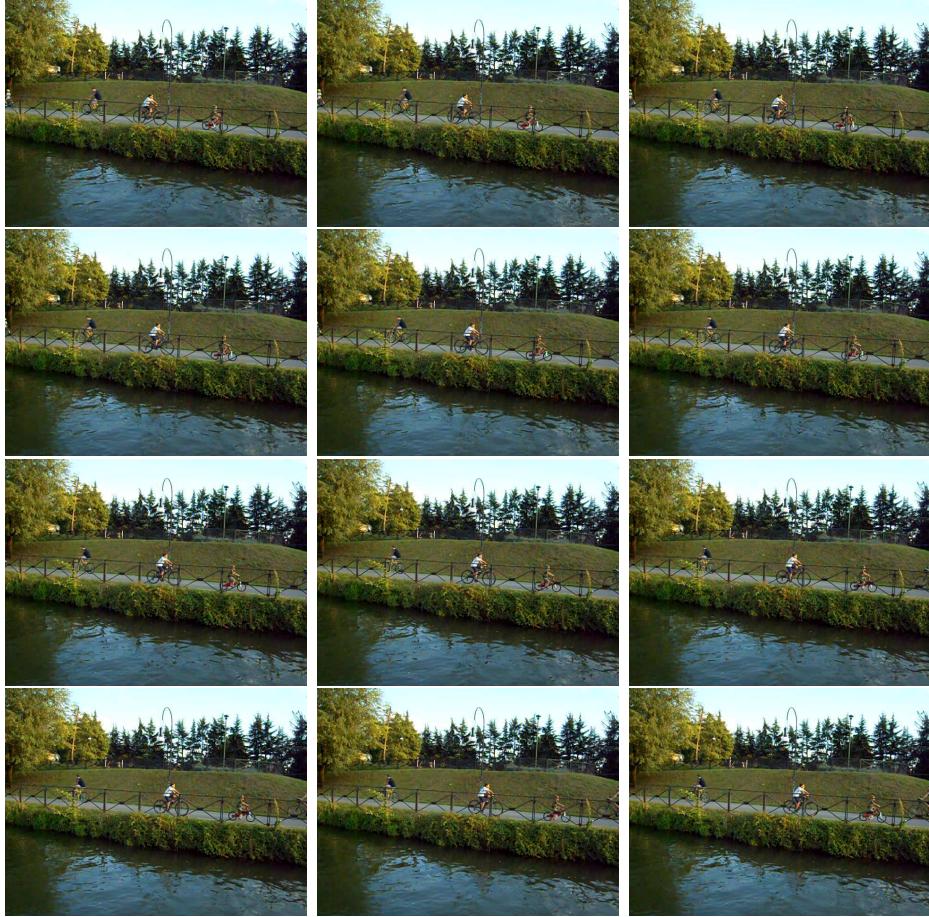


Figura 2.16: Sequenza di frame acquisiti a 30 fps

esempio di come si comporta la trasformata di Fourier nel caso di sfocature: nel passaggio da un frame nitido (Fig. 2.15(a)) a uno sfocato (Fig. 2.15(c)) abbiamo un crollo delle componenti ad alta frequenza nelle trasformate di Fourier (rispettivamente Fig. 2.15(b) e Fig. 2.15(d)). L'evento di tampering viene individuato quando l'*energia media* della trasformata di Fourier (o di quella wavelet) del frame corrente  $E_{HF}(z_t)$  è  $\Gamma$  volte minore di quella del background  $E_{HF}(B_t)$ :

$$E_{HF}(z_t) \leq \Gamma \cdot E_{HF}(B_t),$$

dove  $0 < \Gamma < 1$  è un valore di soglia scelto in base alla sensibilità che si vuole dare all'algoritmo.

Un altro approccio consiste nell'analizzare la perdita di dettagli confrontando i contorni (*edges*) del frame corrente con quelli del background. Questo metodo, utilizzato in [3], [22], [6] e [25], consiste nell'estrarrre i contorni dalle immagini secondo il metodo di Sobel [28] o di Canny [29], e confrontare il

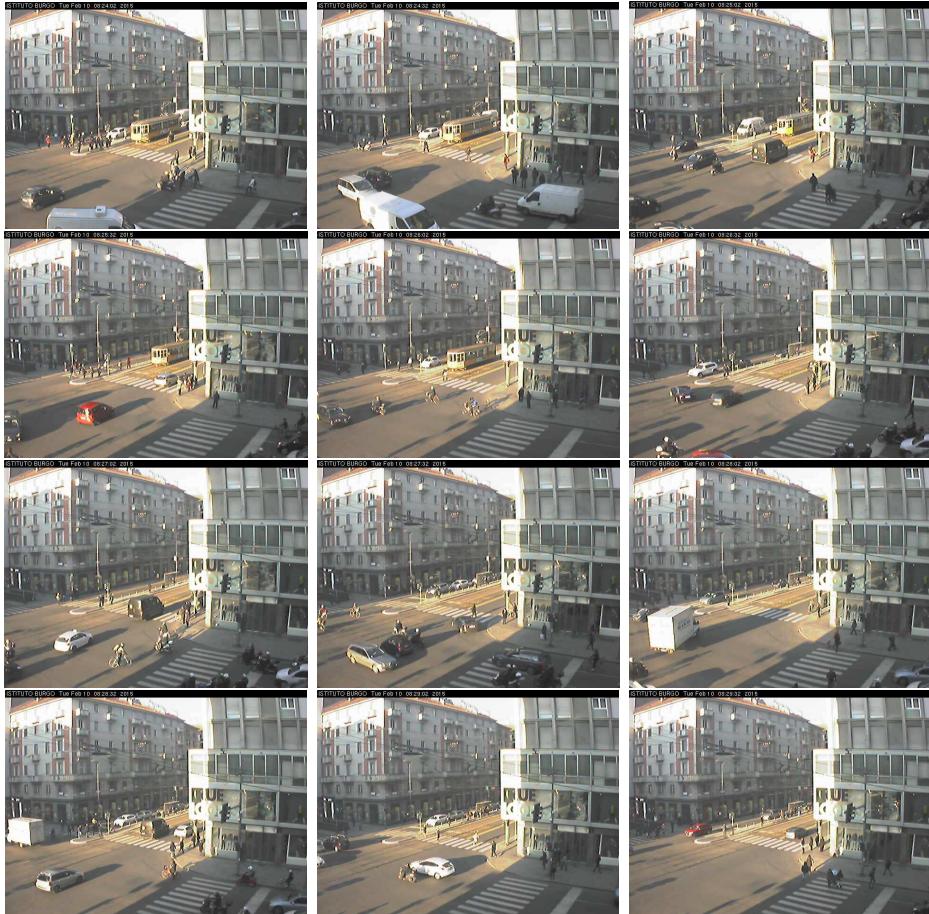


Figura 2.17: Sequenza di frame acquisiti ogni 30 secondi

numero di pixel dei contorni con quelli del background. Quando il numero di pixel dei contorni del frame corrente  $\sum edges(z_t)$  è  $\Gamma$  volte più piccolo di quello del background  $\sum edges(B_t)$ :

$$\sum edges(z_t) \leq \Gamma \sum edges(B_t),$$

dove  $0 < \Gamma < 1$  è un valore di soglia scelto in base alla sensibilità che si vuole dare all'algoritmo.

#### 2.4.3 Tecniche basate su monitoraggio sequenziale

Le tecniche viste finora, come è stato detto nel Paragrafo 2.4.2, permettono di aggiornare ciascun frame con un modello della scena che viene calcolato in base alle osservazioni precedenti. Questo approccio risulta fattibile nel caso in cui la camera operi con un framerate *continuo*, solitamente tra i 30 frame per secondo (*fps*) e i 2 fps. In questi casi, infatti, possiamo considerare che,

tra un frame e il successivo, non avvengano grandi cambiamenti all'interno della scena e non cambi eccessivamente la luminosità media. La Figura 2.16 mostra come, in un'acquisizione fatta a 30 fps, le differenze tra frame consecutivi siano quasi inesistenti. Un evento di tampering può, quindi, essere identificato in maniera molto semplice, in quanto una differenza molto elevata tra il frame analizzato e il background può essere dovuta solamente a un evento di tampering sulla camera. La Figura 2.17 mostra, invece, un esempio di frame acquisiti ogni 30 secondi. Notiamo come le differenze tra immagini consecutive, in questo caso, siano più marcate rispetto al caso dell'acquisizione continua. Questo non permette l'impiego di un modello di background per il problema del tampering detection. Evidenziamo, inoltre, che le tecniche viste finora richiedono che il sistema di monitoraggio possegga elevate capacità computazionali, in quanto l'aggiornamento del background e l'analisi di tampering detection non può rallentare la frequenza di acquisizione.

Un approccio alternativo consiste nel monitorare nel tempo il comportamento di alcuni indicatori estratti dalle singole immagini acquisite. Si presuppone che, quando il sistema di monitoraggio opera in condizioni di funzionamento *ottimali*, gli indicatori analizzati presentino una certa *stazionarietà*, ovvero siano considerati dei campioni *indipendenti* tra loro e distribuiti secondo una stessa funzione di ripartizione. L'evento di tampering viene considerato come un *cambiamento nella stazionarietà* di questi indicatori.

Il monitoraggio può avvenire utilizzando tecniche statistiche, come ad esempio *change-point method* (CPM) [13] o *change-detection test* [30].

Troviamo alcuni esempi nell'identificazione di sfocature: in [7] la soluzione consiste nel monitorare nel tempo il *numero di SURF* [31], in quanto tali descrittori decrementano in maniera considerevole il loro numero in presenza di sfocature. Notiamo, però, che l'utilizzo di una tecnica del genere richiede un elevato numero di calcoli per ricavare le SURF. Il metodo, quindi, si presta poco a essere utilizzato su sistemi di monitoraggio a basso consumo. Un altro esempio è dato da [32], dove le sfocature vengono identificate monitorando l'*energia media del gradiente* delle immagini acquisite:

$$m_t = \mathcal{M}[z_t] = \int_{\mathcal{X}} \|\nabla z_t(x)\|_1 dx,$$

dove  $\|\cdot\|_1$  si riferisce alla *norma  $\mathcal{L}_1$* . Per identificare il cambio di stazionarietà di questo indicatore vengono utilizzate tecniche di CDT basate su *somme cumulate* (CUSUM) [14].

Il test statistico utilizzato non richiede alcuna informazione *a priori* del processo che si sta monitorando, e sfrutta una sequenza iniziale  $\{m_t\}, t = 1, \dots, T$  di indicatori estratti da frame non sfocati, in modo da configurare automaticamente i suoi parametri. Tale sequenza prende il nome di *training set* e, assumendo che i dati abbiano una distribuzione *gaussiana*, permette di stimare i parametri di  $m_t$  in assenza di sfocature che determinano l'*ipotesi*

*nulla* (indicata con  $\Theta^0$ ), e di definire le *ipotesi alternative*, indicate con  $\Theta^1$ , che identificano qualsiasi cambiamento non stazionario.

Per garantire una stima accurata dei parametri, [32] consiglia di utilizzare un training set ampio, ad esempio  $T > 400$ . Il test opera su *sotto-sequenze* di misure  $m_t$  (ad esempio da 20 misure) e stima la transizione da  $\Theta^0$  a  $\Theta^1$  misurando la *log-verosimiglianza* tra la pdf in assenza di sfocature e le pdf delle varie ipotesi alternative nella sotto-sequenza  $\tau$ , ovvero

$$r(\tau) = \ln \frac{N_{\Theta^1}(\phi_\tau)}{N_{\Theta^0}(\phi_\tau)},$$

dove  $\phi_\tau$  è il valore medio della misura  $m_t$  nella sotto-sequenza  $\tau$ , e  $N_\Theta$  è la *distribuzione gaussiana multivariata* parametrizzata in  $\Theta$ .

Il metodo CUSUM considera la *somma cumulata*

$$S(\tau) = \sum_{t=1}^{\tau} r(t)$$

e identifica un cambiamento in  $m_t$  quando

$$g(\tau) = S(\tau) - \nu(\tau),$$

ovvero la differenza tra il valore della somma cumulata all'istante  $\tau$  e il suo valore minimo nel tempo

$$\nu(\tau) = \min_{t=1,\dots,\tau} S(t),$$

supera una certa soglia  $h$ .

L'utilizzo di un descrittore leggero come l'energia media del gradiente permette di operare con una bassa complessità computazionale, tanto da poter essere utilizzato come soluzione a livello di nodo per una *wireless multimedia sensor network* (WMSN) [1]. D'altro canto, confrontato con le tecniche descritte nel Paragrafo 2.4.2, l'utilizzo di tecniche sequenziali genera un numero più alto di *falsi allarmi*, il che si traduce, all'interno di una rete di sensori, in un aumento dei messaggi di allarme inviati, che devono essere considerati, quindi, come un costo.



## Capitolo 3

# Impostazione del problema di ricerca

In questo capitolo descriviamo il problema affrontato dall'algoritmo di tampering detection, in maniera formale e rigorosa.

Nel Paragrafo 3.1 illustriamo il modello delle osservazioni e gli eventi che siamo interessati a identificare.

Nel Paragrafo 3.2 formalizziamo il concetto di tampering detection.

### 3.1 Modello delle osservazioni

Il nostro campo di osservazione si concentra su quegli eventi che si interpongono tra la scena ripresa da una camera e il sensore che acquisisce le immagini. Non vogliamo, cioè, identificare degli eventi particolari che avvengono nella scena, come un oggetto lasciato incustodito [21], bensì vogliamo identificare quegli eventi che non permettano al sensore di riprendere in maniera ottimale la scena, quali ad esempio sfocature o spostamenti della camera. Nel seguito cerchiamo di dare una definizione formale di questi eventi.

#### 3.1.1 Sfocatura

Il fenomeno della sfocatura avviene quando un elemento trasparente o semi-trasparente si interpone tra la lente della camera e la scena ripresa, oppure quando viene cambiata la messa a fuoco, causando una perdita nei dettagli della scena ripresa.

Nella Figura 3.1 sono mostrati degli esempi in cui sono presenti delle sfocature. Queste possono essere di origine diversa:

- dovute a *cause naturali*, come ad esempio dell'acqua piovana che si deposita sulla lente (Figura 3.1(a)), o la condensa dovuta all'umidità e alle basse temperature, oppure un raggio di sole incidente sull'obiettivo della camera;



Figura 3.1: Esempi di sfocature

- per *intervento dell'uomo*, che a sua volta può avvenire in maniera intenzionale (e in questo caso si può parlare di *manomissione*) oppure non intenzionale. Ad esempio, si può direttamente intervenire sulla messa a fuoco, nel caso sia possibile cambiarla manualmente; oppure (come nel caso della Figura 3.1(b)) è possibile applicare una sostanza semitrasparente sulla lente della camera, come il gas di un deodorante spray.

Inoltre, possiamo notare come nella Figura 3.1(b) la sfocatura riguardi tutta l'immagine, mentre nella Figura 3.1(a) la sfocatura si concentri solo in alcune aree (quelle dove sono presenti le gocce). Nel primo caso si parlerà, quindi, di sfocatura *totale*, mentre nel secondo caso di sfocatura *parziale*.

Riprendendo la trattazione presente in [32], questo fenomeno può essere modellato come un operatore di *degradazione*  $\mathcal{D}$  applicato a un'immagine  $y$ , considerata priva di errori, i.e.,

$$z = \mathcal{D}[y]. \quad (3.1)$$

In particolare, all'interno dell'operatore  $\mathcal{D}$  si può considerare il contributo dovuto a un operatore di *sfocatura*  $\mathcal{B}$  (dall'inglese *blur*) e un termine aleatorio  $\eta$  corrispondente al rumore, i.e.,

$$z(x) = \mathcal{D}[y](x) = \mathcal{B}[y](x) + \eta(x), \quad x \in \mathcal{X} \quad (3.2)$$

dove, come abbiamo specificato nel Paragrafo 2.4.1, indichiamo con  $x$  le coordinate dei *pixel* dell'immagine e con  $\mathcal{X}$  l'insieme dei pixel che formano l'immagine. Per praticità possiamo assumere che l'operatore di blur sia *lineare*. Quindi, considerando l'immagine come un dato *continuo*,

$$\mathcal{B}[y](x) = \int_{\mathcal{X}} y(s)h(x, s)ds, \quad (3.3)$$



Figura 3.2: Sequenza di otto frame consecutivi acquisiti ogni minuto

dove  $h(x, \cdot)$  rappresenta la *risposta all'impulso*, *point spread function* (PSF), della sfocatura sul pixel  $x$ . L'effetto di  $h(x, \cdot)$  è quello di rendere le differenze di intensità, tra pixel adiacenti, più morbide (*smooth*). Nel caso in cui la sfocatura sia applicata sulla totalità dell'immagine e fosse *spazio invariante* (come nel caso della Figura 3.1(b)), allora è possibile modellare l'operatore di blur come una *convoluzione*<sup>1</sup>:

$$\mathcal{B}[y](x) = \int_{\mathcal{X}} y(s)h(s-x)ds, \quad (3.4)$$

dove  $h(\cdot)$  è un filtro gaussiano o uniforme.

Nel caso più generale possiamo considerare che la camera acquisisca una sequenza di  $N$  osservazioni (dove  $N$  può tendere all'infinito)  $\{z_t\}, t = 1, \dots, N$ , quindi la formula (3.2) si può riscrivere come

$$z_t(x) = \mathcal{D}_t[y_t](x) = \mathcal{B}_t[y_t](x) + \eta(x), \quad x \in \mathcal{X}. \quad (3.5)$$

La sequenza delle immagini  $\{y_t\}, t = 1, \dots, N$ , può variare in maniera significativa nel suo contenuto, anche nel caso in cui la vista sia la stessa. Un esempio è illustrato nella Figura 3.2, in cui le immagini riprese dalla camera sono acquisite ogni minuto. Nonostante l'inquadratura non cambi tra le acquisizioni, il contenuto delle singole immagini varia parecchio, a causa del continuo passaggio di automobili e pedoni. Questo problema fa sì che l'identificazione delle sfocature non possa avvenire facendo un semplice confronto tra frame consecutivi, in quanto avremmo un numero troppo elevato di falsi positivi. Infatti, nel caso in cui avessimo un riscontro negativo dal confronto tra due frame ( $z_t \neq z_{t+1}$ ), sarebbe difficile capire se è cambiato il contenuto delle immagini ( $y_t \neq y_{t+1}$ ) o l'operatore di sfocatura ( $\mathcal{B}_t \neq \mathcal{B}_{t+1}$ ).

### 3.1.2 Spostamento della camera

Lo spostamento della camera avviene quando cambia la sua inquadratura. Le cause possono essere, ancora una volta, di tipo naturale, ad esempio una

---

<sup>1</sup>Il blur convoluzionale è quello che abbiamo utilizzato per generare, in maniera sintetica, sequenze con immagini sfocate.



(a)

(b)

Figura 3.3: Esempio di spostamento della camera

raffica di vento che sposta la camera, oppure dovute a un intervento umano, uno spostamento intenzionale per evitare che la scena venga ripresa. Un esempio è mostrato nella Figura 3.3, dove vediamo che tra il frame riportato in Figura 3.3(a) e quello in Figura 3.3(b) c'è stato un evento che ha spostato la camera. Possiamo formalizzare il concetto di spostamento della camera nel modo seguente: consideriamo la sequenza  $\{y_t\}$  di immagini generate da una camera in una certa posizione, e la sequenza  $\{w_t\}$  di immagini generate dalla stessa camera in una posizione differente.

Possiamo modellare la sequenza di immagini  $\{z_t\}$  in cui avviene uno spostamento della camera all'istante  $T^*$  nel seguente modo:

$$z_t(x) = \begin{cases} y_t(x) + \eta(x) & \text{per } t < T^* \\ w_t(x) + \eta(x) & \text{per } t \geq T^* \end{cases}, \quad (3.6)$$

dove  $\eta(x)$  è un rumore stazionario.

In questa formulazione abbiamo considerato lo spostamento come un fenomeno *istantaneo*; in generale, possiamo considerare una fase *transitoria* in cui l'inquadratura della camera cambia a ogni frame acquisito, fino a raggiungere la posizione finale. Dato che, nella nostra applicazione, la camera opera con framerate molto bassi (come ad esempio un'immagine al minuto), possiamo considerare lo spostamento come istantaneo e, quindi, tenere come riferimento il modello (3.6).

Anche per lo spostamento della camera vale la considerazione fatta nel caso della sfocatura: il contenuto delle immagini varia con il passare del tempo, quindi identificare lo spostamento confrontando frame consecutivi nel tempo genera un alto numero di falsi allarmi, come verrà mostrato dalla fase sperimentale.



*Figura 3.4: Esempi di occlusione*

### 3.1.3 Occlusione e guasti della camera

Il fenomeno dell’occlusione avviene quando un oggetto opaco si pone a ridosso della camera, impedendo la visione di una parte, se non la totalità, della scena. Esempi di occlusione sono illustrati in Figura 3.4. Può succedere (Fig. 3.4(a)) che un oggetto venga posto intenzionalmente davanti alla lente della camera, in modo da coprire la scena, oppure (Fig. 3.4(b)), a causa di una nevicata, può avvenire che della neve si depositi sulla lente e, quindi, venga compromessa la corretta acquisizione.

Quando parliamo di guasti, invece, possiamo considerare due casi:

- guasto della *trasmissione*;
- guasto del *sensore*.

Il primo caso può avvenire nel caso si considerino delle WMSN, in particolare quando i frame vengono trasmessi attraverso la rete dai sensori verso un nodo centrale. Quando avviene un guasto nella rete parte dell’immagine non viene trasmessa, come illustrato nella Figura 3.5(a). Il caso del sensore guasto, come ad esempio quello nella Figura 3.5(b), comporta generalmente un aumento del rumore presente nel frame.

Questi problemi non sono stati affrontati durante il corso della tesi, comunque le tecniche messe a punto per rilevare spostamenti e sfocature possono essere utilizzate anche per rilevare questo tipo di eventi.

## 3.2 Tampering detection

Nel Paragrafo 2.4 abbiamo introdotto in maniera molto generale il concetto di tampering detection. In questo paragrafo diamo una definizione più formale al problema. L’algoritmo di tampering detection consiste nell’analizzare la sequenza dei frame generati dalla camera in modo da determinare



(a)

(b)

*Figura 3.5: Esempi di guasti che possono compromettere l’acquisizione dei frame. In (a) vediamo un esempio di guasto della trasmissione, in cui parte dell’immagine non viene correttamente trasmessa nella rete. In (b), invece, vediamo un aumento del rumore nell’immagine, causato da un guasto del sensore della camera.*

un possibile cambiamento nell’inquadratura della scena o una sfocatura. Consideriamo il caso generale di una sequenza di frame  $\{z_t\}, t = 1, \dots, \infty$ . Per  $t < T^*$  abbiamo che i frame vengono acquisiti in condizioni di funzionamento normale:

$$z_t(x) = y_t(x) + \eta(x), \forall x \in \mathcal{X}, \text{ per } t = 1, \dots, T^* - 1.$$

All’istante di tempo  $t = T^*$  avviene un evento di tampering, il quale compromette i frame per  $t \geq T^*$ . In particolare, nel caso di una sfocatura avremo

$$z_t = \mathcal{B}_t[y_t](x) + \eta(x), \forall x \in \mathcal{X}, \text{ per } t \geq T^*,$$

mentre nel caso di uno spostamento della camera avremo

$$z_t = w_t(x) + \eta(x), \forall x \in \mathcal{X}, \text{ per } t \geq T^*.$$

L’obiettivo dell’algoritmo di tampering detection è quello di stimare l’istante  $T^*$ .

Come abbiamo illustrato precedentemente, discriminare tra cambiamenti avvenuti a livello di contenuto della scena e cambiamenti dovuti a tampering può diventare complicato confrontando direttamente i frame tra loro, in quanto stiamo operando con framerate bassi. Non utilizzeremo, quindi, le tecniche basate su background che sono state descritte nel Paragrafo 2.4.2. Nel Capitolo 4 vedremo la soluzione che abbiamo deciso di utilizzare per lo sviluppo dell’algoritmo di tampering detection.

## Capitolo 4

# Soluzione proposta

In questo capitolo descriviamo la soluzione che abbiamo proposto per risolvere il problema del tampering detection, formulato nel Capitolo 3.

Nel Paragrafo 4.1 descriviamo quali sono gli indicatori che abbiamo deciso di monitorare per individuare gli eventi di tampering.

Nel Paragrafo 4.2 illustriamo in che modo vengono monitorati questi indicatori in modo da individuare degli eventi specifici.

Nel Paragrafo 4.3 descriviamo, infine, l'algoritmo di segmentazione che utilizziamo, assieme al monitoraggio, per individuare eventi di spostamento della camera.

### 4.1 Indicatori utilizzati per identificare gli eventi di tampering

L'approccio che abbiamo considerato per risolvere il problema del tampering detection consiste nell'estrarrre, da ciascun frame ripreso dalla camera, degli indicatori *scalari* che possano essere monitorati nel tempo, in modo da individuare un cambio di distribuzione o un *outlier* associabile a un evento di tampering. In particolare abbiamo deciso di considerare un indicatore in grado di verificare la presenza di sfocature globali all'interno della scena e un altro in grado di identificare gli eventi di spostamento della camera. Il resto del paragrafo è dedicato alla descrizione di questi indicatori.

#### 4.1.1 Misura della sfocatura nell'immagine

Nel Paragrafo 3.1.1 abbiamo modellizzato il fenomeno della sfocatura secondo la formula (3.5):

$$z_t(x) = \begin{cases} y_t(x) + \eta(x) & \text{per } t < T^* \\ \mathcal{B}_t[y_t](x) + \eta(x) & \text{per } t \geq T^* \end{cases}, \forall x \in \mathcal{X}.$$

Ricavare un indicatore in grado di misurare direttamente il grado di sfocatura di un'immagine è difficile. Quello che è possibile fare, come proposto



(a)

(b)

*Figura 4.1: Esempio di cambi di luminosità tra il giorno e la notte*

in [32], è misurare *indirettamente* il grado di sfocatura di un’immagine  $z_t$  basandosi sulle frequenze dell’immagine.

Come abbiamo visto nel Paragrafo 3.1.1, l’operatore di sfocatura  $\mathcal{B}$  ha come effetto principale quello di rendere le differenze di intensità tra pixel adiacenti più morbide (*smooth*). In base a questa considerazione è possibile identificare un evento di sfocatura andando a monitorare l’*energia media del gradiente* di ciascuna immagine:

$$g(t) = \mathcal{G}[z_t] = \frac{\sum_{\mathcal{X}} \|\nabla z_t(x)\|_2^2}{|\mathcal{X}|}, \quad (4.1)$$

dove abbiamo indicato con  $|\mathcal{X}|$  la *cardinalità* dell’insieme dei pixel  $\mathcal{X}$ , e con  $\|\cdot\|_2$  la norma di tipo  $\mathcal{L}_2$ <sup>1</sup>.

Lavorando nel dominio discreto delle immagini digitali, possiamo calcolare le derivate dell’intensità luminosa (*luma*) per mezzo di convoluzioni con filtri derivativi. In particolare, per il calcolo delle derivate orizzontali abbiamo utilizzato il seguente filtro  $f_h$ :

$$f_h = f \circledast \begin{bmatrix} 1 & 0 & -1 \end{bmatrix},$$

mentre per il calcolo delle derivate verticali abbiamo utilizzato il seguente filtro  $f_v$ :

$$f_v = f \circledast \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix},$$

dove abbiamo indicato con  $\circledast$  l’operatore di convoluzione. Il filtro  $f$ , invece, è ottenuto tramite un campionamento della *funzione gaussiana*  $h$ , con media 0 e deviazione standard  $\sigma$

$$h(i, j) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{i^2 + j^2}{2\sigma^2}\right), \quad (4.2)$$

---

<sup>1</sup> $\|x\|_2 = \sqrt{\sum_t x_t^2}$



(a)

(b)

*Figura 4.2: In questo esempio vediamo come l'aumentare il tempo di esposizione della camera porti come effetto una presenza di sfocature nelle zone dove sono presenti oggetti in movimento. In (a), dove il frame è acquisito durante il giorno, vediamo come le macchine in movimento siano riprese in maniera nitida, mentre in (b), dove il frame è ripreso durante la notte, le zone con le macchine risultano sfocate.*

e ponendo il valore massimo di questa funzione nel centro del filtro. Con questi filtri è possibile calcolare la *norma del gradiente* nel seguente modo:

$$\|\nabla z_t(x)\|_2^2 = (z_t \circledast f_h)(x)^2 + (z_t \circledast f_v)(x)^2. \quad (4.3)$$

Una volta calcolata la norma del gradiente è possibile farne la media come specificato in (4.1). Il risultato finale è un indicatore *scalare* per ciascun frame acquisito, che può essere monitorato per individuare eventi di sfocature. In particolare ci aspettiamo che l'evento di sfocatura provochi un abbattimento del valore di  $g$ .

#### 4.1.2 Misura dello spostamento della camera

Nel Paragrafo 3.1.2 abbiamo modellizzato il fenomeno dello spostamento della camera secondo (3.6)

$$z_t(x) = \begin{cases} y_t(x) + \eta(x) & \text{per } t < T^* \\ w_t(x) + \eta(x) & \text{per } t \geq T^* \end{cases}, \forall x \in \mathcal{X}$$

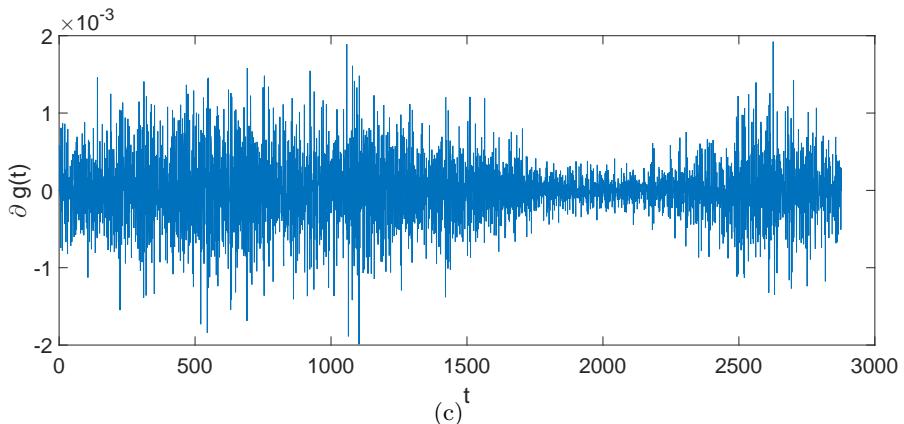
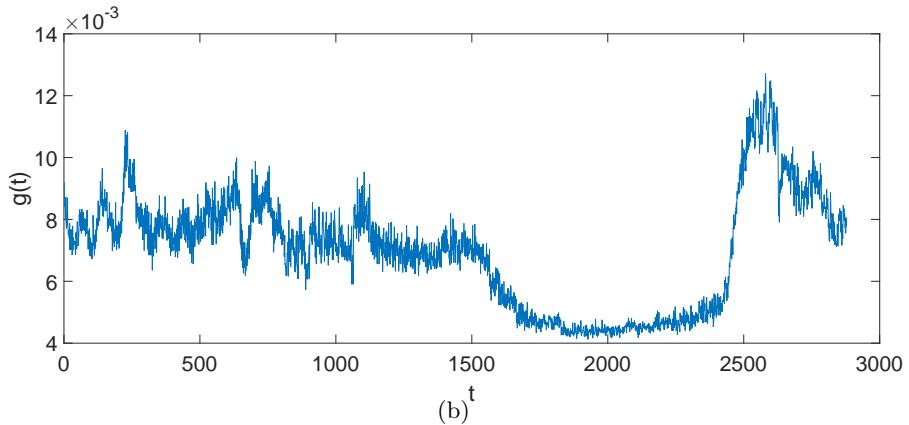
dove  $T^*$  indica l'istante in cui avviene il cambiamento.

Uno spostamento della camera, quindi, può essere rilevato come un cambiamento *globale* dei valori di intensità luminosa (*luma*) nei pixel dell'immagine. In base a questo è possibile identificare un evento di spostamento della camera andando a monitorare l'*energia media della luma* di ciascuna immagine:

$$l(t) = \mathcal{L}[z_t] = \frac{\sum_{\mathcal{X}} z_t(x)}{|\mathcal{X}|}, \quad (4.4)$$



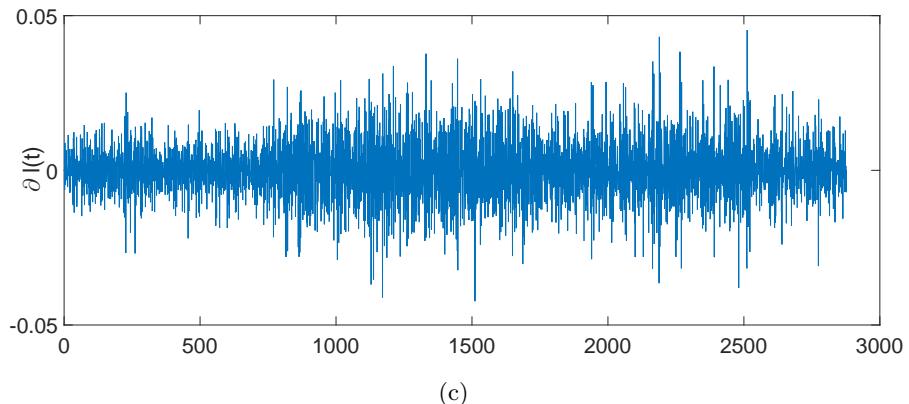
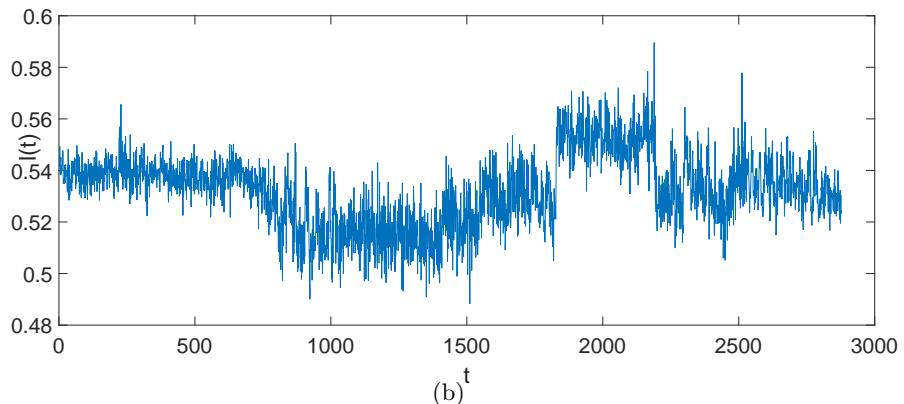
(a)



*Figura 4.3: In questo esempio vediamo il comportamento dell'energia media del gradiente su una sequenza di 24 ore in cui non avvengono eventi di tampering. In (a) sono riportati alcuni frame estratti dalla sequenza. In (b) vediamo il comportamento dell'indicatore  $g(t)$ , e in (c) quello del suo detrending . Anche in assenza di tampering, l'indicatore  $g(t)$  presenta un andamento molto irregolare e difficilmente prevedibile. Il detrending dell'indicatore, invece, possiede un andamento più stazionario, incentrato sul valore 0.*



(a)



*Figura 4.4: In questo esempio vediamo il comportamento dell'energia media della luma su una sequenza di 24 ore in cui non avvengono eventi di tampering. In (a) sono riportati alcuni frame estratti dalla sequenza. In (b) vediamo il comportamento dell'indicatore  $l(t)$ , e in (c) quello del suo detrending. Anche in assenza di tampering, l'indicatore  $l(t)$  presenta un andamento molto irregolare e difficilmente prevedibile. Il detrending dell'indicatore, invece, possiede un andamento più stazionario, incentrato sul valore 0.*

dove abbiamo indicato con  $|\mathcal{X}|$  la *cardinalità* dell'insieme dei pixel  $\mathcal{X}$ .

Il risultato finale è un indicatore *scalare* per ciascun frame acquisito, che può essere monitorato per individuare eventi di spostamenti della camera.

#### 4.1.3 Comportamento degli indicatori nel tempo

Analizzando alcune sequenze video abbiamo notato che, anche in assenza di eventi di tampering, vi sono alcuni fattori che sono in grado di far variare il valore degli indicatori estratti. Tra i più importanti abbiamo:

- *Cambiamenti di luminosità* che avvengono nel corso della giornata. Se consideriamo l'esempio in Figura 4.1, possiamo notare come, nel passaggio dal giorno (Figura 4.1(a)) alla notte (Figura 4.1(b)), le differenze di luminosità siano elevate.
- *Dinamicità della scena*. La ripresa di una scena dinamica, come ad esempio una strada, ha come risultato che ciascun frame sia diverso dagli altri. Ciò si traduce in una variabilità elevata degli indicatori che abbiamo utilizzato. Inoltre, col passare del tempo, può succedere che cambi anche il *grado di dinamicità* della scena. Considerando ancora l'esempio della strada avremo dei momenti in cui il traffico è più intenso (nelle cosiddette *ore di punta*) e altri in cui le macchine passano meno spesso (tipicamente durante la notte).
- *Tempo di esposizione della camera*. Solitamente le camere sono in grado di configurare in maniera automatica alcuni parametri che regolano l'acquisizione dell'immagine, in base alle condizioni di luminosità esterne. Ad esempio, durante la ripresa di scene notturne la camera solitamente aumenta il *tempo di esposizione* del sensore, in modo che esso possa ricevere più luce possibile. Ciò porta alla *presenza di sfocature* nel caso vengano immortalati degli oggetti in movimento (come ad esempio le macchine che si muovono nella Figura 4.2(b)). Nel caso in cui il tempo di esposizione non fosse sufficiente, invece, i cambiamenti di luminosità potrebbero portare a un aumento del rumore nei frame acquisiti nelle ore più scure, in quanto il sensore riceverebbe meno luce.

Questi fenomeni fanno sì che i nostri indicatori abbiano una dinamica *dificilmente prevedibile* e che *non siano stazionari*<sup>2</sup>, come possiamo vedere dal comportamento dell'energia del gradiente nella Figura 4.3(b) e da quello dell'energia media della luma nella Figura 4.4(b). I due grafici riportano l'andamento degli indicatori durante una ripresa di 24 ore, acquisendo un frame ogni minuto, in cui non sono avvenuti eventi di tampering. Il fatto che questi indicatori non si comportino in maniera stazionare anche nel caso

---

<sup>2</sup>Ovvero non sono realizzazioni i.i.d. di una stessa variabile aleatoria

in cui non avvengano eventi di tampering rende impossibile applicare direttamente le tecniche di CDT come in [32].

#### 4.1.4 Detrending degli indicatori

Osservando l’andamento degli indicatori nelle Figure 4.3(b) e 4.4(b) possiamo notare la presenza di componenti ad alta frequenza, dovute dal rumore nelle immagini, e di componenti in bassa frequenza, dovute prevalentemente ai cambi di luce e dalla dinamicità della scena. Per eliminare le componenti in bassa frequenza, che sono quelle che rendono i nostri indicatori non prevedibili, possiamo fare un *detrending* di ciascun segnale calcolando la *differenza* tra l’indicatore all’istante corrente e quello precedente. Nel caso dell’energia media del gradiente avremo

$$\frac{\partial g}{\partial t}(t) = g(t) - g(t-1), \quad (4.5)$$

mentre per l’energia media della luma avremo

$$\frac{\partial l}{\partial t}(t) = l(t) - l(t-1). \quad (4.6)$$

Vediamo un esempio di come si comporta il detrending sui nostri indicatori nelle Figure 4.3(c) e 4.4(c). Possiamo notare come le fluttuazioni in bassa frequenza vengano rimosse dal detrending, visto che gli indicatori di due frame consecutivi sono pressoché costanti.

Come abbiamo detto prima, lo scopo del monitoraggio di questi indicatori è quello di individuare degli eventi di tampering. Nelle Figure 4.5 e 4.7 possiamo vedere il comportamento dell’energia media di luma e gradiente rispettivamente per un caso di sfocatura e per un caso di spostamento della camera. In particolare, in entrambi i casi l’evento di tampering avviene al frame 1000<sup>3</sup>. Il detrending di questi segnali è visualizzato nelle Figure 4.6 e 4.8.

Possiamo vedere come, in generale, l’evento di tampering sia associato a un brusco salto o a un crollo *istantaneo* del valore di uno o entrambi gli indicatori. Vanno notate alcune cose:

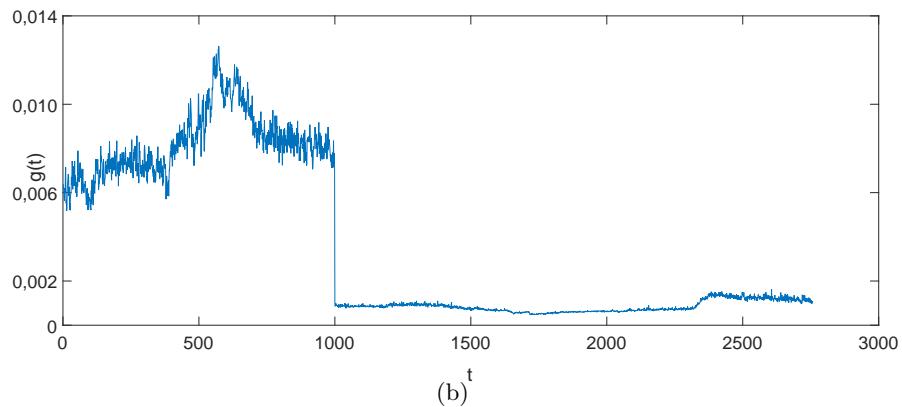
- L’evento di sfocatura non si traduce in un cambiamento nell’energia media della luma. Questo avviene perché questo tipo di tampering abbatta le alte frequenze presenti nell’immagine, mantenendo comunque il valore medio della luma invariato.
- Facendo il detrending della sequenza abbiamo dei valori che oscillano attorno allo zero, un picco in corrispondenza dell’istante in cui avviene il tampering (Figure 4.5(c), 4.7(c), 4.8(c)) e infine altri valori

---

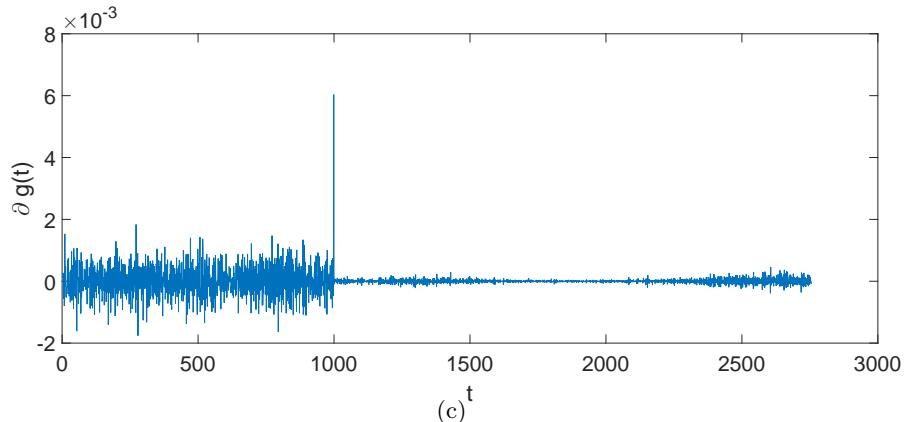
<sup>3</sup>Il modo in cui sono stati ottenuti gli eventi di tampering è descritto nel Capitolo 5



(a)



(b)

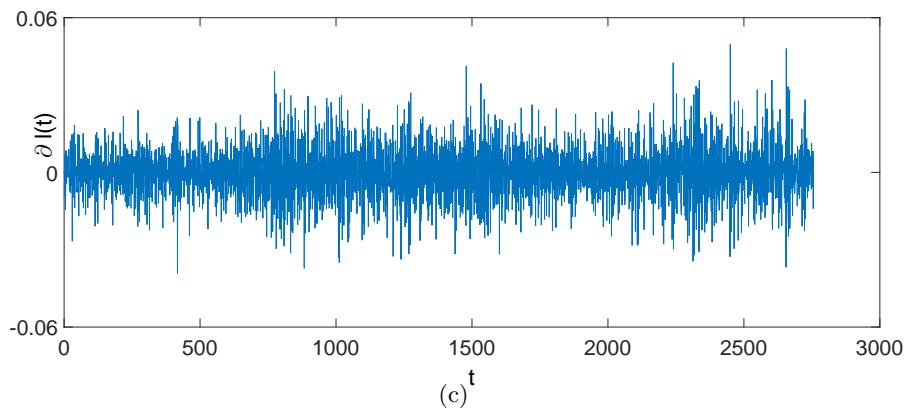
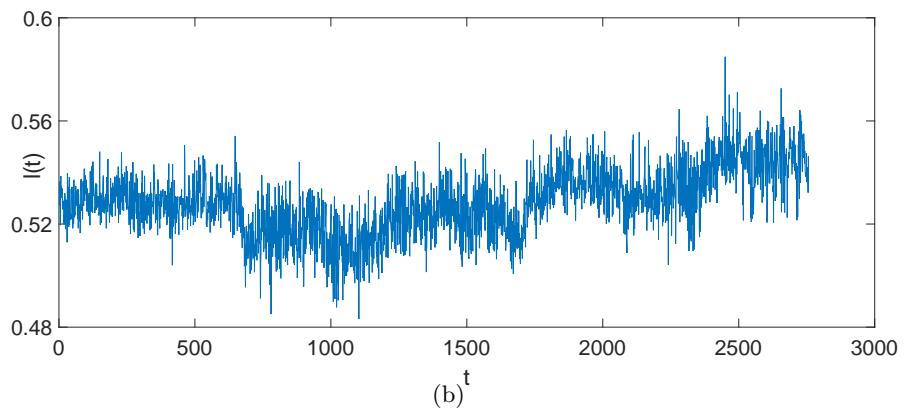


(c)

*Figura 4.5: In questo esempio vediamo il comportamento dell'energia media del gradiente su una sequenza di 24 ore in cui avviene un evento di sfocatura. In (a) sono riportati alcuni frame estratti dalla sequenza. La sfocatura avviene al frame 1000 e continua per il resto della sequenza. In (b) vediamo il comportamento dell'indicatore  $g(t)$ , e in (c) quello del suo detrending. Vediamo come in (b) l'evento di sfocatura si traduca in un crollo del valore di  $g(t)$ . In (c), invece, vediamo che l'evento si traduce in un picco nel valore del detrending nell'istante in cui inizia la sfocatura, e in una diminuzione della varianza negli istanti successivi*



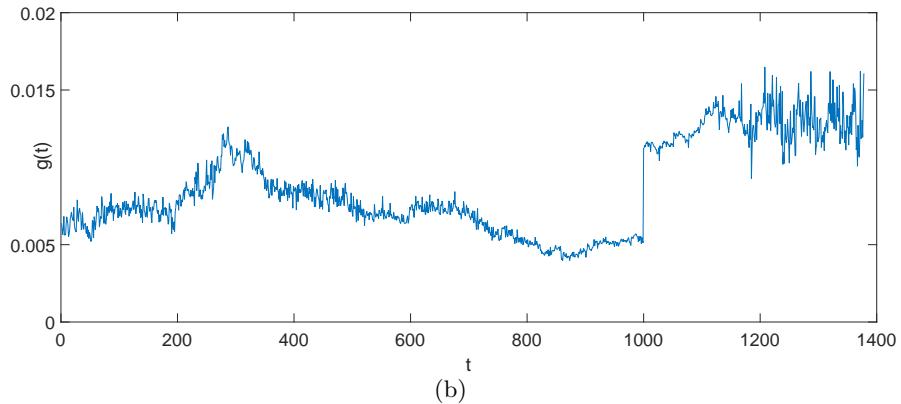
(a)



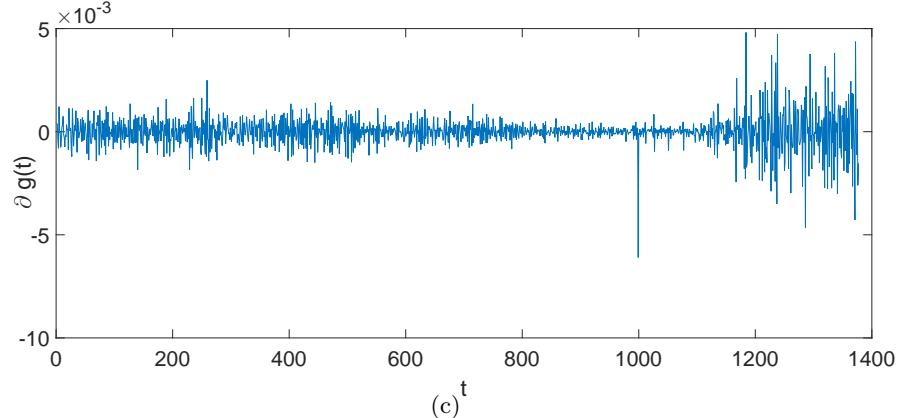
*Figura 4.6: In questo esempio vediamo il comportamento dell'energia media della luma su una sequenza di 24 ore in cui avviene un evento di sfocatura. In (a) sono riportati alcuni frame estratti dalla sequenza. La sfocatura avviene al frame 1000 e continua per il resto della sequenza. Vediamo come il comportamento dell'indicatore  $l(t)$  (b) e quello del suo detrending (c) non siano influenzati dall'evento di sfocatura. Questo avviene perché questo tipo di tampering abbatte le alte frequenze presenti nell'immagine, mantenendo comunque il valore medio della luma invariato.*



(a)



(b)

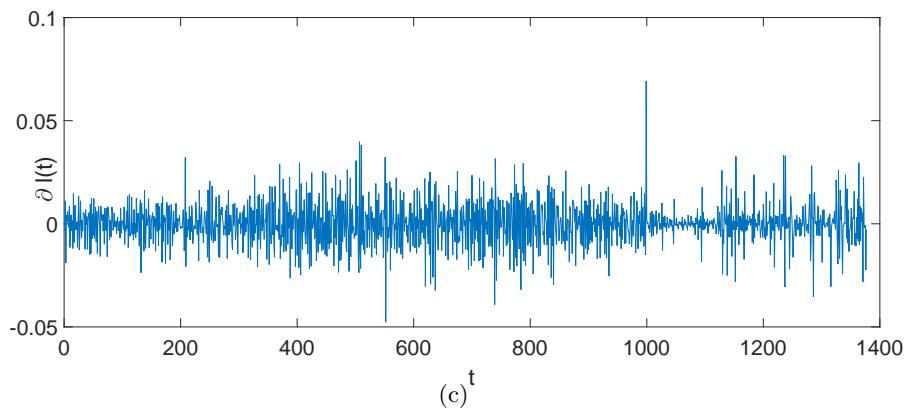
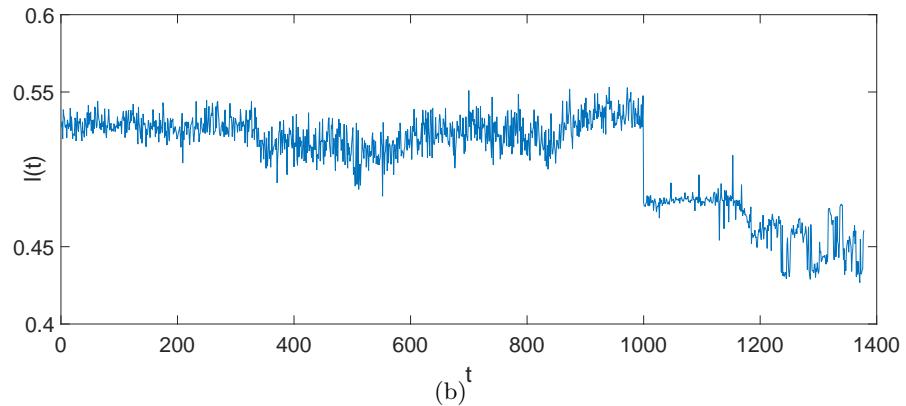


(c)

*Figura 4.7:* In questo esempio vediamo il comportamento dell'energia media del gradiente su una sequenza di 24 ore in cui avviene un evento di spostamento della camera. In (a) sono riportati alcuni frame estratti dalla sequenza. Lo spostamento della camera avviene al frame 1000 e, per il resto della sequenza, l'inquadratura rimane la stessa. In (b) vediamo il comportamento dell'indicatore  $g(t)$ , e in (c) quello del suo detrending. Vediamo come in (b) l'evento di spostamento della camera si traduca in un salto del valore di  $g(t)$ . In (c), invece, vediamo che l'evento si traduce in un picco (in questo caso negativo) nel valore del detrending nell'istante in cui inizia la sfocatura.



(a)



*Figura 4.8:* In questo esempio vediamo il comportamento dell'energia media della luma su una sequenza di 24 ore in cui avviene un evento di spostamento della camera. In (a) sono riportati alcuni frame estratti dalla sequenza. Lo spostamento della camera avviene al frame 1000 e, per il resto della sequenza, l'inquadratura rimane la stessa. In (b) vediamo il comportamento dell'indicatore  $l(t)$ , e in (c) quello del suo detrending. Vediamo come in (b) l'evento di spostamento della camera si traduca in un salto del valore di  $l(t)$ . In (c), invece, vediamo che l'evento si traduce in un picco (in questo caso positivo) nel valore del detrending nell'istante in cui inizia la sfocatura.

che oscillano attorno allo zero. Questo è dato dal fatto che il detrending considera le differenze tra dati consecutivi e, quindi, la differenza maggiore si ha proprio nell'istante in cui inizia l'evento di tampering, mentre solitamente le differenze tra misure consecutive sono minime. Questo fa sì che monitorare il detrending delle sequenze degli indicatori permetta di identificare più facilmente gli eventi di tampering rispetto ad analizzare la sequenza originale. Il risvolto della medaglia è che i cambiamenti *persistenti*, come quelli che stiamo considerando noi, diventano dei cambiamenti *istantanei*.

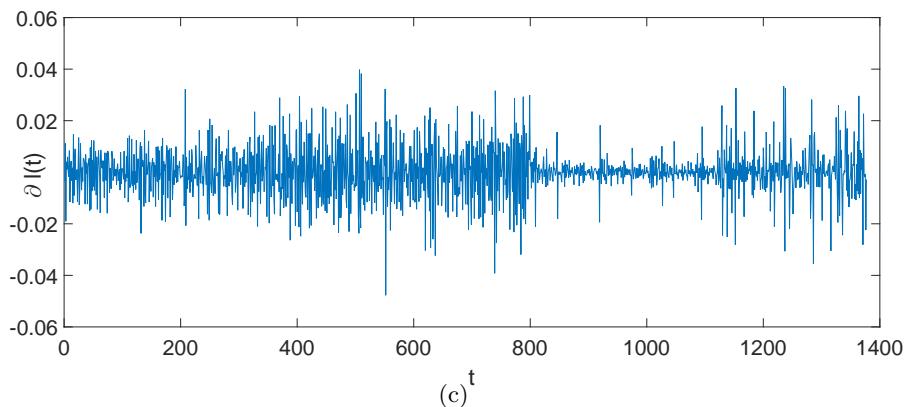
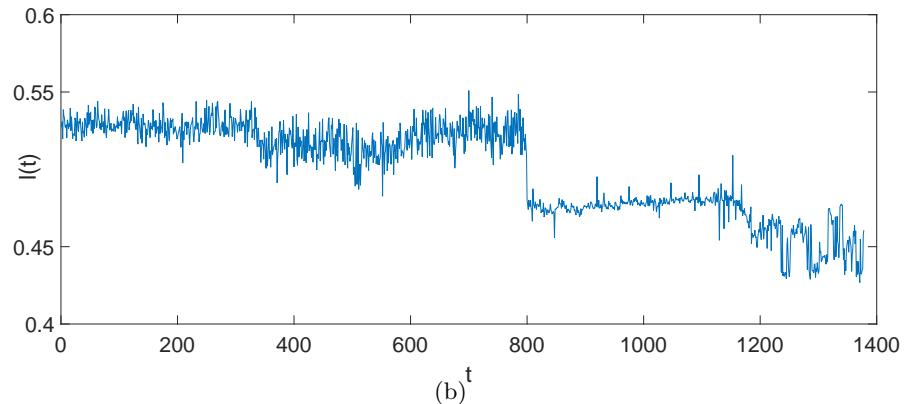
- Considerando l'evento di sfocatura, possiamo notare (Figura 4.5(b)) come, in seguito all'evento, oltre ad aver un crollo istantaneo del valore dell'energia del gradiente, abbiamo anche un abbassamento *persistente* della sua varianza. Questo permette di utilizzare tecniche di monitoraggio sequenziale sull'energia del gradiente, con dei CDT sulla varianza, per identificare eventi di sfocatura.

In definitiva, è possibile identificare un evento di tampering andando a monitorare il detrending degli indicatori descritti da (4.1) e (4.4), utilizzando semplicemente delle soglie in modo da individuare il picco causato dall'evento di tampering. In particolare possiamo monitorare l'energia media del gradiente per individuare eventi di sfocatura, e l'energia media della luma per individuare eventi di spostamento della camera. Inoltre, per rendere più robusta l'identificazione di sfocature, è possibile usare un test sequenziale sull'energia media del gradiente in grado di individuare dei cambiamenti nella varianza. Dato il *basso carico computazionale* richiesto da queste tecniche, è possibile integrarle su dispositivi embedded a basso consumo di energia. Dobbiamo fare un'ultima considerazione sullo spostamento della camera. Ci possono essere dei casi in cui l'evento è difficilmente individuabile monitorando la scena nella sua totalità. Un esempio è illustrato nella Figura 4.9, dove vediamo un caso di spostamento della camera che avviene al frame 800. Questo evento, però, non si traduce, nel segnale  $\frac{\partial l}{\partial t}$ , in un picco che si eleva rispetto agli altri, come nel caso della Figura 4.8(c). Questo problema capita perché stiamo monitorando l'energia media della luma calcolata sulla *totalità* della scena. Possiamo avere situazioni, come nel caso della Figura 4.9, in cui lo spostamento della camera non determina un cambiamento sostanziale nella luminosità media della scena.

Questo problema viene meno se consideriamo il contributo dell'energia della luma mediato non sulla totalità della scena, bensì *separatamente su regioni* specifiche. Infatti, se consideriamo un'area particolare della scena, come ad esempio quella occupata dal palazzo nella Figura 4.10(a), durante uno spostamento della camera la variazione della luma mediata solo sui pixel appartenenti a quella regione sarà più marcata rispetto a quella della luminosità mediata su tutta l'immagine. Questo ci ha suggerito di inserire una fase di *segmentazione* in cui vengono estratte le regioni della scena che



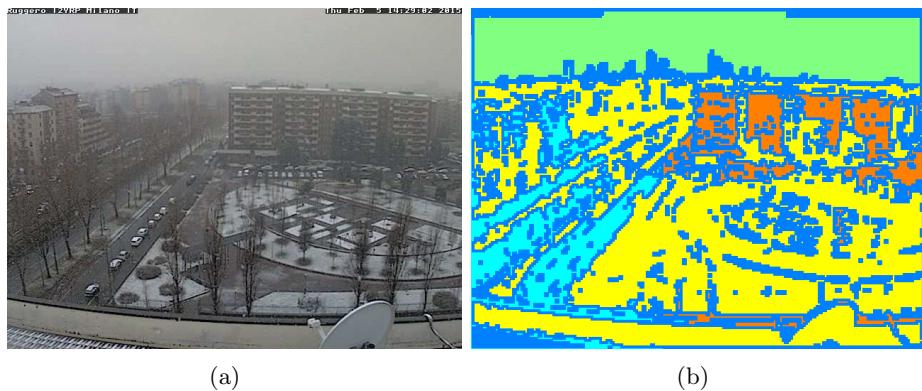
(a)



*Figura 4.9: In questo esempio vediamo il comportamento dell'energia media della luma su una sequenza di 24 ore in cui avviene un evento di spostamento della camera. In (a) sono riportati alcuni frame estratti dalla sequenza. Lo spostamento della camera avviene al frame 800 e, per il resto della sequenza, l'inquadratura rimane la stessa. In (b) vediamo il comportamento dell'indicatore  $l(t)$ , e in (c) quello del suo detrending. Notiamo come, in (c), non abbiamo un picco ben distinguibile dagli altri valori nell'istante in cui avviene lo spostamento, come nella Figura 4.8. Questo problema capita perché stiamo monitorando l'energia media della luma calcolata sulla totalità della scena.*



*Figura 4.10: Esempio di spostamento della camera*



*Figura 4.11: Esempio di segmentazione della scena*

la camera deve inquadrare. Un esempio è illustrato nella Figura 4.11. Nel Paragrafo 4.3 vedremo in dettaglio come vengono estratte le regioni dalla scena.

## 4.2 Algoritmo di identificazione di sfocature e di spostamenti della camera

In base alle considerazioni fatte nel Paragrafo 4.1 possiamo dividere l'algoritmo di tampering detection in due *thread*: il primo in grado di individuare la presenza di sfocature, il secondo lo spostamento della camera. In particolare la presenza di sfocature può essere identificata monitorando l'energia media del gradiente, descritta in (4.1), mentre l'evento di spostamento della camera può essere identificato monitorando l'energia media della luma, descritta in (4.4).

In questo paragrafo illustriamo come sono state sviluppate le due tecniche.

### 4.2.1 Identificazione delle sfocature

L’Algoritmo 1 mostra il funzionamento, ad alto livello, dell’algoritmo per identificare la presenza di sfocature nei frame. Dato che la sfocatura causa un crollo dell’energia media del gradiente e anche della sua varianza, è possibile lanciare due monitoraggi in grado di identificare ciascuno di questi cambiamenti, uno di tipo *one-shot* e l’altro di tipo *sequenziale*.

Il monitoraggio one-shot prevede un’analisi del detrending dell’energia media del gradiente separatamente per ciascuna regione estratta dall’algoritmo di segmentazione, in modo da identificare il picco dovuto al cambiamento (si veda la Figura 4.5). Facendo riferimento a (4.1) e (4.5) possiamo derivare le formule per il calcolo dell’energia media del gradiente e del suo detrending per una specifica regione  $R_k$ :

$$\begin{aligned} g^k(t) &= \mathcal{G}^k[z_t] = \frac{\sum_{R_k} \|\nabla z_t(x)\|_2^2}{|R_k|}, \\ \frac{\partial g^k}{\partial t}(t) &= g^k(t) - g^k(t-1) \end{aligned} \quad (4.7)$$

dove abbiamo indicato con  $|R_k|$  il numero totale dei pixel appartenenti alla regione  $R_k$ .

L’identificazione viene fatta attraverso la definizione di due *soglie*, calcolate facendo riferimento alle prime  $T_o$  osservazioni, ritenute prive di tampering. Tale sequenza prende il nome di *training set*. Le due soglie  $\Gamma_{min}^k$  e  $\Gamma_{max}^k$  vengono calcolate nel seguente modo:

$$\begin{aligned} \Gamma_{min}^k &= \hat{\mu}_g^k - \gamma \hat{\sigma}_g^k \\ \Gamma_{max}^k &= \hat{\mu}_g^k + \gamma \hat{\sigma}_g^k \end{aligned} \quad (4.8)$$

dove  $\hat{\mu}_g^k$  indica il valore medio delle osservazioni del training set

$$\hat{\mu}_g^k = \frac{\sum_{\tau=1}^{T_o} \frac{\partial g^k}{\partial t}(\tau)}{T_o},$$

$\hat{\sigma}_g^k$  indica la deviazione standard delle osservazioni del training set

$$\hat{\sigma}_g^k = \sqrt{\frac{1}{T_o - 1} \sum_{\tau=1}^{T_o} \left( \frac{\partial g^k}{\partial t}(\tau) - \hat{\mu}_g^k(\tau) \right)^2}$$

e  $\gamma > 1$  è un parametro moltiplicativo ottenuto sperimentalmente<sup>4</sup>.

Le soglie definite in (4.8) forniscono un limite superiore e uno inferiore ai valori di  $\{\frac{\partial g^k}{\partial t}\}$  ammissibili. Se, all’istante  $T^*$ , abbiamo che, per  $K - 1$  regioni sulle  $K$  totali, il valore di  $\frac{\partial g^k}{\partial t}(T^*)$  è maggiore di  $\Gamma_{max}^k$  o minore di  $\Gamma_{min}^k$ , allora possiamo considerare avvenuto un evento di sfocatura nel frame

---

<sup>4</sup>Per maggiori dettagli si rimanda al Capitolo 5

**Configurazione:**

1. Estraggo le regioni  $\{R_k\}, k = 1, \dots, K$
2. **for**  $t = 1, \dots, T_o$  **do**
3.   Estraggo il frame  $z_t$
4.   **for**  $k = 1, \dots, K$  **do**
5.     Calcolo  $g^k(t), \frac{\partial g^k}{\partial t}(t)$  per la regione  $R_k$
6.     **end**
7.     Calcolo  $g(t), \frac{\partial g}{\partial t}(t)$
8.     **end**
9.   **for**  $k = 1, \dots, K$  **do**
10.     Definisco le soglie  $\Gamma_{min}^k$  e  $\Gamma_{max}^k$
11.     **end**
12.   Definisco i parametri per il CDT sulla varianza di  $g(t)$

**Fase operativa:**

13. **for**  $t = T_o, \dots, \infty$  **do**
14.   Estraggo il frame  $z_t$
15.   Calcolo  $g(t), \frac{\partial g}{\partial t}(t)$
16.    $n = 0$
17.   **for**  $k = 1, \dots, K$  **do**
18.     Calcolo  $g^k(t), \frac{\partial g^k}{\partial t}(t)$  per la regione  $R_k$
19.     **if**  $\frac{\partial g^k}{\partial t}(t) < \Gamma_{min}^k \vee \frac{\partial g^k}{\partial t}(t) > \Gamma_{max}^k$  **then**
20.        $n = n + 1$
21.     **end**
22.   **end**
23.   **if** CDT identifica un cambiamento in  $g(t)$  **then**
24.      $z_t$  è un frame in cui è avvenuta una sfocatura
25.   **end**
26. **end**

**Algoritmo 1:** Algoritmo di identificazione di sfocature

$\tilde{z}_{T^*}$ .

Oltre all'analisi sul detrending è possibile fare un monitoraggio sequenziale sulla varianza di  $\{g(t)\}$ : infatti, come abbiamo visto nel Paragrafo 4.1.3, la presenza di una sfocatura comporta una diminuzione della varianza di questa sequenza. Il monitoraggio sequenziale viene fatto utilizzando un CDT basato su ICI-rule<sup>5</sup> sulla varianza di  $\{g(t)\}$ , usando il training set per configurare i suoi parametri.

#### 4.2.2 Identificazione degli spostamenti della camera

L'Algoritmo 2 mostra il funzionamento, ad alto livello, dell'algoritmo per identificare un evento di spostamento della camera.

Una prima fase dell'algoritmo consiste nella *segmentazione* della scena inquadrata dalla camera in un insieme di regioni  $\{R_k\}, k = 1, \dots, K$ . Il metodo con cui vengono estratte queste regioni verrà analizzato in dettaglio nel paragrafo 4.3.

L'analisi che viene fatta è simile a quella vista nel monitoraggio del detrending dell'energia del gradiente: in questo caso l'analisi è fatta in maniera indipendente per ciascuna regione  $R_k$ , calcolando l'energia della luma *mediata per i pixel appartenenti alla regione*:

$$\begin{aligned} l^k(t) &= \mathcal{L}^k[z_t] = \frac{\sum_{R_k} z_t(x)}{|R_k|}, \\ \frac{\partial l^k}{\partial t}(t) &= l^k(t) - l^k(t-1) \end{aligned} \quad (4.9)$$

dove abbiamo indicato con  $|R_k|$  il numero totale dei pixel appartenenti alla regione  $R_k$ .

L'identificazione viene fatta attraverso la definizione di due *soglie*, calcolate facendo riferimento alle prime  $T_o$  osservazioni, ritenute prive di tampering. Le due soglie  $\Gamma_{min}^k$  e  $\Gamma_{max}^k$  vengono calcolate per ciascuna regione nel seguente modo:

$$\begin{aligned} \Gamma_{min}^k &= \hat{\mu}_l^k - \gamma \hat{\sigma}_l^k, \\ \Gamma_{max}^k &= \hat{\mu}_l^k + \gamma \hat{\sigma}_l^k, \end{aligned} \quad (4.10)$$

dove  $\hat{\mu}_l^k$  indica il valore medio delle osservazioni del training set

$$\hat{\mu}_l^k = \frac{\sum_{\tau=1}^{T_o} \frac{\partial l^k}{\partial t}(\tau)}{T_o},$$

$\hat{\sigma}_l^k$  indica la deviazione standard delle osservazioni del training set

$$\hat{\sigma}_l^k = \sqrt{\frac{1}{T_o - 1} \sum_{\tau=1}^{T_o} \left( \frac{\partial l^k}{\partial t}(\tau) - \hat{\mu}_l^k(\tau) \right)^2}$$

---

<sup>5</sup>Lo schema di funzionamento del CDT basato su ICI-rule è spiegato nel Paragrafo 2.3.

e  $\gamma > 1$  è un parametro moltiplicativo ottenuto sperimentalmente.

Le soglie definite nella Formula (4.10) forniscono un limite superiore e uno inferiore ai valori di  $\{\frac{\partial l^k}{\partial t}\}$  ammissibili.

Dato che l'evento di spostamento della camera viene inteso come un cambiamento globale dell'immagine, ci aspettiamo che tale cambiamento sia percepibile in tutte le regioni contemporaneamente. Nella pratica, però, può capitare che l'energia media della luma all'interno di una specifica regione non cambi, anche in caso di spostamento della camera. Se consideriamo, ad esempio, l'evento di spostamento nella Figura 4.9 e la segmentazione della scena in Figura 4.11(b), infatti, possiamo notare come la luma nella regione del cielo non subisca cambiamenti sostanziali dato che, anche in seguito all'evento di tampering, questa regione riprende sempre una porzione di cielo. In generale, quindi, possiamo considerare un monitoraggio indipendente di ogni sequenza  $\{\frac{\partial l^k}{\partial t}\}$  per  $k = 1, \dots, K$ . Se, all'istante  $T^*$ , abbiamo che, per  $K - 1$  regioni sulle  $K$  totali, il valore di  $\frac{\partial l^k}{\partial t}(T^*)$  è maggiore di  $\Gamma_{max}^k$  o minore di  $\Gamma_{min}^k$ , allora possiamo considerare avvenuto un evento di sfocatura nel frame  $z_{T^*}$ .

Dato che l'evento di spostamento della camera, in genere, non comporta un cambiamento persistente nella varianza dell'energia media della luma, non ha senso aggiungere un monitoraggio sequenziale come abbiamo fatto nell'Algoritmo 1.

### 4.3 Algoritmo di segmentazione

In molte applicazioni di visione artificiale è spesso necessario estrarre, da un'immagine o un video, una o più regioni specifiche. Quando si vanno a trattare dei video, i tipi di segmentazione che possono essere applicati sono solitamente due:

- una segmentazione di tipo *spaziale*, in cui vengono estratti dei pixel specifici per ogni frame costituente il video;
- una segmentazione di tipo *temporale*, in cui vengono estratti dei frame significativi (*key-frames*).

Segmentazioni di tipo spaziale permettono, ad esempio, di seguire il movimento di uno specifico oggetto all'interno della scena ripresa [33, 34], oppure di identificare un particolare evento all'interno di una scena [35]. Alcuni standard video, come ad esempio l'MPEG-4, utilizzano una codifica *object-based* in cui viene utilizzata una segmentazione spaziale dei frame [36]. Segmentazioni di tipo temporale, invece, permettono di dividere un filmato in *sottosequenze* oppure di creare una sintesi del video con dei frame significativi. In quest'ultimo caso si parla di *key-frames extraction* o di *video summarization* [37, 38, 39, 40]. Quando si vanno a trattare immagini

**Configurazione:**

1. Estrago le regioni  $\{R_k\}, k = 1, \dots, K$
2. **for**  $t = 1, \dots, T_o$  **do**
3.   Estrago il frame  $z_t$
4.   **for**  $k = 1, \dots, K$  **do**
5.     Calcolo  $l^k(t)$ ,  $\frac{\partial l^k}{\partial t}(t)$  per la regione  $R_k$
6.     **end**
7.   **end**
8.   **for**  $k = 1, \dots, K$  **do**
9.     Definisco le soglie  $\Gamma_{min}^k$  e  $\Gamma_{max}^k$
10.   **end**

**Fase operativa:**

11.   **for**  $t = T_o, \dots, \infty$  **do**
12.     Estrago il frame  $z_t$
13.      $n = 0$
14.     **for**  $k = 1, \dots, K$  **do**
15.       Calcolo  $l^k(t)$ ,  $\frac{\partial l^k}{\partial t}(t)$  per la regione  $R_k$
16.       **if**  $\frac{\partial l^k}{\partial t}(t) < \Gamma_{min}^k \vee \frac{\partial l^k}{\partial t}(t) > \Gamma_{max}^k$  **then**
17.          $n = n + 1$
18.       **end**
19.     **end**
20.     **if**  $n \geq K - 1$  **then**
21.        $| z_t$  è un frame in cui è avvenuto uno spostamento della camera
22.       **end**
23.     **end**

**Algoritmo 2:** Algoritmo di identificazione di spostamenti della camera

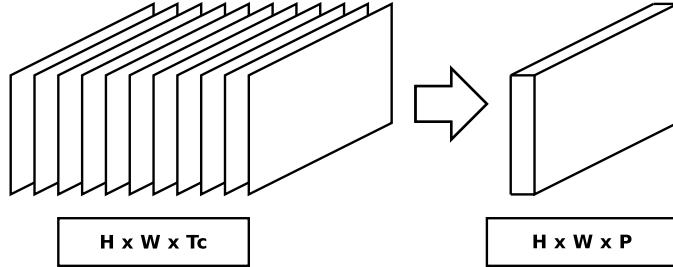


Figura 4.12: Passaggio dallo spazio dei frame allo spazio dei feature vector

la segmentazione è di tipo spaziale.

Considerando la segmentazione di tipo spaziale, una soluzione molto diretta consiste nell'utilizzare dei descrittori per ciascun pixel e applicare delle tecniche di *clustering*, ovvero delle metodologie atte a partizionare un insieme di dati [41], sugli stessi.

Nel Paragrafo 4.1.3 abbiamo introdotto il fatto di utilizzare una segmentazione in regioni della scena ripresa dalla camera, in modo da rendere più efficiente l'identificazione di spostamenti della camera. Vediamo ora il modo in cui questa segmentazione viene fatta.

Durante la fase di estrazione delle regioni acquisiamo un certo numero di frame in cui non avviene nessun evento di tampering. Da questi frame estraiamo un vettore descrittore (*feature vector*) per ciascun pixel della scena inquadrata. Passiamo, quindi, da una matrice di dimensioni  $H \times W \times T_c$ , dove  $H$  e  $W$  sono le dimensioni in pixel dell'immagine acquisita dalla camera e  $T_c$  è il numero di frame usato per la creazione della segmentazione, a una matrice di dimensioni  $H \times W \times P$ , dove  $P$  è il numero di descrittori calcolati per fare la segmentazione.

Una volta ottenuta la matrice, vengono raggruppati i pixel aventi feature vector simili tramite tecniche di *clustering*.

La fase di segmentazione della scena in regioni avviene durante la configurazione del sistema, separatamente rispetto alla fase di identificazione degli eventi di tampering. La segmentazione, quindi, non comporta ulteriore costo computazionale all'algoritmo, in cui viene considerata semplicemente come una variabile d'ingresso. Inoltre, la segmentazione può essere eseguita *offline* su un dispositivo esterno.

#### 4.3.1 Calcolo dei descrittori utilizzati per la segmentazione

Consideriamo la sequenza  $\{z_t\}$  di frame acquisiti dalla camera, con  $t = 1, \dots, T_c$ . Per ciascun pixel  $x \in \mathcal{X}$  calcoliamo un vettore  $\mathbf{d}(x)$  di 5 elementi

$$\mathbf{d}(x) = [r(x); c(x); \mu_\nabla(x); \sigma_\nabla(x); \bar{z}(x)], \mathbf{d}(x) \in \mathbb{R}^5 \quad (4.11)$$

dove:

- $r(x)$  rappresenta il numero di riga del pixel  $x$ .
- $c(x)$  rappresenta il numero di colonna del pixel  $x$ .
- $\mu_\nabla(x)$  rappresenta il valore del gradiente nel pixel  $x$  mediato nel tempo:

$$\mu_\nabla(x) = \frac{\sum_{t=1}^{T_c} (\|\nabla z_t\|_2^2 \circledast f)(x)}{T_c}, \quad (4.12)$$

dove abbiamo indicato con  $\|\nabla z_t\|_2^2$  la norma del gradiente per l'immagine  $z_t$ , definita in (4.3), e con  $f$  il filtro gaussiano discreto derivato dal campionamento di (4.2).

- $\sigma_\nabla(x)$  rappresenta la deviazione standard nel tempo del gradiente nel pixel  $x$ :

$$\sigma_\nabla(x) = \sqrt{\frac{1}{T_c - 1} \sum_{t=1}^{T_c} ((\|\nabla z_t\|_2^2 \circledast f)(x) - \mu_\nabla(x))^2}. \quad (4.13)$$

- $\bar{z}(x)$  rappresenta il valore della luma del pixel  $x$  mediato nel tempo:

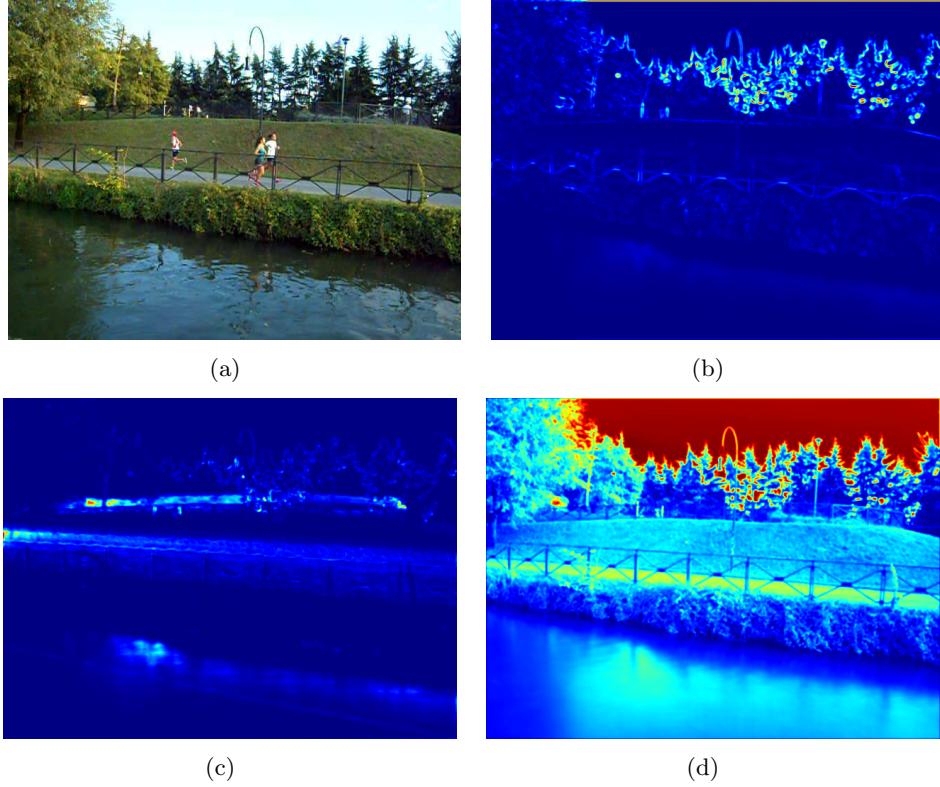
$$\bar{z}(x) = \frac{\sum_{t=1}^{T_c} (z_t \circledast f)(x)}{T_c}. \quad (4.14)$$

Come possiamo vedere in (4.12), (4.13) e (4.14), nel calcolo degli indicatori viene fatta una convoluzione con un filtro gaussiano. Questo è equivalente a mediare il contributo di  $\|\nabla z_t\|_2^2$  e di  $z_t$  in un *intorno spaziale*.

Nella Figura 4.13 possiamo vedere un esempio di come si comportano questi indicatori su una specifica scena (Figura 4.13(a)). Il loro utilizzo permette di avere un'informazione completa sul comportamento dei pixel durante la ripresa della scena e il loro rapporto con i pixel appartenenti al suo intorno, definito dal filtro gaussiano  $f$ .

In particolare, l'indicatore  $\mu_\nabla(x)$  mette in relazione il valore di luma del pixel  $x$  con quelli nel suo intorno, definito dal filtro  $f$ . Valori alti di  $\mu_\nabla(x)$  corrispondono a zone della scena con molti dettagli (*textured*), mentre valori bassi corrispondono a zone della scena poco dettagliate (*flat*). Ad esempio, nella Figura 4.13(b) possiamo vedere come i valori più alti di  $\mu_\nabla(x)$  corrispondano alle zone dove le variazioni di luma sono più elevate (ad esempio nelle aree di contorno tra le foglie degli alberi e il cielo).

L'indicatore  $\sigma_\nabla(x)$ , invece, ci fornisce un'informazione riguardo all'evoluzione di ciascun pixel nel tempo. Valori alti di  $\sigma_\nabla(x)$  corrisponderanno a pixel appartenenti a zone *dinamiche* della scena, mentre valori bassi dell'indicatore corrisponderanno a pixel appartenenti a zone *statiche*. Nell'esempio in Figura 4.13(c) possiamo vedere come i valori più alti dell'indicatore corrispondano alle zone dove passano i pedoni e i ciclisti.



*Figura 4.13: Esempio grafico di come si comportano i descrittori utilizzati per la segmentazione di una specifica scena. La scena di esempio è rappresentata in (a). In (b), dove sono illustrati i valori di  $\mu_\nabla(x)$  per ciascun pixel, possiamo vedere come i valori più alti siano in prossimità delle zone più dettagliate, come per esempio il contorno tra le foglie e il cielo. In (c), invece, vediamo i valori di  $\sigma_\nabla(x)$  per ciascun pixel. Possiamo notare come i valori più alti del descrittore siano in prossimità delle zone a maggior dinamicità, come ad esempio la zona dove passano le persone. In (d), infine, mostriamo i valori di  $\bar{z}(x)$  per ciascun pixel.*

L’indicatore  $\bar{z}$  (Figura 4.13(d)) ci fornisce un’indicazione su come è distribuita mediamente, su un intorno spaziale, la luminosità nella scena.

L’utilizzo delle coordinate spaziali, infine, permette di avere un’informazione sulla posizione del pixel all’interno della scena.

#### 4.3.2 Partizionamento dei feature vector per l’estrazione delle regioni

Una volta calcolati i feature vector di tutti i pixel, possiamo raggrupparli tra loro usando un algoritmo di *clustering*. In realtà, per alleggerire il peso computazionale nella fase di segmentazione, possiamo fare un *sottocampionamento* dei feature vector totali. Come abbiamo visto nel Paragrafo 4.3.1, infatti, ciascun feature vector è associato non al singolo pixel, ma a un in-

torno del pixel definito dal filtro gaussiano  $f$ . Possiamo, quindi, dividere la scena totale in *blocchi*, le cui dimensioni sono paragonabili a quelle del filtro  $f$ , e prendere il feature vector del pixel centrale di ciascun blocco.

Per partizionare i feature vector selezionati, abbiamo deciso di utilizzare l'algoritmo di clustering *k-means* [41, 42], che permette di partizionare un insieme di dati in  $K$  sottoinsiemi (*cluster*). L'algoritmo, nella sua forma più semplice, riceve in ingresso un insieme  $\mathcal{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$  di  $N$  dati da partizionare e il numero  $K$  di partizioni (cluster)  $\{C_i\}, i = 1, \dots, K$  che si vuole creare. Per semplicità consideriamo ciascun dato come un vettore  $\mathbf{d}(\mathbf{x})$  di  $P$  elementi,  $\mathbf{d}(\mathbf{x}) \in \mathbb{R}^P, \mathbf{x} \in \mathcal{X}$ .

Come prima cosa vengono creati i *centroidi*  $\{\mathbf{c}_i\}, i = 1, \dots, K, \mathbf{c}_i \in \mathbb{R}^P$  associati ai cluster  $\{C_i\}, i = 1, \dots, K$ . Nella versione più semplice dell'algoritmo essi vengono scelti in maniera casuale dai dati appartenenti a  $\mathcal{X}$ . Una tecnica più raffinata è data dall'algoritmo *k-means++* [43], che permette di distribuire meglio i centroidi su tutto lo spazio dei dati. In particolare, k-means++ sceglie il primo centroide  $\mathbf{c}_1$  in maniera casuale da  $\mathcal{X}$  con distribuzione probabilistica uniforme. I successivi centroidi vengono scelti iterativamente prendendo  $\mathbf{c}_i = \mathbf{x}' \in \mathcal{X}$  con probabilità  $\frac{D(\mathbf{x}')^2}{\sum_{\mathbf{x} \in \mathcal{X}} D(\mathbf{x})^2}$ , dove  $D(\mathbf{x})$  indica la minima distanza di  $\mathbf{x}$  dal centroide più vicino tra quelli già calcolati.

Una volta ottenuti i centroidi vengono calcolate le *distanze euclidi* di ciascun dato da ogni centroide:

$$\text{dist}(\mathbf{d}(\mathbf{x}), \mathbf{c}_i) = (\mathbf{d}(\mathbf{x}) - \mathbf{c}_i)^T \cdot (\mathbf{d}(\mathbf{x}) - \mathbf{c}_i).$$

Ciascun dato  $\mathbf{d}(\mathbf{x})$ , quindi, viene associato al cluster con centroide  $\mathbf{c}^*(\mathbf{x})$  con distanza *minima* da esso:

$$\mathbf{c}^*(\mathbf{x}) = \underset{\mathbf{c}_i}{\operatorname{argmin}} \text{dist}(\mathbf{d}(\mathbf{x}), \mathbf{c}_i).$$

Una volta associato ciascun dato al cluster più vicino, vengono aggiornati i centroidi di ciascun cluster in base ai loro elementi:

$$\mathbf{c}_i = \frac{\sum_{\mathbf{x} \in C_i} \mathbf{x}}{|C_i|}$$

La procedura viene ripetuta con la nuova assegnazione dei centroidi. L'algoritmo viene richiamato fino a quando non si raggiunge la *convergenza*, ovvero il momento in cui la posizione dei centroidi non cambia più.

Per utilizzare questa tecnica nel nostro algoritmo di segmentazione abbiamo dovuto considerare alcune evoluzioni del k-means rispetto alla sua versione originale, in modo da risolvere i seguenti problemi.

Il primo problema, utilizzando la versione base del k-means, è quello di determinare il numero di cluster da creare. Per valutare in maniera automatica il numero di cluster ottimale per ciascun insieme di dati abbiamo utilizzato

il *criterio di Calinski-Harabasz*[44], che consiste nel provare l'algoritmo di k-means per un insieme di valori  $k = K_{min}, \dots, K_{max}$ . Per ciascun  $k$  utilizzato viene calcolata una cifra di merito chiamata *variance ratio criterion* (VRC):

$$VRC_k = \frac{SS_B}{SS_W} \times \frac{N - k}{k - 1},$$

dove  $SS_B$  rappresenta la *varianza totale tra cluster* (*overall between-cluster variance*):

$$SS_B = \sum_{i=1}^k |C_i| \| \mathbf{c}_i - \bar{\mathbf{d}} \|^2,$$

con  $|C_i|$  che rappresenta il numero di dati appartenenti al cluster  $C_i$  e  $\bar{\mathbf{d}}$  che rappresenta il valore medio di tutti i dati:

$$\bar{\mathbf{d}} = \frac{\sum_{\mathbf{x} \in \mathcal{X}} \mathbf{x}}{|\mathcal{X}|}.$$

$SS_W$ , invece, rappresenta il grado di dispersione medio di ciascun cluster (*overall within-cluster variance*):

$$SS_W = \sum_{i=1}^k \sum_{\mathbf{x} \in C_i} \| \mathbf{d}(\mathbf{x}) - \mathbf{c}_i \|^2.$$

Viene scelto, infine, il valore  $k$  con il valore  $VRC_k$  più alto:

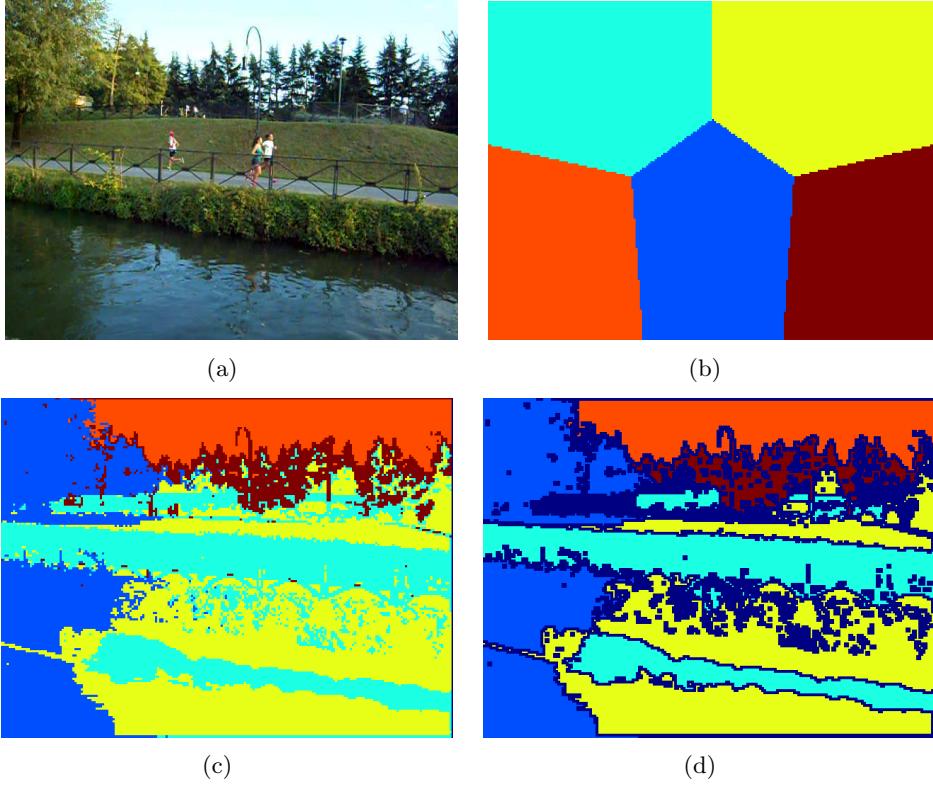
$$K^* = \operatorname{argmax}_k VRC_k.$$

Un altro problema è dato dal peso che ha ciascun elemento dei dati durante la segmentazione. Nel nostro caso, ad esempio, i valori delle coordinate possiedono una varianza talmente elevata rispetto a quella degli altri elementi, che il loro contributo domina quello delle altre componenti, come possiamo vedere nell'esempio in Figura 4.14(b). Per risolvere il problema abbiamo utilizzato, quindi una variante *pesata* del k-means [34], in cui il calcolo delle distanze di ciascun dato da ogni centroide viene modificato associando un *peso* a ciascuna componente:

$$\text{dist}_w(\mathbf{d}(\mathbf{x}), \mathbf{c}_i) = (\mathbf{d}(\mathbf{x}) - \mathbf{c}_i)^T W^i (\mathbf{d}(\mathbf{x}) - \mathbf{c}_i),$$

dove  $W^i$  è una matrice di pesi associata a ciascun cluster  $C_i$ :

$$W^i = \begin{bmatrix} w_1^i & 0 & 0 & 0 & 0 \\ 0 & w_2^i & 0 & 0 & 0 \\ 0 & 0 & w_3^i & 0 & 0 \\ 0 & 0 & 0 & w_4^i & 0 \\ 0 & 0 & 0 & 0 & w_5^i \end{bmatrix},$$



*Figura 4.14: Un esempio di segmentazione di una particolare scena. La scena di esempio è rappresentata in (a). Possiamo vedere in (b) il risultato della segmentazione utilizzando l'algoritmo di k-means nella sua versione originale, dove l'unico contributo è dato dalle coordinate dei pixel. Il risultato ottenuto utilizzando l'algoritmo di k-means pesato è illustrato invece in (c), dove possiamo vedere come la segmentazione sia legata a particolari regioni della scena. Infine, in (d) possiamo vedere il risultato finale della segmentazione, che consiste nella separazione delle regioni e nell'eliminazione delle aree più piccole.*

dove  $w_s^i$  corrisponde al peso dato all'elemento  $s$  del feature vector associato al cluster  $C_i$ :

$$w_s^i = \frac{(\sigma_1^i \cdot \sigma_2^i \cdot \sigma_3^i \cdot \sigma_4^i \cdot \sigma_5^i)^{1/5}}{\sigma_s^i}, s = 1, \dots, 5,$$

dove  $\sigma_s^i$  rappresenta la deviazione standard dell'elemento  $s$  dei dati appartenenti al cluster  $C_i$ .

### 4.3.3 Separazione e rifinitura delle regioni

L'algoritmo di clustering utilizzato produce un partizionamento della scena ripresa dalla camera come quello in Figura 4.14(c). Come possiamo vedere

le regioni estratte dal nostro algoritmo sono legate a particolari aree presenti nella scena, in base alla loro dinamicità, alla presenza di dettagli e all'intensità media della luma.

La fase finale della segmentazione consiste nell'eliminare le regioni più piccole e separare quelle rimanenti per mezzo di *operatori morfologici*.

La prima operazione che facciamo consiste nel separare le varie regioni tra di loro utilizzando l'operatore morfologico di *erosione*. Dato che l'operatore funziona su immagini *binarie* creiamo, per ciascun cluster, una *maschera binaria*:

$$M_i(x) = \begin{cases} 1 & \text{se } x \in C_i \\ 0 & \text{se } x \notin C_i \end{cases}, \forall x \in \mathcal{X}.$$

L'operatore morfologico di erosione esegue un filtraggio non lineare che rimpiazza il valore di ciascun pixel della maschera  $M_i$  con il valore minimo tra quelli presenti in un suo intorno.

$$E_i(x) = \begin{cases} 1 & \text{se } \forall \xi \in U_x \quad M_i(\xi) = 1 \\ 0 & \text{se } \exists \xi \in U_x \quad M_i(\xi) = 0 \end{cases}, \forall x \in \mathcal{X},$$

dove abbiamo indicato con  $U_x$  l'intorno del pixel  $x$ . Il risultato di questo operatore è quello di ridurre i bordi degli elementi posti a 1 delle immagini binarie.

L'immagine binaria  $E_i$  conterrà al suo interno un certo numero di *regioni connesse*. Le regioni più piccole, ovvero quelle il cui numero di pixel è inferiore allo 0,01% dei pixel totali, vengono eliminate ponendo a 0 il valore dei loro pixel. Una volta eseguite queste operazioni su tutte le maschere  $M_i$ , i risultati finali vengono composti assieme in una nuova immagine:

$$S(x) = \begin{cases} i & \text{se } x \in E_i, \quad i = 1, \dots, K \\ 0 & \text{altrimenti} \end{cases}, \forall x \in \mathcal{X}.$$

Infine eliminiamo i cluster più piccoli, ovvero quelli il cui numero di pixel è inferiore al 2% dei pixel totali. Il risultato finale è quello mostrato in Figura 4.14(d), dove le zone colorate in blu scuro rappresentano le aree che non vengono appartengono ad alcun cluster. Queste zone, durante l'esecuzione dell'algoritmo di identificazione di spostamenti della camera, non verranno considerate nel calcolo dell'energia media della luma.

## Capitolo 5

# Prove sperimentali e valutazione

In questo capitolo illustriamo il procedimento attraverso il quale sono stati condotti gli esperimenti per la valutazione della soluzione proposta e i risultati ottenuti.

Il Paragrafo 5.1 è dedicato alla descrizione dei metodi considerati durante gli esperimenti e i loro obiettivi.

Il Paragrafo 5.2 è dedicato alla descrizione dei dataset utilizzati e dei sistemi di acquisizione realizzati per la loro acquisizione.

Il Paragrafo 5.3 descrive le metriche utilizzate per valutare le prestazioni del nostro algoritmo.

I Paragrafi 5.4 e 5.5, infine, descrivono i risultati delle prove sperimentali.

### 5.1 Metodi considerati e obiettivi

Nel Capitolo 4 abbiamo illustrato gli algoritmi proposti per la soluzione al problema del tampering detection. In particolare, abbiamo visto come l'evento di sfocatura possa essere identificato attraverso un'analisi *one-shot* del detrending dell'energia media del gradiente, utilizzando due soglie in modo da identificare un *outlier*, e un monitoraggio *sequenziale* sulla varianza dell'energia media del gradiente. Abbiamo visto, infine, come l'evento di spostamento della camera possa essere identificato tramite una segmentazione in regioni della scena ripresa e un monitoraggio one-shot per ciascuna regione in maniera indipendente.

Per validare queste nostre scelte abbiamo implementato l'algoritmo in MATLAB [45], un ambiente per il calcolo numerico e l'analisi statistica, che dispone di numerose librerie per l'elaborazione di segnali e immagini. Abbiamo condotto, quindi, alcuni esperimenti, in modo da ricavare delle cifre di merito in grado di esprimere le performance delle varie tecniche utilizzate. Per quanto riguarda l'identificazione di spostamenti della camera abbiamo

confrontato la nostra soluzione con altri approcci. I metodi che abbiamo confrontato sono:

- il nostro metodo di valutazione dell'energia media della luma sulle regioni estratte (Algoritmo 2);
- analisi dell'energia media della luma sulla *totalità* della scena;
- analisi dell'energia media del *frame difference*  $\varphi(t)$  di ciascun frame,

$$\varphi(t) = \frac{\sum_{x \in \mathcal{X}} (z_t(x) - z_{t-1}(x))^2}{|\mathcal{X}|}, \quad (5.1)$$

usando sempre una tecnica one-shot per identificare lo spostamento della camera;

- analisi del frame difference per ciascuna regione estratta dall'algoritmo di segmentazione:

$$\varphi_k(t) = \frac{\sum_{x \in R_k} (z_t(x) - z_{t-1}(x))^2}{|R_k|}, k = 1, \dots, K. \quad (5.2)$$

La scelta di fare un confronto con il frame difference è giustificata dal fatto che essa può essere considerata come la soluzione più immediata al problema dell'identificazione dello spostamento della camera, nel caso di scenario ad alto framerate. Le quattro tecniche sono state confrontate tra loro generando delle *Receiver Operator Characteristic Curve* (ROC curve) al variare delle soglie utilizzate per identificare l'evento. Il modo in cui queste curve sono realizzate è illustrato nel Paragrafo 5.3.1.

Per quanto riguarda l'identificazione degli eventi di sfocatura, invece, abbiamo analizzato separatamente la tecnica one-shot e quella sequenziale.

Nel caso della tecnica one-shot abbiamo confrontato due metodologie differenti:

- la nostra scelta di considerare, nel calcolo dell'energia media del gradiente, la totalità della scena ripresa;
- l'analisi dell'energia media del gradiente per ciascuna regione estratta dall'algoritmo di segmentazione.

Per l'analisi sequenziale abbiamo valutato le performance del change detection test al variare dell'intensità della sfocatura.

## 5.2 Acquisizione dei dataset

Durante lo svolgimento della tesi abbiamo acquisito diversi dataset video, in modo da poter testare le soluzioni proposte per l'identificazione di eventi



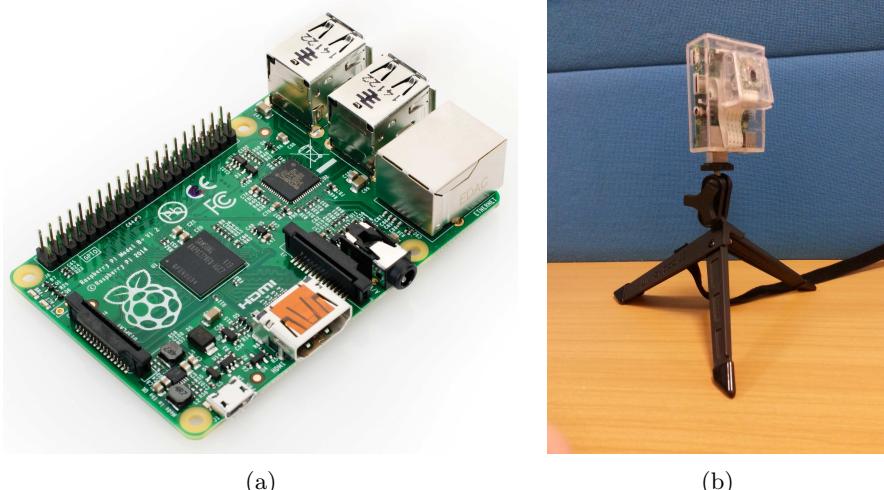
Figura 5.1: Camera digitale usata per le acquisizioni

di tampering e l'impatto della segmentazione sulle sue performance.

Un primo dataset è stato acquisito utilizzando una consumer camera *Nikon Coolpix S570* [46] (Figura 5.1), in grado di registrare video. Questo primo insieme è stato utilizzato durante la realizzazione dell'algoritmo di segmentazione, ed è costituito da scene riprese all'aperto con un framerate continuo (30 fps). Ciascun video è costituito da un minuto di ripresa (1800 frame), e ciò rende questo dataset inutilizzabile per validare le scelte fatte per l'algoritmo di tampering detection.

Per validare il nostro algoritmo, infatti, è necessario che le sequenze utilizzate comprendano un elevato numero di frame acquisiti con framerate bassi, ad esempio un'immagine ogni minuto. Dato che la consumer camera non permette di variare il framerate, abbiamo utilizzato un secondo sistema di acquisizione basato su un *Raspberry Pi modello B+* [47] con relativo *modulo camera* [48], in cui è possibile variare la frequenza di acquisizione dei frame a piacimento. Il Raspberry Pi (Fig. 5.2(a)) è un *single-board computer* (ovvero un computer implementato su una singola scheda elettronica) basato su un *system-on-chip* (SoC) *Broadcom BCM2835* [49], che incorpora un processore *ARM1176JZF-S* [50], una GPU *VideoCore IV* [51] e 512 MB di memoria. Utilizza un sistema operativo *Debian Linux* realizzato per processori ARM chiamato *Raspbian* [52].

Il modulo camera permette di acquisire immagini a diverse risoluzioni e a diverso framerate, fornendo inoltre la possibilità di salvarle in vari formati. Il sistema realizzato è illustrato nella Figura 5.2(b). Le ridotte dimensioni e il basso consumo di potenza del sistema hanno permesso il suo utilizzo per fare le acquisizioni in ambienti esterni, utilizzando una batteria per alimentare il tutto. Per interfacciarsi con il dispositivo abbiamo creato una connessione *SSH*, tramite USB, con uno smartphone: in questo modo ab-



*Figura 5.2: Il Raspberry Pi (a) e il sistema di acquisizione basato su di esso (b)*

biamo potuto lanciare i comandi necessari per far partire l’acquisizione. Per l’acquisizione abbiamo creato uno script in *Python*, utilizzando la libreria *picamera* [53] per interfacciarsi con il modulo camera.

Abbiamo acquisito, infine, un terzo dataset utilizzando il sito *ilMeteo.it* [54]. Questo portale di previsioni del tempo fornisce l’accesso ai frame acquisiti dalle webcam presenti in varie città e in varie località turistiche. A ciascuna webcam è associato un unico URL, in cui è presente un’immagine in formato *jpeg* rappresentante il frame corrente acquisito dalla camera. Queste webcam, in genere, acquisiscono un frame ogni minuto, e ciò ha permesso di utilizzarle come caso d’uso reale.

Attraverso uno script in Python e il tool *curl* [55], che permette il trasferimento di dati da indirizzi URL, abbiamo creato delle sequenze di frame che coprono un arco di 24 ore ciascuna, con frame acquisiti ogni minuto. In questo modo abbiamo potuto valutare il comportamento degli indicatori in condizioni di framerate basso e su lunghi periodi.

### 5.2.1 Eventi di tampering

Per testare i nostri algoritmi, abbiamo dovuto creare degli eventi in cui venisse compromessa l’acquisizione corretta della scena ripresa. Nel caso del dataset acquisito con il Raspberry Pi abbiamo potuto introdurre degli eventi di tampering *reali*, ad esempio spostando la camera durante la ripresa, oppure buttando dell’acqua o spruzzando del deodorante spray sull’obiettivo della camera, in modo da creare la sfocatura.

Nel caso dei frame presi dalle webcam su internet abbiamo dovuto creare degli eventi di tampering in maniera *sintetica*. La sfocatura è stata introdotta

utilizzando delle convoluzioni con filtri *gaussiani* di varie dimensioni,

$$z_t(x) = \begin{cases} z_t(x) & \text{per } t = 1, \dots, T^* - 1 \\ (z_t \otimes f)(x) & \text{per } t > T^* \end{cases}, \forall x \in \mathcal{X}, \quad (5.3)$$

dove  $f$  è ottenuto tramite un campionamento della *funzione gaussiana*  $h$ , con media 0 e deviazione standard  $\sigma$ , descritta in (4.2). Per creare sfocature di intensità differente abbiamo utilizzato filtri gaussiani di dimensioni varie e deviazioni standard  $\sigma$  differenti.

Lo spostamento della camera, invece, è stato simulato concatenando sequenze di frame differenti.

### 5.2.2 Definizione dei ground truth

Per valutare le prestazioni del nostro metodo, abbiamo dovuto definire un *ground truth* (GT) per ciascuna sequenza video, in modo da poter disporre di alcune metriche per poter confrontare i risultati ottenuti.

Dato che il nostro algoritmo identifica gli istanti in cui un evento di tampering inizia, nel GT di ciascuna sequenza sarà presente il numero del frame in cui questo evento inizia effettivamente. In particolare avremo un'indicazione del frame in cui avviene una sfocatura (se presente) e un'indicazione del frame in cui avviene lo spostamento della camera (se presente). Ricordiamo, inoltre, che nella nostra analisi stiamo considerando che il passaggio da una situazione prima di tampering a una con tampering come un evento *istantaneo*.

## 5.3 Figure di merito

Grazie all'informazione presente nel GT siamo in grado, una volta che viene lanciato l'algoritmo di tampering detection, di definire quando il risultato è corretto e quando no. Combinando assieme i risultati ottenuti possiamo ricavare delle cifre di riferimento che ci permettano di valutare le prestazioni del nostro algoritmo.

### 5.3.1 Creazione delle ROC curve per il monitoraggio one-shot

Le ROC curve forniscono un metodo grafico per la valutazione della qualità delle tecniche di monitoraggio one-shot che vogliamo confrontare.

Per la loro costruzione, come prima cosa, è necessario valutare alcuni indicatori. Come abbiamo visto nel Paragrafo 4.2, dato un generico descrittore  $\xi(t)$  e il suo detrending  $\frac{\partial \xi}{\partial t}(t)$ , il monitoraggio one-shot che viene fatto sul detrending utilizza due soglie  $\Gamma_{min}^\xi$  e  $\Gamma_{max}^\xi$ , definite come:

$$\begin{aligned} \Gamma_{min}^\xi &= \hat{\mu}_\xi - \gamma \hat{\sigma}_\xi, \\ \Gamma_{max}^\xi &= \hat{\mu}_\xi + \gamma \hat{\sigma}_\xi, \end{aligned} \quad (5.4)$$

dove  $\hat{\mu}_\xi$  indica il valore medio delle osservazioni del training set

$$\hat{\mu}_\xi = \frac{\sum_{\tau=1}^{T_o} \frac{\partial \xi}{\partial t}(\tau)}{T_o},$$

$\hat{\sigma}_\xi$  indica la deviazione standard delle osservazioni del training set

$$\hat{\sigma}_\xi = \sqrt{\frac{1}{T_o - 1} \sum_{\tau=1}^{T_o} \left( \frac{\partial \xi}{\partial t}(\tau) - \hat{\mu}_\xi(\tau) \right)^2}$$

e  $\gamma > 1$  è un parametro moltiplicativo.

Fissato un valore di  $\gamma$ , una volta che abbiamo lanciato il monitoraggio per un consistente numero di sequenze di frame con eventi di tampering, quello che andiamo a controllare è:

- il numero totale di **true positive** (TP), ovvero le identificazioni avvenute correttamente;
- il numero totale di **true negative** (TN), ovvero il numero di frame che, giustamente, non vengono identificati dall'algoritmo;
- il numero totale di **false positive** (FP), ovvero il numero di frame che vengono identificati dall'algoritmo ma che non corrispondono a un evento di inizio di tampering;
- il numero totale di **false negative** (FN), ovvero il numero di eventi di inizio tampering che non vengono individuati dall'algoritmo.

Queste cifre di merito vengono calcolate per diversi valori del parametro  $\gamma$ , utilizzato per la definizione delle soglie in (5.4). Una volta trovati tutti i valori possiamo realizzare un grafico, dove:

- Sull'asse delle ascisse mettiamo il valore *1-SPECIFICITY* al variare di  $\gamma$ :

$$1 - \text{SPECIFICITY}_\gamma = 1 - \frac{\text{TN}_\gamma}{\text{TN}_\gamma + \text{FP}_\gamma} = \frac{\text{FP}_\gamma}{\text{TN}_\gamma + \text{FP}_\gamma}$$

- Sulle ordinate mettiamo il valore *RECALL* al variare di  $\gamma$ :

$$\text{RECALL}_\gamma = \frac{\text{TP}_\gamma}{\text{TP}_\gamma + \text{FN}_\gamma}$$

Il risultato finale è una curva che passa per i punti  $(0, 0)$  e  $(1, 1)$ , che corrispondono rispettivamente ai casi in cui i valori di soglia sono troppo alti (e quindi non viene identificato nessun evento di tampering) o sono troppo bassi (e quindi tutti i dati vengono considerati come tampering). L'area

sottesa a ciascuna curva prende il nome di *Area Under Curve* della ROC (AUC) e il suo valore fornisce un elemento di confronto fra tecniche diverse. Dato uno specifico tampering, quindi, possiamo scegliere la tecnica la cui ROC curve ha un valore di AUC più elevato. Inoltre, grazie alle ROC curve, possiamo ricavare il valore ottimale del parametro  $\gamma$ , cercando quello per cui la curva è più vicina al punto  $(0, 1)$ .

### 5.3.2 Metriche per il monitoraggio sequenziale

Per valutare le prestazioni del monitoraggio sequenziale, abbiamo analizzato i valori di alcuni indicatori al variare dell'intensità della sfocatura presente nelle immagini affette da tampering. Abbiamo fatto questa valutazione solamente per gli eventi di tampering creati artificialmente; l'intensità della sfocatura, in questo modo, è determinata univocamente dalla larghezza del filtro  $f$ , utilizzato in (5.3) per la creazione della sfocatura, e dalla sua deviazione standard  $\sigma$ .

Se indichiamo con  $T^*$  l'istante in cui avviene l'evento di sfocatura e con  $\hat{T}$  la sua stima fatta dal monitoraggio sequenziale, le figure di merito che possiamo considerare sono:

- **False Positive Rate** (FPR), ovvero la percentuale di sequenze in cui viene indicato erroneamente un evento di tampering, ovvero quando  $\hat{T} < T^*$ .
- **False Negative Rate** (FNR), ovvero la percentuale di sequenze in cui non viene identificato un evento di tampering.
- **Detection Delay** (DD), ovvero la latenza media  $(\hat{T} - T^*)$  in caso di corretta identificazione dell'evento di tampering, che si ha nel caso in cui  $\hat{T} > T^*$ .

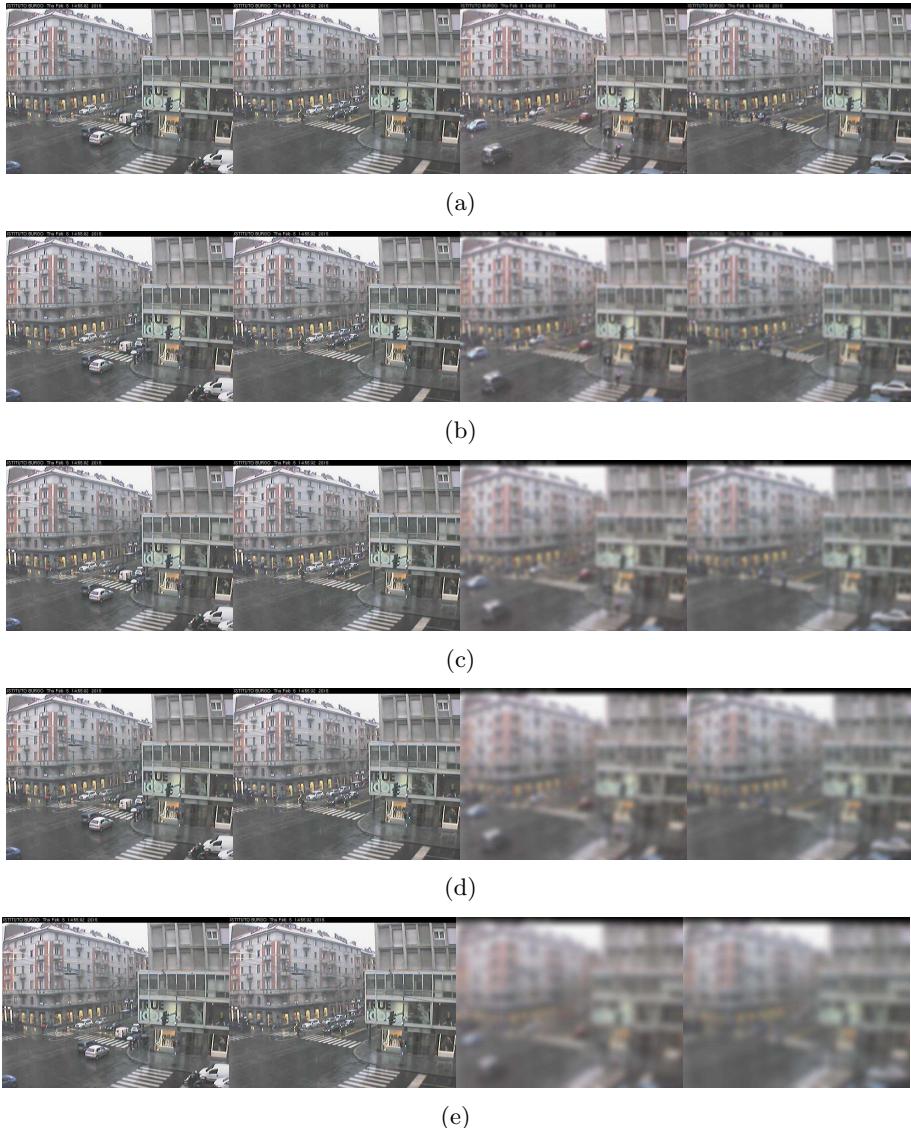
## 5.4 Esperimento 1: tampering sintetico

Le prime prove sperimentali che abbiamo condotto riguardano l'utilizzo di sequenze video in cui gli eventi di tampering vengono indotti sinteticamente, utilizzando le tecniche che abbiamo descritto nel Paragrafo 5.2.1. Abbiamo analizzato il comportamento del nostro algoritmo per varie sequenze di frame e utilizzato le cifre di merito e i grafici introdotti nel Paragrafo 5.3.

### 5.4.1 Creazione del tampering

Gli esperimenti sintetici sono stati condotti sia per quanto riguarda la sfocatura che per quanto riguarda lo spostamento della camera.

Gli eventi di sfocatura sono stati creati utilizzando la (5.3). In particolare



*Figura 5.3: Esempi di sequenze con eventi di sfocature create con filtri gaussiani: (a)  $\sigma = 1$ , (b)  $\sigma = 3$ , (c)  $\sigma = 5$ , (d)  $\sigma = 7$ , (e)  $\sigma = 10$ .*



Figura 5.4: Esempio di sequenza con un evento di spostamento della camera creato sinteticamente

abbiamo considerato tre diverse scene. Per ciascuna scena abbiamo utilizzato 10 diversi tipi di filtro gaussiano, variando la deviazione standard  $\sigma$  tra 1 e 10. Inoltre, per ciascun filtro, abbiamo creato 5 sequenze diverse, cambiando l'istante in cui avviene l'evento di sfocatura. In totale, quindi, le sequenze video che abbiamo considerato per la nostra valutazione sono state 150. La Figura 5.3 mostra alcuni esempi di come operano i filtri gaussiani appena definiti.

Per simulare l'evento di spostamento della camera, invece, abbiamo creato 100 sequenze di frame concatenando due diversi scenari tra loro. Per rendere la simulazione il più verosimile possibile, le sequenze video concatenate hanno dovuto rispettare alcuni vincoli:

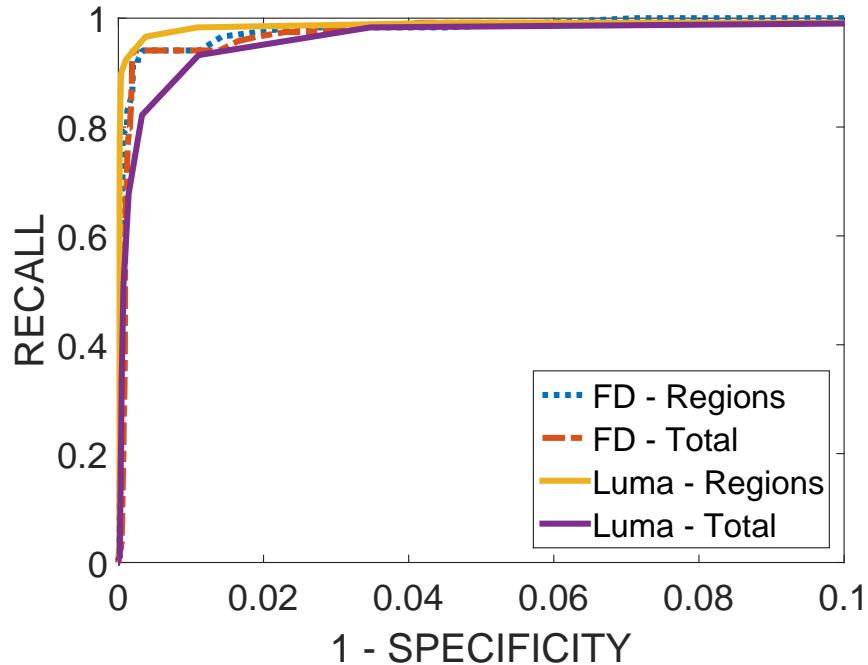
- le acquisizioni di entrambe le sequenze devono avvenire nello stesso giorno e negli stessi istanti di tempo;
- lo scenario ripreso dalle due sequenze deve essere simile; ad esempio, nel nostro caso, entrambe le sequenze video riprendevano strade trafficate,
- le due camere che eseguono l'acquisizione devono essere posizionate a un'altezza simile; ad esempio, nel nostro caso, le due camere erano entrambe poste al primo piano di un palazzo,
- le due camere che eseguono l'acquisizione devono essere orientate in maniera *diversa* tra loro.

La Figura 5.4 mostra un esempio di sequenze concatenate tra loro per simulare l'evento di spostamento della camera.

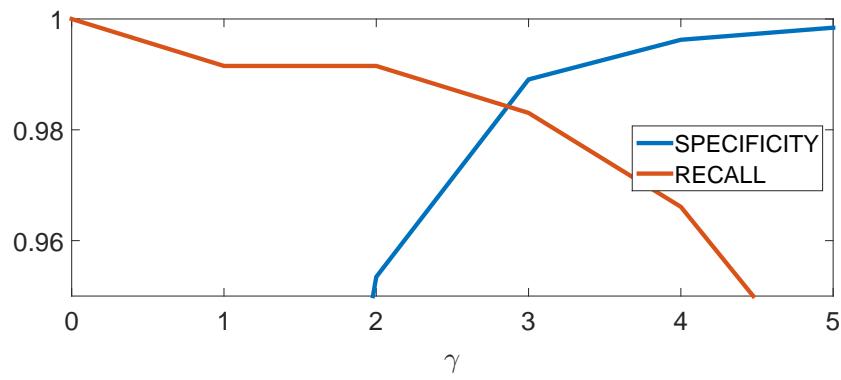
#### 5.4.2 Risultati

Una volta create tutte le sequenze di tampering abbiamo proceduto ad analizzare il comportamento del nostro algoritmo.

Per le tecniche one-shot abbiamo osservato le prestazioni dell'algoritmo al variare del parametro  $\gamma$  utilizzato per la definizione delle soglie in (5.4). In particolare, abbiamo considerato valori di  $\gamma$  compresi tra 0 e 500. Le prestazioni al variare del parametro  $\gamma$  sono state riportate su delle ROC curve in modo da poter confrontare tecniche differenti e scegliere il parametro  $\gamma$  ottimale.



(a)



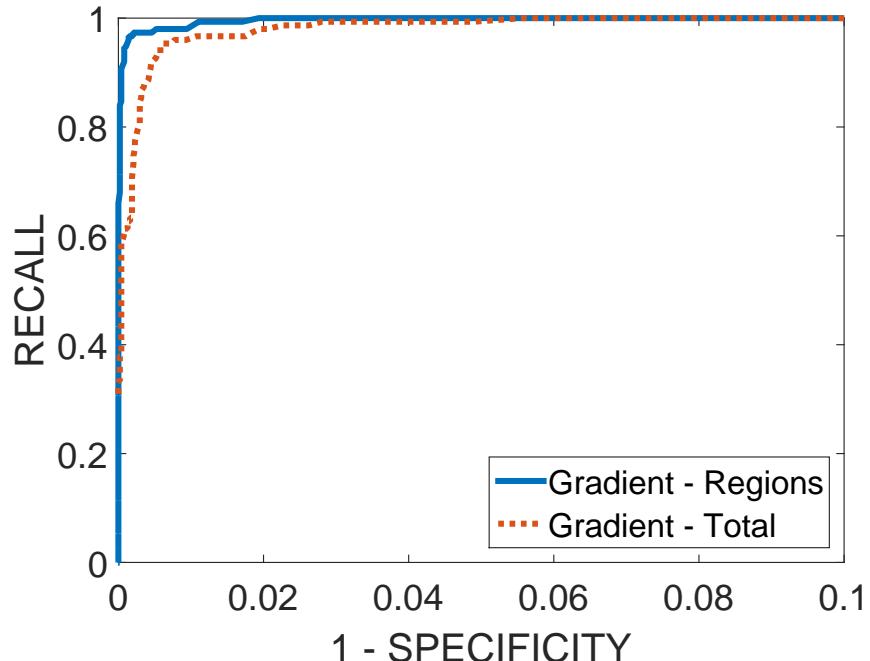
(b)

*Figura 5.5: Nella Figura (a) notiamo l'andamento delle ROC curve per gli indicatori utilizzati per individuare l'evento di spostamento della camera. Come possiamo vedere i risultati migliori sono dati dall'analisi, nelle regioni, dell'energia media della luma. In (b), invece, vediamo la scelta del parametro  $\gamma$  per lo spostamento della camera nel caso di analisi, nelle regioni, dell'energia media della luma. La scelta è stata compiuta trovando il valore di  $\gamma$  in cui i valori SPECIFICITY e RECALL si intersecano. Dal grafico in figura possiamo notare che le due caratteristiche si intersecano per  $\gamma = 3$ .*

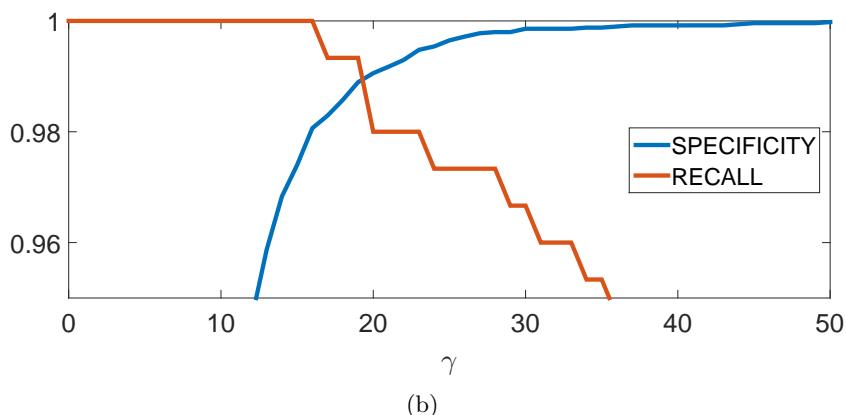
Nella Figura 5.5(a) possiamo vedere le ROC curve costruite per valutare gli indicatori utilizzati per individuare uno spostamento della camera. Le curve visualizzate sul grafico fanno riferimento a valori di  $1 - \text{SPECIFICITY}$  compresi tra 0 e 0.1, in quanto tutte le tecniche comunque mantengono buone prestazioni senza avere un numero troppo alto di falsi positivi (che rimangono sotto al 5% anche per valori di RECALL prossimi a 1). Quello che possiamo notare è come, per i valori più bassi di  $1 - \text{SPECIFICITY}$ , le prestazioni migliori si abbiano nel caso in cui si utilizzi l'algoritmo di identificazione degli spostamenti della camera descritto nel Paragrafo 4.2.2, dove viene utilizzato il monitoraggio dell'energia media della luma assieme alla segmentazione della scena in regioni. In particolare i risultati migliori si hanno nel caso in cui  $\gamma = 3$  dove, considerando il nostro algoritmo, abbiamo  $1 - \text{SPECIFICITY} = 0.0109$  e  $\text{RECALL} = 0.9831$ . La scelta del valore ottimale di  $\gamma$  è stato trovato guardando i grafici dei valori di SPECIFICITY e RECALL in funzione di  $\gamma$ , che sono riportati in Figura 5.5(b), e trovando il punto in cui i due grafici si intersecano.

Nella Figura 5.6(a) possiamo vedere le ROC curve costruite per valutare gli indicatori utilizzati per individuare eventi di sfocatura. In questo caso abbiamo fatto un confronto tra la nostra scelta di utilizzare le regioni nell'analisi dell'energia media del gradiente, illustrata nel Paragrafo 4.2.1, e la stessa analisi considerando però la totalità della scena. Dalle due ROC curve possiamo vedere come l'utilizzo dell'informazione portata dalle regioni porti a un miglioramento delle prestazioni. In particolare i risultati migliori si hanno nel caso in cui  $\gamma = 19$  dove, considerando il nostro algoritmo, abbiamo  $1 - \text{SPECIFICITY} = 0.0111$  e  $\text{RECALL} = 0.9933$ . La scelta del valore ottimale di  $\gamma$ , ancora una volta, è stato trovato guardando i grafici dei valori di SPECIFICITY e RECALL in funzione di  $\gamma$ , che sono riportati in Figura 5.6(b), e trovando il punto in cui i due grafici si intersecano.

Per quanto riguarda l'identificazione delle sfocature, inoltre, abbiamo analizzato le prestazioni del monitoraggio sequenziale della varianza dell'energia media del gradiente in funzione dell'intensità della sfocatura, determinata dal parametro  $\sigma$  del filtro gaussiano usato per simularla. Nelle Figure 5.7(a), 5.7(b) e 5.7(c) vediamo, rispettivamente, i valori di *Detection Delay*, *False Positive Rate* e *False Negative Rate* in funzione del valore di  $\sigma$ . Possiamo notare come la latenza del monitoraggio decresca in funzione dell'intensità della sfocatura, ma rimane comunque elevata anche per sfocature consistenti. Ciò è dovuto al fatto che il CDT utilizzato nel monitoraggio sequenziale opera *a finestre* e, quindi, l'identificazione di un cambiamento nella stazionarietà dell'indicatore è determinato dal numero di osservazioni costituenti una finestra. Per quanto riguarda l'andamento dei falsi positivi possiamo notare come questi non siano influenzati dal grado di intensità della sfocatura. Questo è normale dato che queste identificazioni avvengono prima che l'evento effettivamente si manifesti. Possiamo vedere, infine, come i falsi negativi siano influenzati dall'intensità della sfocatura.



(a)



(b)

*Figura 5.6: Nella Figura (a) illustriamo l'andamento delle ROC curve per gli indicatori utilizzati per individuare un evento di sfocatura. Come possiamo vedere i risultati migliori sono dati dall'analisi, nelle regioni, dell'energia media del gradiente. In (b), invece, vediamo la scelta del parametro  $\gamma$  per la sfocatura. La scelta è stata compiuta trovando il valore di  $\gamma$  in cui i valori SPECIFICITY e RECALL si intersecano. Dal grafico in figura possiamo notare che le due caratteristiche si intersecano per  $\gamma = 19$ .*

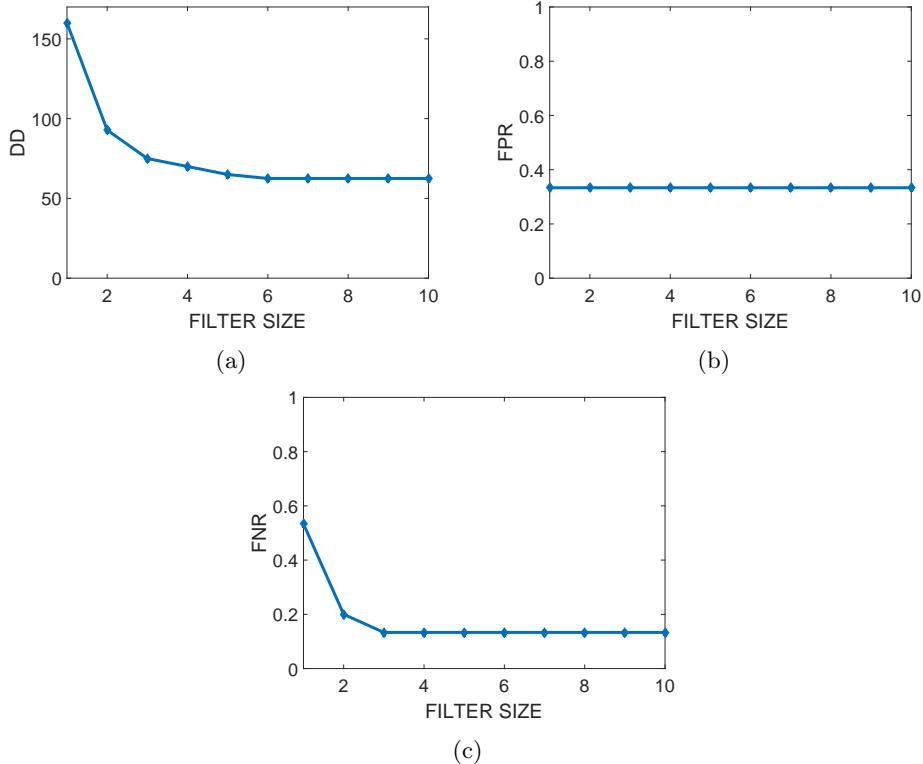
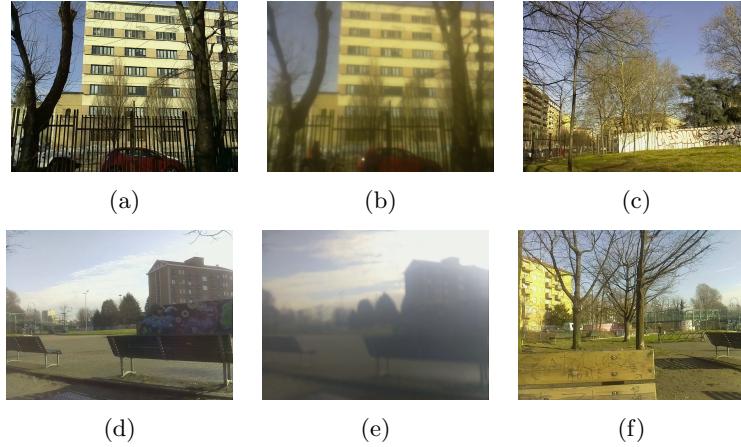


Figura 5.7: Prestazioni del monitoraggio sequenziale per l’identificazione di sfocature al variare dell’intensità di sfocatura: (a) detection delay, (b) false positive rate, (c) false negative rate

Come abbiamo potuto vedere, il monitoraggio sequenziale ha lo svantaggio principale di avere una latenza molto alta. L’ultimo esperimento che abbiamo condotto è servito per verificare la sua effettiva utilità affiancato al monitoraggio one-shot dell’energia media del gradiente sulle regioni. Per verificare ciò abbiamo fissato il valore del parametro  $\gamma$  al suo valore ottimale ricavato precedentemente, ovvero  $\gamma = 19$ . Fissato questo valore abbiamo eseguito l’algoritmo su tutte le sequenze video con eventi di sfocatura. L’algoritmo è stato in grado di identificare l’evento su 148 sequenze sulle 150 totali, con una resa del 99%. Per le due sequenze che non sono state riconosciute abbiamo eseguito il monitoraggio sequenziale. In questo caso siamo stati in grado di identificare correttamente un’ulteriore sequenza, mentre la restante ha prodotto un falso negativo.

## 5.5 Esperimento 2: tampering reale

La seconda prova sperimentale è stata fatta su alcune sequenze riprese utilizzando il sistema basato su Raspberry Pi, dove sono presenti eventi di



*Figura 5.8: In questa figura sono riportate le sequenze di tampering reale considerate: Prima scena (a) scena originale (b) evento di sfocatura (c) evento di spostamento della camera. Seconda scena (d) scena originale (e) evento di sfocatura (f) evento di spostamento della camera.*

tampering *reali*, realizzati come descritto nel Paragrafo 5.2.1. Esempi di frame utilizzati durante l'esperimento sono illustrati nella Figura 5.8. In particolare abbiamo analizzato il comportamento del nostro algoritmo per due scene differenti, considerando sia il caso di sfocatura che quello di spostamento della camera. Le sequenze totali, quindi, sono state 4.

Per gli esperimenti condotti abbiamo utilizzato i valori di  $\gamma$ , il parametro che determina le soglie, ricavati nel Paragrafo 5.4, ovvero

- $\gamma = 19$  per gli eventi di sfocatura;
- $\gamma = 3$  per identificare gli eventi di spostamento della camera.

Per tutte e quattro le sequenze l'algoritmo è stato in grado di individuare l'evento di tampering. Nonostante questo abbiamo avuto in tutte le sequenze un certo numero di falsi positivi, soprattutto per quanto riguarda lo spostamento della camera.

## Capitolo 6

# Conclusioni e direzioni future di ricerca

In questo lavoro di tesi abbiamo presentato una soluzione al problema, riguardante sistemi di monitoraggio video, di identificare particolari eventi che possano compromettere la corretta ripresa della scena, a cui si fa riferimento con il termine tampering. In particolare abbiamo considerato l'utilizzo di camere intelligenti alimentate a batteria e lo scenario in cui la frequenza di acquisizione delle immagini da parte del sensore sia bassa, ad esempio un frame ogni minuto.

Abbiamo visto come il fatto di considerare dei framerate bassi complichii l'identificazione di eventi di tampering, in quanto le differenze tra frame consecutivi sono molto più elevate rispetto al caso di acquisizione continua. Inoltre, il fatto di avere algoritmi a bassa complessità computazionale non ci permette di utilizzare degli indicatori troppo onerosi da estrarre dalle immagini.

La soluzione che abbiamo proposto è stata di utilizzare degli indicatori semplici, da estrarre in specifiche regioni della scena inquadrata dalla camera, e di monitorarli nel tempo con tecniche one-shot e sequenziali, in modo da individuare cambiamenti nel loro comportamento associabili a eventi di tampering. Le regioni vengono estratte da un algoritmo di segmentazione della scena, che viene eseguito prima della messa in opera del sistema.

Abbiamo visto, infine, come le prove sperimentali condotte abbiano dimostrato che l'utilizzo della segmentazione della scena porti a dei miglioramenti nelle prestazioni dell'algoritmo, diminuendo il numero di falsi allarmi, senza aggiungere complessità computazionale. Un monitoraggio sequenziale sulla varianza dell'energia media del gradiente, inoltre, ha permesso di diminuire ulteriormente i falsi allarmi nell'identificazione degli eventi di sfocatura.

Gli sviluppi futuri riguarderanno il miglioramento dell'algoritmo e la sua integrazione su un dispositivo. Per quanto riguarda l'identificazione di sfocature la ricerca dovrà essere condotta su come combinare il monitoraggio

sequenziale con quello one-shot. Per come è stato realizzato l'algoritmo al momento, infatti, le due tecniche sono eseguite in cascata, e il primo che identifica un cambiamento solleva l'allarme. Combinare le due tecniche, ad esempio utilizzando il monitoraggio sequenziale come *validazione* degli allarmi lanciati dal monitoraggio one-shot, potrebbe portare a un miglioramento delle prestazioni, riducendo il numero di falsi allarmi e, di conseguenza, il consumo energetico dovuto alla trasmissione di segnali inutili.

Per quanto riguarda l'identificazione di spostamenti della camera un ulteriore sviluppo potrebbe riguardare l'integrazione delle informazioni estratte dalle immagini della camera con i dati estratti da dispositivi MEMS (*Micro Electro-Mechanical Systems*), in modo da poter validare gli allarmi ricevuti dalla camera. Uno scenario possibile, ad esempio, potrebbe essere quello in cui abbiamo dei sensori inerziali che forniscono un'acquisizione *continua* di dati accelerometrici e giroscopici. I dati estratti dalla camera possono essere utilizzati come un'*informazione aggiuntiva* per validare un evento di spostamento della camera identificato dal sensore inerziale.

La fase finale dello sviluppo dovrebbe consistere nell'integrazione dell'algoritmo su un prototipo di smart camera di *STMicroelectrics*. L'integrazione passa prima di tutto da una riscrittura del codice MATLAB in C, rispettando alcuni vincoli di ottimizzazione del codice. In seguito sarà possibile accelerare alcune funzioni direttamente in hardware, in modo da aumentare le prestazioni e ridurre il consumo energetico.

# Bibliografia

- [1] Ian F Akyildiz, Tommaso Melodia, and Kaushik R Chowdhury. A survey on wireless multimedia sensor networks. *Computer networks*, 51(4):921–960, 2007.
- [2] Wayne Wolf, Burak Ozer, and Tiehan Lv. Smart cameras as embedded systems. *Computer*, 35(9):48–53, 2002.
- [3] Sebastien Harasse, Laurent Bonnaud, Alice Caplier, and Michel Desvignes. Automated camera dysfunctions detection. In *Image Analysis and Interpretation, 2004. 6th IEEE Southwest Symposium on*, pages 36–40. IEEE, 2004.
- [4] Anil Aksay, Alptekin Temizel, and A. Emis Cetin. Camera tamper detection using wavelet analysis for video surveillance. In *Advanced Video and Signal Based Surveillance, 2007. AVSS 2007. IEEE Conference on*, pages 558–562. IEEE, 2007.
- [5] Ali Saglam and Alptekin Temizel. Real-time adaptive camera tamper detection for video surveillance. In *Advanced Video and Signal Based Surveillance, 2009. AVSS'09. Sixth IEEE International Conference on*, pages 430–435. IEEE, 2009.
- [6] Damian Ellwart, Piotr Szczuko, and Andrzej Czyżewski. Camera sabotage detection for surveillance systems. In *Security and Intelligent Information Systems*, pages 45–53. Springer, 2012.
- [7] Theodore Tsesmelis, Lars Christensen, Preben Fihl, and Thomas B Moeslund. Tamper detection for active surveillance systems. In *Advanced Video and Signal Based Surveillance (AVSS), 2013 10th IEEE International Conference on*, pages 57–62. IEEE, 2013.
- [8] Antonio Manetti, Domenico De Robertis, and Giuliano Tanturli. *Vita di Filippo Brunelleschi: preceduta da La novella del Grasso*, volume 2. Milano: Il Polifilo, 1976.
- [9] Richard Hartley and Andrew Zisserman. *Multiple view geometry in computer vision*. Cambridge university press, 2003.

- [10] David A Forsyth and Jean Ponce. Computer vision: A modern approach. 2002.
- [11] Cesare Alippi. *Intelligence for Embedded Systems*. Springer, 2014.
- [12] Sheldon M. Ross. *Introduction to probability and statistics for engineers and scientists*. Academic Press, 2009.
- [13] Gordon J. Ross, Dimitris K. Tasoulis, and Niall M. Adams. Nonparametric monitoring of data streams for changes in location and scale. *Technometrics*, 53(4):379–389, 2011.
- [14] Cesare Alippi and Manuel Roveri. Just-in-time adaptive classifiers—part I: Detecting nonstationary changes. *Neural Networks, IEEE Transactions on*, 19(7):1145–1153, 2008.
- [15] Cesare Alippi, Giacomo Boracchi, and Manuel Roveri. A just-in-time adaptive classification system based on the intersection of confidence intervals rule. *Neural Networks*, 24(8):791–800, 2011.
- [16] A. Goldenshluger and A. Nemirovski. On spatially adaptive estimation of nonparametric regression. *Mathematical methods of Statistics*, 6(2):135–170, 1997.
- [17] George E.P. Box and David R. Cox. An analysis of transformations. *Journal of the Royal Statistical Society. Series B (Methodological)*, pages 211–252, 1964.
- [18] BFJ Manly. Exponential data transformations. *The Statistician*, pages 37–42, 1976.
- [19] Giacomo Boracchi and Manuel Roveri. A reconfigurable and element-wise ici-based change-detection test for streaming data. *Computational Intelligence and Virtual Environments for Measurement Systems and Applications (CIVEMSA), 2014 IEEE International Conference on*, pages 58–63, 2014.
- [20] Cesare Alippi, Giacomo Boracchi, and Manuel Roveri. A hierarchical, nonparametric, sequential change-detection test. In *Neural Networks (IJCNN), The 2011 International Joint Conference on*, pages 2889–2896. IEEE, 2011.
- [21] <http://www.mitan.it/security-solution/videosorveglianza/sistemi-di-videosorveglianza-e-registrazione/>. Visitato il giorno 09/03/2015.
- [22] Pedro Gil-Jiménez, R. López-Sastre, Philip Siegmann, Javier Acevedo-Rodríguez, and Saturnino Maldonado-Bascón. Automatic control of

- video surveillance camera sabotage. *Nature Inspired Problem-Solving Methods in Knowledge Engineering*, pages 222–231, 2007.
- [23] Evan Ribnick, Stefan Atev, Osama Masoud, Nikolaos Papanikolopoulos, and Richard Voyles. Real-time detection of camera tampering. In *Video and Signal Based Surveillance, 2006. AVSS’06. IEEE International Conference on*, pages 10–10. IEEE, 2006.
  - [24] Nuno Roma, José Santos-Victor, and José Tomé. A comparative analysis of cross-correlation matching algorithms using a pyramidal resolution approach. 2002.
  - [25] Tomasz Kryjak, Mateusz Komorkiewicz, and Marek Gorgon. Fpga implementation of real-time head-shoulder detection using local binary patterns, svm and foreground object detection. In *Design and Architectures for Signal and Image Processing (DASIP), 2012 Conference on*, pages 1–8. IEEE, 2012.
  - [26] Stephane G Mallat. A theory for multiresolution signal decomposition: the wavelet representation. *Pattern Analysis and Machine Intelligence, IEEE Transactions on*, 11(7):674–693, 1989.
  - [27] Ronald N Bracewell. The fourier transform and its applications. 1978.
  - [28] Irwin Sobel and Gary Feldman. A 3x3 isotropic gradient operator for image processing. 1968.
  - [29] John Canny. A computational approach to edge detection. *Pattern Analysis and Machine Intelligence, IEEE Transactions on*, (6):679–698, 1986.
  - [30] Marco A.F. Pimentel, David A. Clifton, Lei Clifton, and Lionel Tarassenko. A review of novelty detection. *Signal Processing*, 99:215–249, 2014.
  - [31] Herbert Bay, Tinne Tuytelaars, and Luc Van Gool. Surf: Speeded up robust features. In *Computer vision–ECCV 2006*, pages 404–417. Springer, 2006.
  - [32] Cesare Alippi, Giacomo Boracchi, Romolo Camplani, and Manuel Roveri. Detecting external disturbances on the camera lens in wireless multimedia sensor networks. *Instrumentation and Measurement, IEEE Transactions on*, 59(11):2982–2990, 2010.
  - [33] Jong Bae Kim and Hang Joon Kim. Efficient region-based motion segmentation for a video monitoring system. *Pattern Recognition Letters*, 24(1):113–128, 2003.

- [34] Dane P Kottke and Ying Sun. Motion estimation via cluster matching. *Pattern Analysis and Machine Intelligence, IEEE Transactions on*, 16(11):1128–1132, 1994.
- [35] Yan Ke, Rahul Sukthankar, and Martial Hebert. Event detection in crowded videos. In *Computer Vision, 2007. ICCV 2007. IEEE 11th International Conference on*, pages 1–8. IEEE, 2007.
- [36] Yining Deng and BS Manjunath. Unsupervised segmentation of color-texture regions in images and video. *Pattern Analysis and Machine Intelligence, IEEE Transactions on*, 23(8):800–810, 2001.
- [37] Yihong Gong and Xin Liu. Video summarization using singular value decomposition. In *Computer Vision and Pattern Recognition, 2000. Proceedings. IEEE Conference on*, volume 2, pages 174–180. IEEE, 2000.
- [38] Richard M Jiang, Abdul H Sadka, and Danny Crookes. Hierarchical video summarization in reference subspace. *Consumer Electronics, IEEE Transactions on*, 55(3):1551–1557, 2009.
- [39] Alessandro Sentinelli and Luca Celetto. Live key frame extraction in user generated content scenarios for embedded mobile platforms. In *MultiMedia Modeling*, pages 291–302. Springer International Publishing, 2014.
- [40] Wayne Wolf. Key frame selection by motion analysis. In *Acoustics, Speech, and Signal Processing, 1996. ICASSP-96. Conference Proceedings., 1996 IEEE International Conference on*, volume 2, pages 1228–1231. IEEE, 1996.
- [41] Jiawei Han and Micheline Kamber. *Data Mining: Concepts and Techniques*. Morgan kaufmann, 2011.
- [42] Stuart Lloyd. Least squares quantization in pcm. *Information Theory, IEEE Transactions on*, 28(2):129–137, 1982.
- [43] David Arthur and Sergei Vassilvitskii. k-means++: The advantages of careful seeding. In *Proceedings of the eighteenth annual ACM-SIAM symposium on Discrete algorithms*, pages 1027–1035. Society for Industrial and Applied Mathematics, 2007.
- [44] Tadeusz Caliński and Jerzy Harabasz. A dendrite method for cluster analysis. *Communications in Statistics-theory and Methods*, 3(1):1–27, 1974.
- [45] <http://it.mathworks.com/products/matlab>.

- [46] [http://www.nikon.it/it\\_IT/product/discontinued/digital-cameras/2011/coolpix-s570/](http://www.nikon.it/it_IT/product/discontinued/digital-cameras/2011/coolpix-s570/).
- [47] <http://www.raspberrypi.org/products/model-b-plus/>.
- [48] <http://www.raspberrypi.org/products/camera-module/>.
- [49] <http://www.broadcom.com/products/BCM2835/>.
- [50] [http://www.arm.com/products/processors/classic/arm11/arm1176.php/](http://www.arm.com/products/processors/classic/arm11/arm1176.php).
- [51] [http://www.broadcom.com/products/technology/mobmm\\_videocore.php/](http://www.broadcom.com/products/technology/mobmm_videocore.php).
- [52] <http://www.raspbian.org/>.
- [53] <http://picamera.readthedocs.org/en/release-1.9/>.
- [54] <http://www.ilmeteo.it/webcam/>.
- [55] <http://curl.haxx.se/>.